Raport 3

Analiza și procesarea extinsă a parametrilor fiziologici în evaluarea comportamentului uman

Student: Nicolescu Șerban-Teodor

CUPRINS

1. Introducere 3

2. Determinarea stărilor emoționale prin procesarea undelor EEG 5

2.1. Introducere 6

2.2. Înregistrarea şi măsurarea EEG 10

2.2.1. Poziţionarea convenţională a electrozilor EEG 13

2.2.2. Condiţionarea semnalelor EEG 15

2.3. Noţiuni fundamentale ale procesării semnalelor EEG 16

2.4. Modelarea semnalului EEG 18

2.4.1. Modelarea liniară a semnalelor EEG 23

2.4.1.1. Metoda predicţiei 23

2.4.1.2. Metoda lui Prony 25

2.4.2. Modelarea nonlineară a semnalelor EEG 26

2.4.2.1. Generarea EEG pe baza modelării activităţilor neuronale 28

2.4.2.2. Nonlinearitatea mediului 31

2.4.3. Nonstaționaritatea semnalelor EEG 32

2.4.4. Segmentarea semnalelor EEG 34

3. Concluzii 39

4. Bibliografie 40

1. Introducere

În infrastructurile critice, unde siguranța operațională și fiabilitatea personalului reprezintă elemente indispensabile pentru funcționarea continuă, monitorizarea comportamentului uman devine o prioritate strategică. Aceste medii complexe, care includ domenii precum transporturile, energia, telecomunicațiile și sănătatea publică, depind în mod direct de capacitatea personalului de a reacționa adecvat la situații de stres sau criză. În acest context, chiar și cea mai mică deviere comportamentală poate avea consecințe semnificative, ducând la breșe de securitate, erori operaționale sau pierderi de resurse critice. Un aspect esențial al monitorizării comportamentului este identificarea stărilor emoționale și a comportamentelor disimulate, care pot semnala stres, anxietate sau intenții ascunse. Aceste stări nu doar că pot afecta luarea deciziilor, dar pot influența negativ și dinamica echipelor, reducând astfel eficiența și siguranța operațională. De exemplu, personalul operativ, aflat sub presiuni constante, poate manifesta comportamente care maschează starea reală a individului, fie din dorința de a ascunde vulnerabilități, fie din cauza unor intenții distructive. Detectarea acestor comportamente în timp util permite o gestionare proactivă a riscurilor și oferă posibilitatea de a interveni pentru a preveni incidentele. În plus, tehnologiile moderne oferă oportunități noi pentru monitorizarea automată a acestor variabile complexe. Prin utilizarea parametrilor fiziologici și a tehnicilor de procesare avansată, stările emoționale și comportamentele critice pot fi analizate în timp real, furnizând informații valoroase pentru deciziile operative. Această capacitate de a detecta rapid și obiectiv semnale subtile devine un avantaj esențial în medii unde viteza de reacție și precizia sunt cruciale pentru menținerea funcționalității optime a sistemelor critice. Astfel, integrarea unor soluții avansate de monitorizare și evaluare a comportamentului uman sprijină nu doar siguranța infrastructurilor critice, ci și adaptabilitatea acestora în fața amenințărilor emergente.

Acest raport, intitulat *„Analiza și procesarea extinsă a parametrilor fiziologici în evaluarea comportamentului uman”*, extinde cercetările anterioare din cadrul tezei de doctorat *„Contribuții privind sistemele de evaluare automată a comportamentului uman pentru personalul din infrastructuri critice”*. Raportul își propune să investigheze în profunzime procesarea undelor EEG, cu scopul de a înțelege mai bine relația acestora cu comportamentele critice. Dacă raportul precedent a explorat utilizarea undelor EEG pentru detectarea

comportamentului disimulat, acest raport se concentrează exclusiv pe procesarea și analiza avansată a acestor semnale, fără a extinde încă analiza la alți parametri fiziologici. Obiectivul principal este determinarea stării emoționale a subiecților prin identificarea tiparelor specifice din semnalele EEG și dezvoltarea unor metode eficiente de prelucrare, eliminare a artefactelor și interpretare a datelor. În acest scop, raportul explorează utilizarea tehnologiilor avansate de inteligență artificială (IA), inclusiv algoritmi de învățare automată și de învățare profundă, pentru procesarea semnalelor EEG. Aceste metode permit detectarea tiparelor subtile din datele complexe, sprijinind astfel dezvoltarea unor soluții automatizate pentru evaluarea comportamentului în medii critice. Rezultatele acestui raport vor constitui baza pentru investigațiile viitoare privind corelarea undelor EEG cu alți parametri fiziologici, care vor fi abordate în detaliu în următorul raport. Această abordare progresivă subliniază importanța analizei detaliate a undelor EEG ca etapă fundamentală pentru construirea unui sistem integrat de monitorizare și evaluare a comportamentului uman. Prin concentrarea pe procesarea EEG, raportul contribuie la dezvoltarea unei baze științifice solide pentru înțelegerea comportamentului disimulat, sprijinind, în cele din urmă, siguranța și funcționalitatea infrastructurilor critice.

2. Determinarea stărilor emoționale prin procesarea undelor EEG

Înțelegerea stărilor emoționale ale indivizilor joacă un rol esențial în analiza comportamentului uman, în special în contexte critice, unde deciziile rapide și precise pot avea un impact semnificativ asupra securității și performanței operaționale. Electroencefalograma (EEG), o metodă non-invazivă de monitorizare a activității electrice a creierului, reprezintă o tehnologie avansată capabilă să ofere informații detaliate despre stările mentale și emoționale ale unei persoane. Prin analiza undelor cerebrale înregistrate, cum ar fi cele alfa, beta, theta sau delta, se pot identifica tipare specifice care reflectă emoții, stres sau activitate cognitivă intensă.

Acest capitol își propune să exploreze modul în care procesarea și analiza undelor EEG pot fi utilizate pentru determinarea stărilor emoționale și identificarea comportamentelor critice, cum ar fi disimularea sau reacțiile incongruente. Analiza EEG oferă o perspectivă directă asupra activității cerebrale, permițând detectarea tiparelor subtile asociate cu stări emoționale complexe și comportamente deviante. Această etapă a cercetării se concentrează exclusiv pe procesarea semnalelor EEG, punând bazele pentru corelarea acestora cu alți parametri fiziologici în studii viitoare. Deși semnalele EEG sunt extrem de informative, interpretarea lor poate fi îmbunătățită prin utilizarea tehnicilor avansate de prelucrare și eliminare a artefactelor. Identificarea și separarea semnalelor relevante, cum ar fi cele asociate cu benzile alfa, beta, theta și gamma, contribuie la înțelegerea activității neuronale și a răspunsurilor involuntare în contexte critice. Spre exemplu, o activitate intensificată în banda beta poate indica stări de alertă sau anxietate, oferind indicii esențiale despre starea emoțională a subiectului. Un alt obiectiv central al acestui capitol este utilizarea tehnologiilor de inteligență artificială (IA) pentru procesarea datelor EEG. Algoritmii de învățare automată, în special cei de învățare profundă, permit detectarea tiparelor complexe și automatizarea procesului de analiză, facilitând interpretarea rapidă și precisă a datelor. Aceste metode contribuie la dezvoltarea unor sisteme predictive, care pot evalua în timp real stările emoționale și comportamentele relevante pentru infrastructurile critice. Prin investigarea undelor EEG, acest capitol contribuie la fundamentarea unui sistem integrat de monitorizare a comportamentului uman, concentrându-se pe analiza detaliată a semnalelor cerebrale. Rezultatele obținute vor oferi o bază solidă pentru integrarea viitoare a altor parametri fiziologici, cum ar fi temperatura

corporală, tensiunea arterială, saturația de oxigen, ECG etc. contribuind astfel la construirea unui model complet și holistic pentru evaluarea comportamentului uman în medii critice. Abordarea propusă sprijină siguranța operațională și eficiența infrastructurilor critice, facilitând intervențiile rapide și informate în situații care necesită decizii esențiale.

2.1. Introducere

Activitatea neurală a creierului uman începe între a 17-23 săptămână a dezvoltării prenatale. Se crede că din această fază timpurie şi de-a lungul întregii vieţi, semnalele electrice generate de creier caracterizează nu doar funcţionarea creierului dar şi starea întregului corp. Această ipoteză motivează utilizarea metodelor de procesare avansată a semnalului digital semnalelor electroencefalogramei (EEG) măsurate la nivelul creierului subiectului uman [1]. Emisferele cerebrale includ regiuni ale mişcării, ale senzaţiilor conştiente, analiza complexă, exprimarea emoţiilor şi comportamentului [2]. Cerebelul coordonează mişcările voluntare ale muşchilor şi menţinerea echilibrului. Trunchiul cerebral controlează funcţiile involuntare precum: respiraţia, reglarea inimii, bioritmul şi aparatele neurohormonale şi hormonale. Așadar, studiul semnalelor EEG deschide calea pentru diagnosticarea multor tulburări neuronale precum şi determinarea unor parametri psihologici sau de interacţiune a omului cu calculatorul. Obţinerea semnalelor EEG de la o fiinţă umană poate, de exemplu, să fie utilizată în investigarea următoarelor probleme clinice descrise în Figura 2.1. Această listă confirmă potenţialul bogat al analizei EEG şi motivează nevoia unor tehnici avansate de suport pentru interpretările făcute de persoanele specializate. În continuare vor fi descrise ritmurile creierului, care se doresc a fi măsurate pe baza semnalelor EEG. Figura 2.2 prezintă un model al creierului uman. Multe tulburări ale creierului sunt diagnosticate pe baza vizualizării semnalelor EEG. Clinicienii experţi în domeniu sunt obişnuiţi cu manifestările ritmurilor creierului în semnalele EEG. La adulţii sănătoşi, amplitudinea şi frecvenţa acestor semnale se schimbă de la o stare la alta a omului, cum sunt starea de veghe şi somnul. Caracteristicile undelor se schimbă de asemenea cu vârsta [3]. Există cinci unde cerebrale principale ce se disting prin frecvenţe. Aceste benzi de frecvenţe de la joase la înalte sunt următoarele: alfa (α), theta (θ), beta (β), delta (δ), şi gamma (γ). Undele alfa apar în jumătatea posterioară a capului şi sunt întâlnite de obicei la nivelul regiunii occipitale a creierului. Ele pot fi detectate în toate zonele lobilor posteriori ai creierului. Frecvenţa undelor alfa este cuprinsă între 8–13 Hz, şi de obicei apare

sub formă de semnal rotund sau sinusoidal [4]. Totuşi, în cazuri rare, se poate manifesta ca undă ascuţită. În asemenea cazuri, componenta negativă este ascuţită iar componenta pozitivă este rotundă, similară cu morfologia undei ritmului rolandic mu (μ) [5]. S-a crezut că undele alfa indică atât o conştiinţă relaxată, fără nicio atenţie, cât şi concentrarea. Undele alfa sunt ritmul cel mai proeminent în toată gama de activităţi ale creierului şi este posibil să acopere o arie mai mare dintre acestea decât s-a crezut anterior. Un vârf poate fi înregistrat în mod regulat in zona de frecvenţă a undelor beta chiar şi până la 20 Hz, cu caracteristicile unei stări de unde alfa mai degrabă decât ale undei beta. Cu toate acestea, foarte adesea un răspuns este înregistrat la 75 Hz, şi astfel apare într-o bandă de frecvenţe alfa. Cei mai mulţi subiecţi produc unele unde alfa ţinându-şi ochii închişi, şi de aceea s-a crezut că acestea nu sunt altceva decât un tipar de aşteptare sau scanare produs de regiunile optice din creier. Aceste unde sunt reduse sau eliminate prin deschiderea ochilor, prin receptarea de sunete neobişnuite, de anxietate, sau concentrare mentală sau atenţie. Albert Einstein putea rezolva probleme complexe de matematică rămânând în stare alfa, deşi undele beta şi theta erau de asemenea prezente. O undă alfa are o amplitudine mai mare în zonele occipitale şi are o amplitudine în mod normal mai mică de 50 μV. Originea şi semnificaţia fiziologică a unei unde alfa sunt încă necunoscute şi mai sunt multe cercetări de realizat pentru a înţelege cum este produs acest fenomen de celulele corticale.

O undă beta este activitatea electrică a creierului ce variază între 14–25 Hz (deşi în unele lucrări de specialitate nu este dată o limită superioară). O undă beta este ritmul de veghe obişnuit al creierului asociat cu gândirea activă, atenţia, concentrarea pe lumea exterioară, sau rezolvarea de probleme concrete şi este întâlnit la adulţii normali [6]. Un nivel înalt de undă beta se poate obţine când fiinţa umană este în stare de panică. Activitatea ritmică beta este întâlnită mai ales la nivelul regiunilor frontală şi centrală. Important de notat este faptul că un ritm beta central este legat de ritmul mu rolandic şi poate fi blocat de activitatea motorie sau stimularea tactilă. Amplitudinea ritmului beta este în mod normal sub 30 μV. Frecvenţele peste 25 Hz (în principal cele până în 60 Hz) corespund zonei gamma (uneori numită unda beta rapidă). Deşi amplitudinile acestor ritmuri sunt foarte joase, iar apariţia lor este rară, detectarea acestor ritmuri poate fi folosită pentru confirmarea anumitor boli ale creierului. Regiunile cu frecvenţe EEG înalte şi cele mai înalte niveluri ale circulaţiei sangvine cerebrale (ca şi absorbţia oxigenului şi a glucozei) sunt localizate în aria frontocentrală. Banda de undă gamma s-a dovedit a fi deasemenea un bun indicator al sincronizării de eveniment (ERS) a creierului şi

poate fi utilizată pentru a demonstra locusul pentru mişcarea degetului arătător drept şi stâng, degetului mare de la piciorul drept şi a unei largi arii bilaterale a mişcării limbii [7].



Figura 2.1 Principalii probleme clinice care pot fi investigate prin intermediul EEG

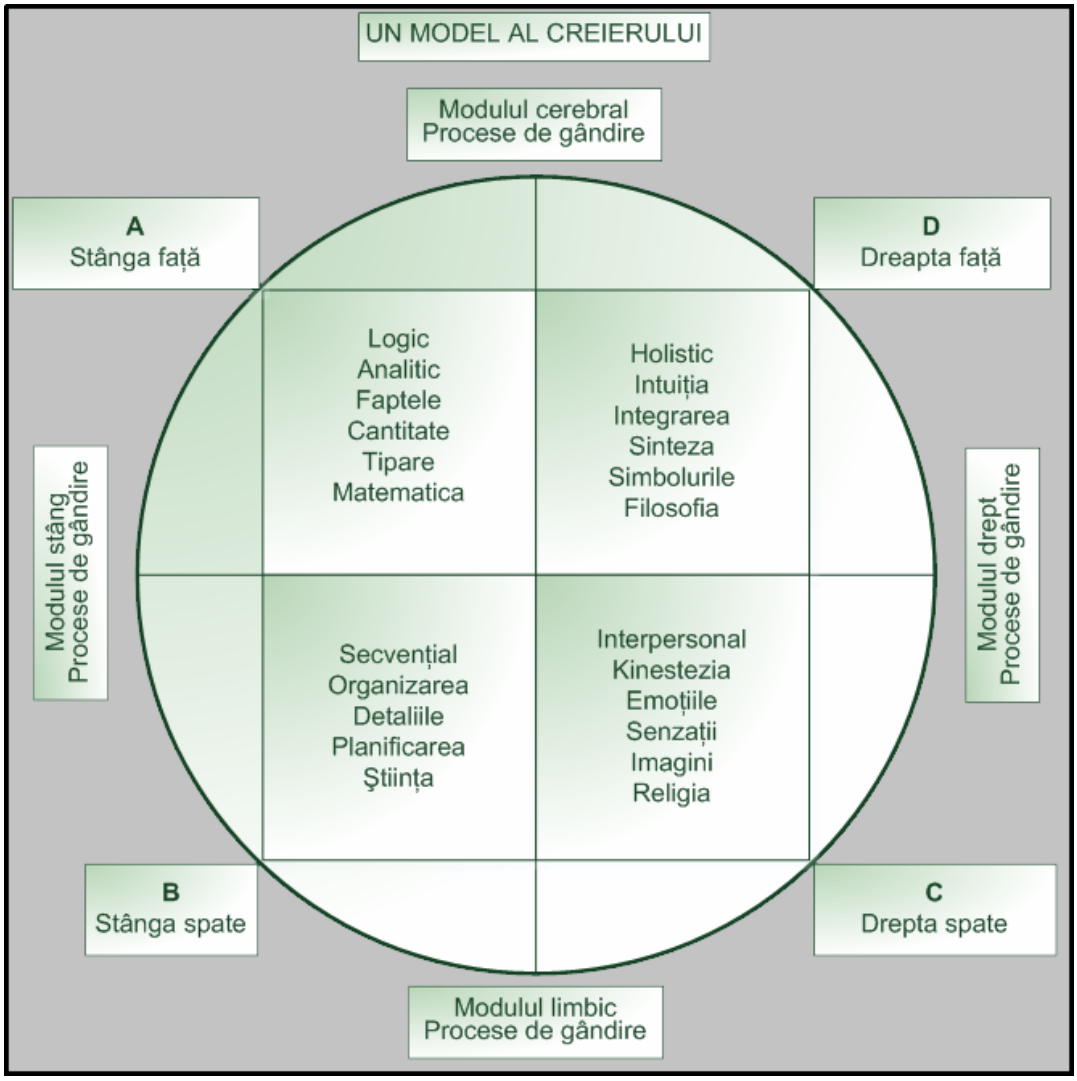


Figura 2.2 Un model al creierului

Figura 2.3 arată ritmurile normale tipice ale creierului cu nivelurile lor obişnuite de amplitudine. În general, semnalele EEG sunt proiecţii ale activităţilor neurale care sunt atenualte de leptomeninge, fluidul cerebrospinal, duramater, os, meninge, şi scalp [8]. Descărcările cartografice arată amplitudini de 0.5–1.5 mV şi până la câţiva milivolţi în vârfuri. Cu toate acestea, pe scalp, amplitudinile se situează în mod obişnuit între 10–100 Mv [9]. Există de asemenea alte ritmuri prezentate de cercetători precum cele din Figura 2.4. Sunt adesea greu de înţeles şi de detectat ritmurile creierului cu ajutorul EEG-urilor de scalp chiar şi pentru cei experimentaţi [10]. Aplicarea unor instrumente avansate de procesare a semnalelor ar trebui să ajute separarea şi analizarea formelor de undă dorite din EEG. Din această cauză, o definiţie a EEG de prim plan şi a celor de fundal este foarte subiectivă şi total dependentă de anomalii şi aplicaţii. În continuare este tratată dezvoltarea înregistrării şi măsurării semnalelor EEG [11-13].

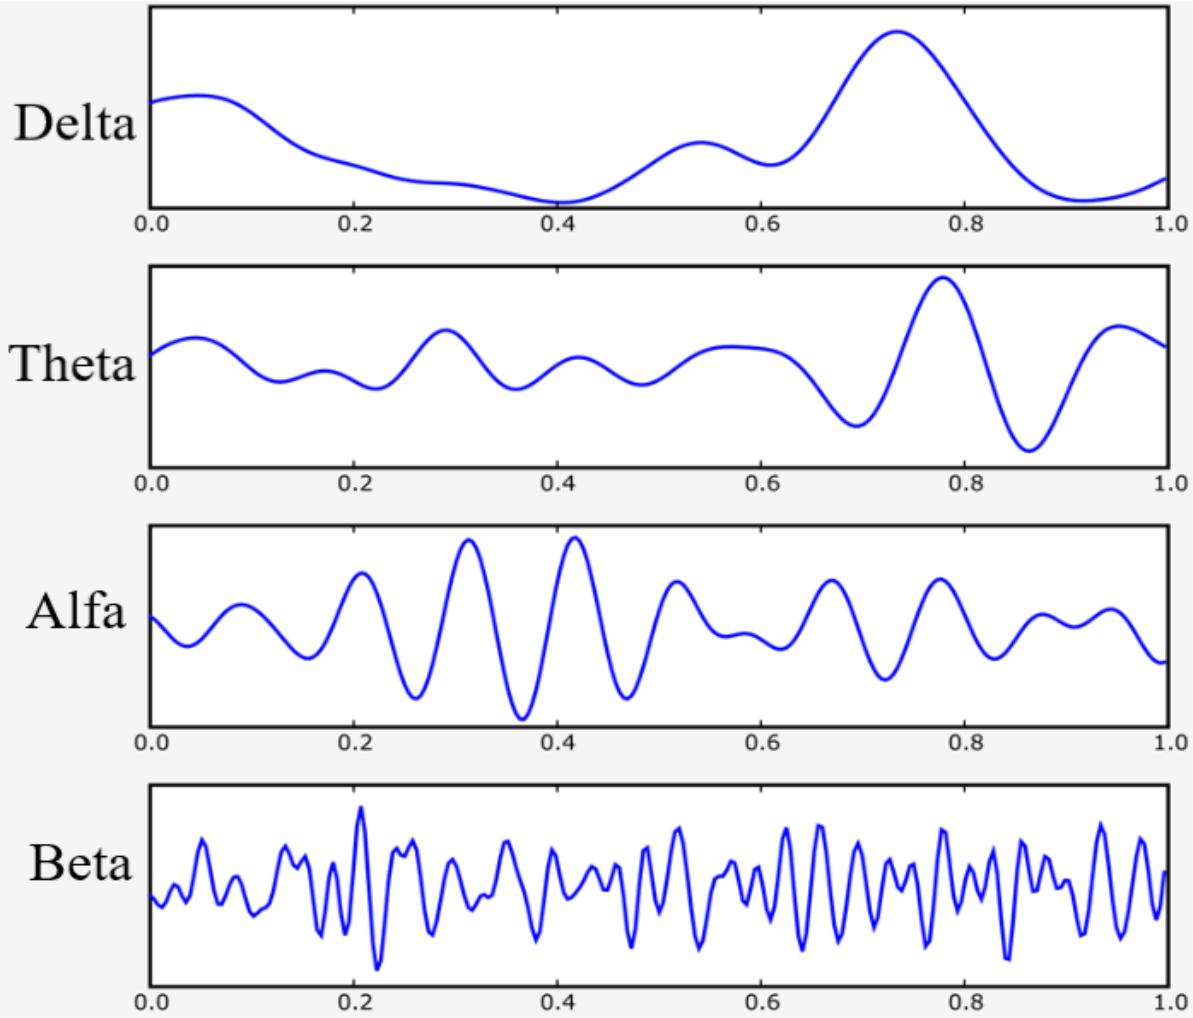


Figura 2.3 Ritmurile tipice ale creierului uman

2.2. Înregistrarea şi măsurarea EEG

Obţinerea semnalelor şi a imaginilor din corpul uman a devenit vitală pentru diagnosticarea timpurie a bolilor, determinarea caracteristicilor psihologice sau de personalitate inclusiv studii în domeniul BCI. Primele activităţi electrice neurale au fost înregistrate folosind galvanometre simple. Pentru a mări variaţiile foarte fine ale indicatorului a fost utilizată o oglindă pentru a reflecta lumina proiectată de galvanometru pe perete. Galvanometrul d'Arsonval a fost dotat cu o oglindă montată pe o bobină mobilă iar lumina concentrată pe oglindă a fost reflectată când un curent a străbătut bobina. Galvanometrul cu conductori, un instrument de măsură sensibil şi mai exact, a fost introdus de Einthoven, în 1903. Acesta a devenit un instrument standard timp de câteva zeci de ani şi a făcut posibile înregistrările fotografice [14].

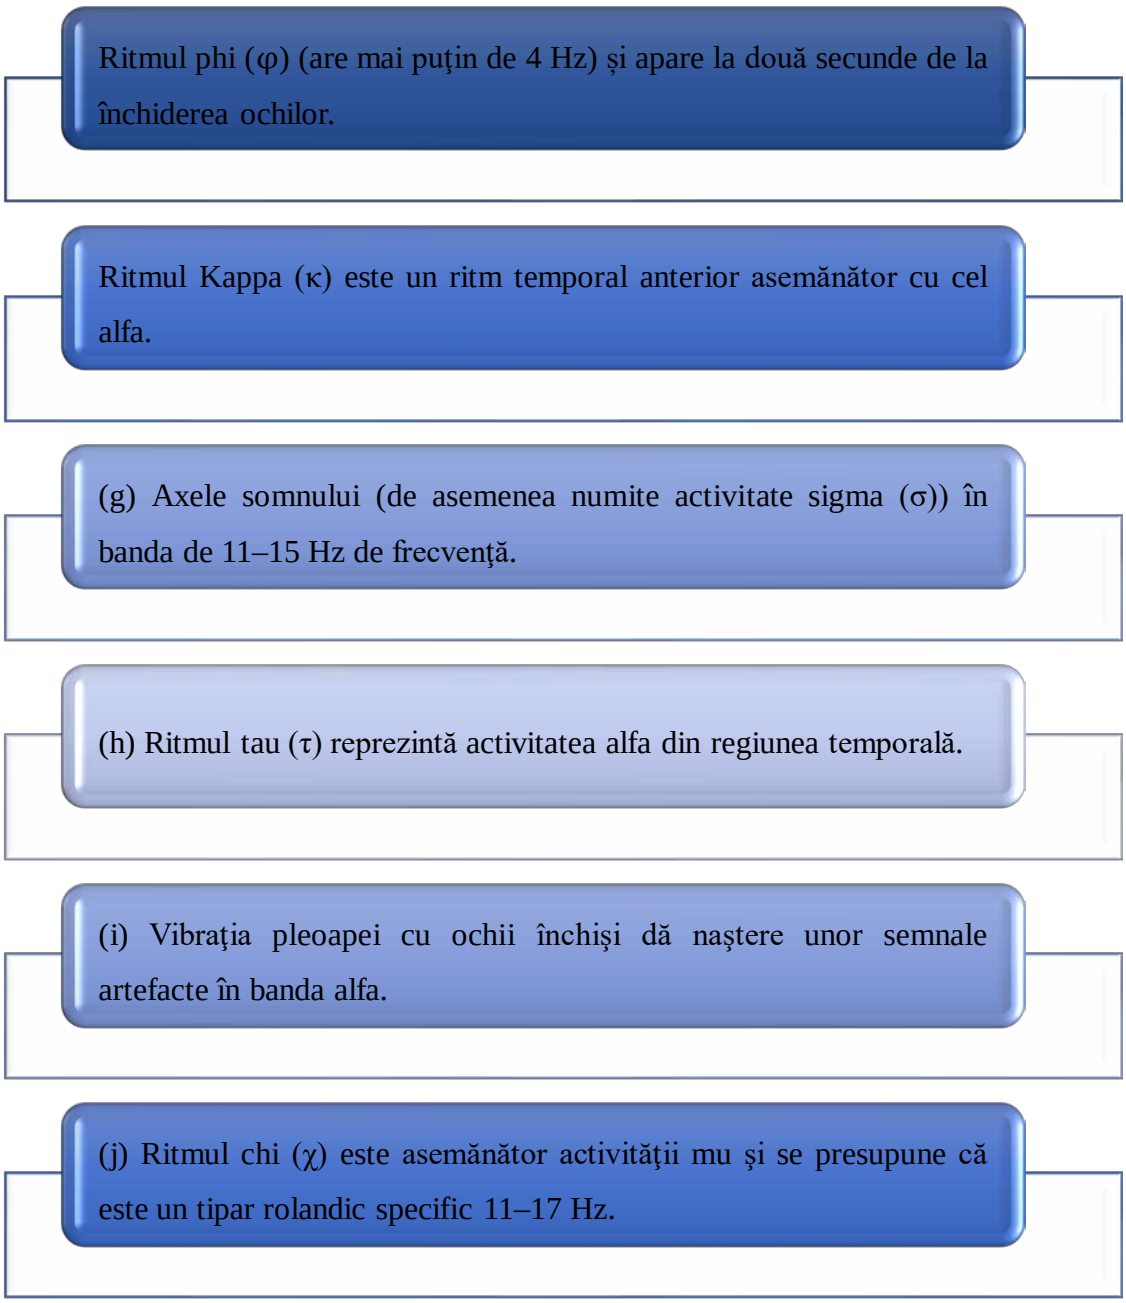


Figura 2.4 Alte ritmurile ale creierului uman

Înregistrările cu electrozi EEG şi funcţionarea corectă a acestora sunt cruciale pentru achiziţia de date de calitate înaltă. În sistemele de înregistrare EEG sunt folosite adesea tipuri diferite de electrozi, cum sunt cei din Figura 2.5. Pentru înregistrări pe canale multiple cu un număr mare de electrozi, sunt utilizaţi adesea electrozii capac. Electrozii de scalp utilizaţi cel mai frecvent constau din discuri de Ag–AgCl, cu mai puţin de 3 mm în diametru, cu conductori lungi flexibili care pot fi legaţi la un amplificator. Electrozii-ac sunt aceia care trebuie să fie

implantaţi sub craniu prin operaţii minim invazive. Impedanţa înaltă între cortex şi electrozi ca şi electrozii cu impedanţă înaltă poate duce la distorsiuni, ceea ce poate chiar masca semnalele EEG reale. Sistemele de înregistrare EEG comerciale sunt adesea echipate cu monitoare pentru impedanţă. Pentru a obţine o înregistrare satisfăcătoare impedanţa unui electrod trebuie să fie mai puţin de 5 kΩ şi să fie echilibrată la până în 1 kΩ unul faţă de altul. Pentru măsurători mai exacte impedanţele sunt verificate după fiecare testare. Datorită structurii stratificate şi convolute a creierului, totuşi, distribuţia potenţialelor la nivelul scalpului (sau cortexului) nu este uniformă. Aceasta poate afecta unele rezultate de localizare a sursei cu ajutorul semnalelor EEG [14].

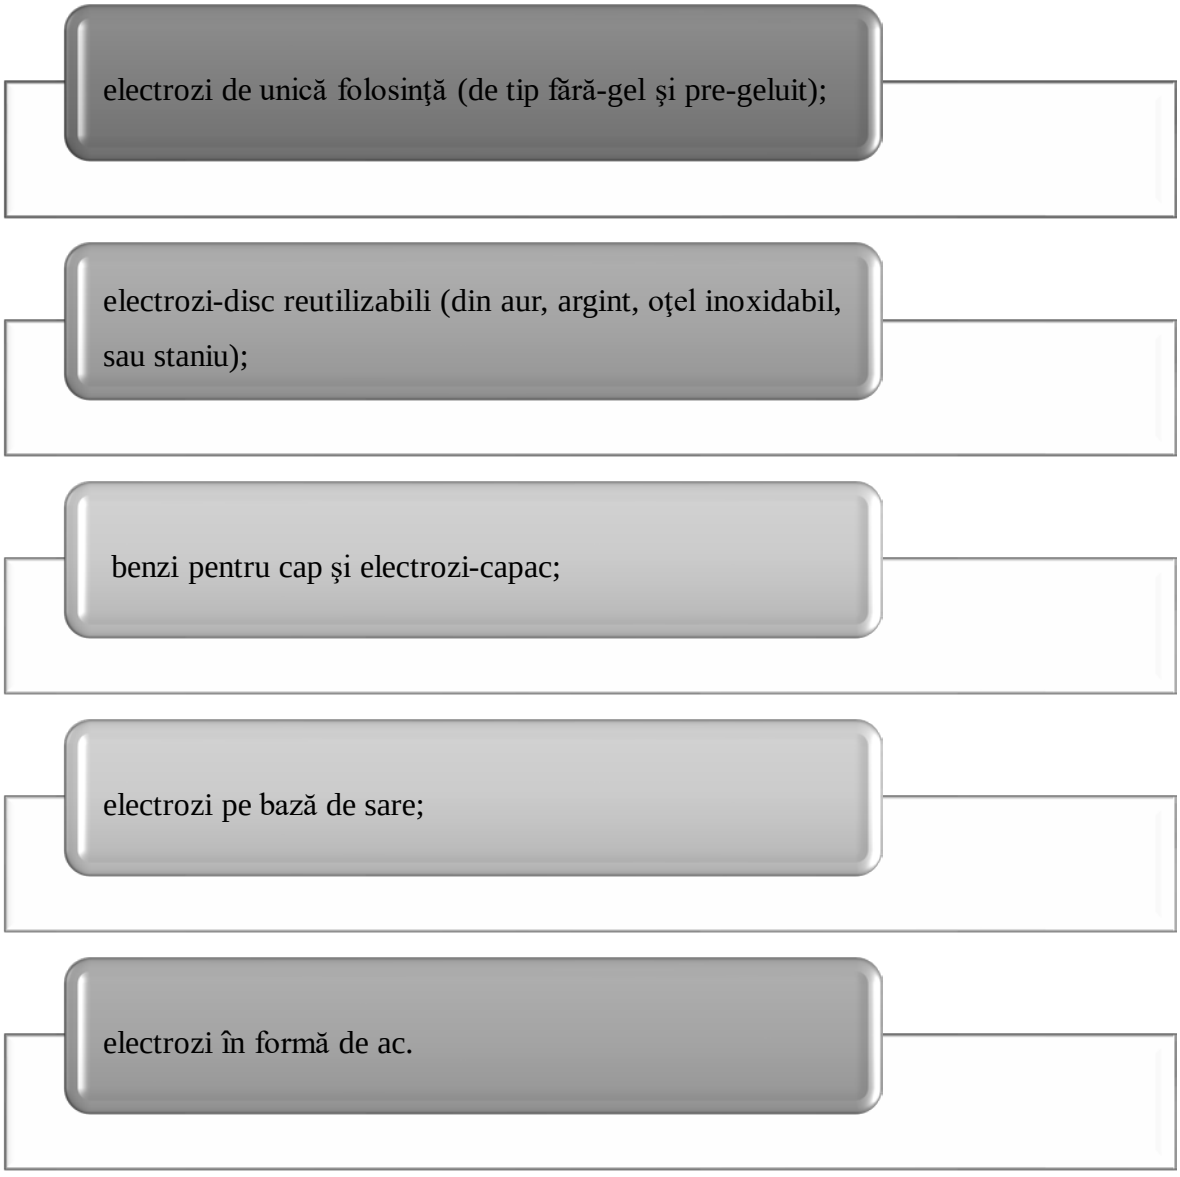


Figura 2.5 Tipurile de electrozi folosiți în cazul EEG

2.2.1. Poziţionarea convenţională a electrozilor EEG

Federaţia Internaţională a Societăţilor pentru Electroencefalografie şi Neurofiziologie Clinică a recomandat setarea convenţională a electrozilor (numită şi 10-20) pentru 21 de electrozi, aşa cum se arată în Figura 2.6 [17]. Adesea electrozii pentru lobii urechilor, numiţi A1 şi A2, conectaţi respectiv la lobul urechii drepte şi al celei stângi, sunt utilizaţi ca electrozi de referinţă. Sistemul 10-20 evită plasarea pe ambii globi oculari dar în acelaşi timp ia în considerare unele distanţe constante folosind repere anatomice constante de la care să fie făcute măsurătorile iar apoi foloseşte 10% sau 20% din acea distanţă ca interval de electrod. Electrozii impari sunt aşezaţi pe partea stângă, unii chiar pe dreapta. Pentru setarea unui număr mare de electrozi folosind sistemul convenţional de mai sus, ceilalţi electrozi sunt plasaţi între electrozii menţionaţi mai sus, la distanţe egale între ei.

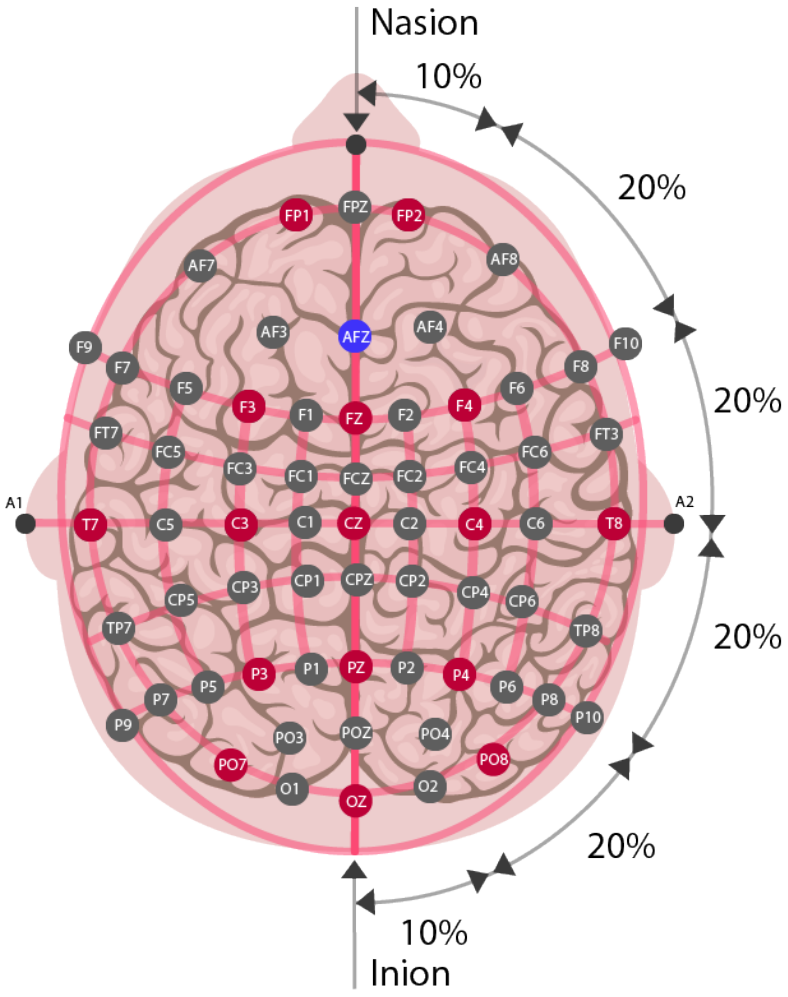


Figura 2.6 Poziţiile standard ale celor 19 electrozi de scalp şi ale celor 2 electrozi de referinţă pentru ureche, în conformitate cu sistemul tradiţional 10-20

De exemplu, C1 este plasat între C3 şi Cz. Uneori sunt utilizaţi electrozi suplimentari pentru măsurarea EOG, ECG, şi EMG de la muşchii pleoapelor şi cei din jurul ochilor. În unele aplicaţii, cum sunt analiza ERP şi interfaţa creier-computer, poate fi folosit un singur canal. In asemenea aplicaţii, totuşi, poziţia electrodului corespunzător trebuie să fie bine determinată. De exemplu, C3 şi C4 pot fi utilizaţi pentru a înregistra semnale ale mişcării degetului drept şi respectiv a celui stâng pentru înregistrarea semnalelor ERP, P300. Sunt utilizate două modalităţi diferite de înregistrare, respectiv una diferenţială şi una referenţială. În modalitatea diferenţială, cele două intrări ce apar la fiecare amplificator diferenţial provin de la doi electrozi. În modul referenţial, în schimb, sunt folosiţi unul sau doi electrozi de referinţă [7].

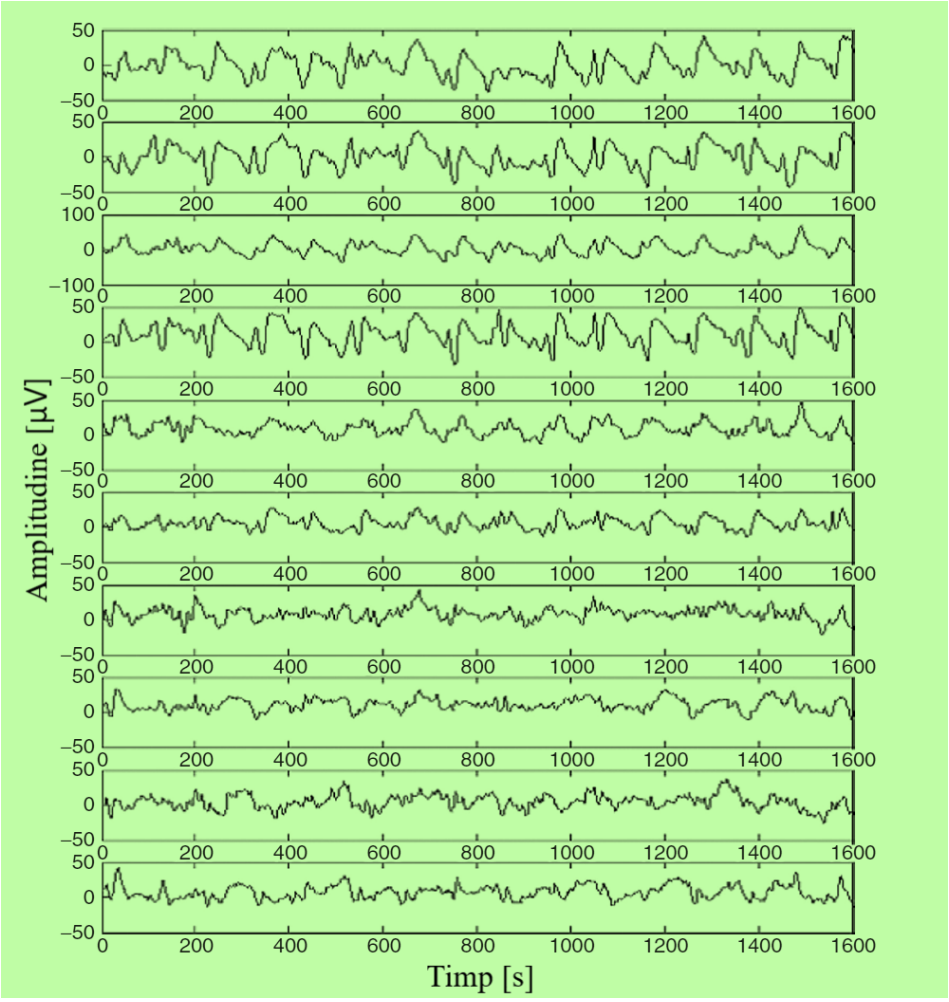


Figura 2.7 Set tipic de semnale EEG timp de aproximativ şapte secunde de activitate a creierului unui adult normal

Există şi tehnici de înregistrare fără referinţe, care folosesc de fapt o referinţă comună medie. Alegerea referinţei poate produce distorsiuni topografice dacă referinţa nu este relativ neutră. În instrumentarea modernă, totuşi, alegerea unei referinţe nu joacă un rol important în

realizarea măsurătorilor [16]. În asemenea sisteme ar putea fi utilizate alte referinţe, cum sunt FPz, electrozii de mână sau picior. Întreaga setare include: electrozii activi şi referinţele. În multe aplicaţii cum ar fi interfaţa creier-computer (BCI) şi studiul activităţii mentale, adesea sunt selectaţi şi utilizaţi un număr mic de electrozi din sistemul 10-20 din jurul regiunilor legate de mişcare. Figura 2.7 ilustrează un set tipic de semnale EEG pe timpul a aproximativ şapte secunde de activitate a creierului unui adult normal.

2.2.2. Condiţionarea semnalelor EEG

Semnalele EEG brute au amplitudini de ordinul μV şi conţin componente ale frecvenţei de până la 300 Hz. Pentru a reţine informaţii efective, semnalele trebuie să fie amplificate înainte de ADC şi filtrate, fie înainte fie după CAD, pentru a reduce zgomotul şi pentru a face semnalele potrivite pentru procesare şi vizualizare. Filtrele cu frecvenţă de eliminare de obicei de mai puţin de 0,5 Hz sunt utilizate pentru a elimina componentele de frecvenţă foarte joase, cum ar fi cele datorate respiraţiei. Pe de altă parte, zgomotul de frecvenţă înaltă este ameliorat utilizând filtre cu o frecvenţă de eliminare de aproximativ 50-70 Hz. Filtrele Notch cu frecvenţa de nul de 50 Hz sunt adesea necesare pentru a asigura rejecţia perfectă a generatorului electric puternic de 50 Hz. În acest caz eşantionarea frecvenţei poate fi până la de două ori mai joasă decât lăţimea de bandă utilizată în mod obişnuit de cele mai multe sisteme EEG.

Principalele artefacte, care apar în cazul semnalelor EEG pot fi împărţite în: artefacte ce au legătură cu pacientul (fiziologice) şi artefacte de sistem. Artefactele ce au legătură cu pacientul sau interne sunt legate de mişcările corpului, EMG, ECG, EOG, balistocardiogramă, şi transpiraţie. Artefactele de sistem sunt interferenţe de sursă de 50/60 Hz, fluctuaţii de impedanţă, defecte de cablu, zgomot electric de la componentele electronice şi impedanţe dezechilibrate ale electrozilor. Adesea în stadiul de preprocesare aceste artefacte sunt mult ameliorate şi informaţia informativă este recuperată. Figura 2.8 prezintă un set de semnale EEG normale afectate de artefacte de clipire.

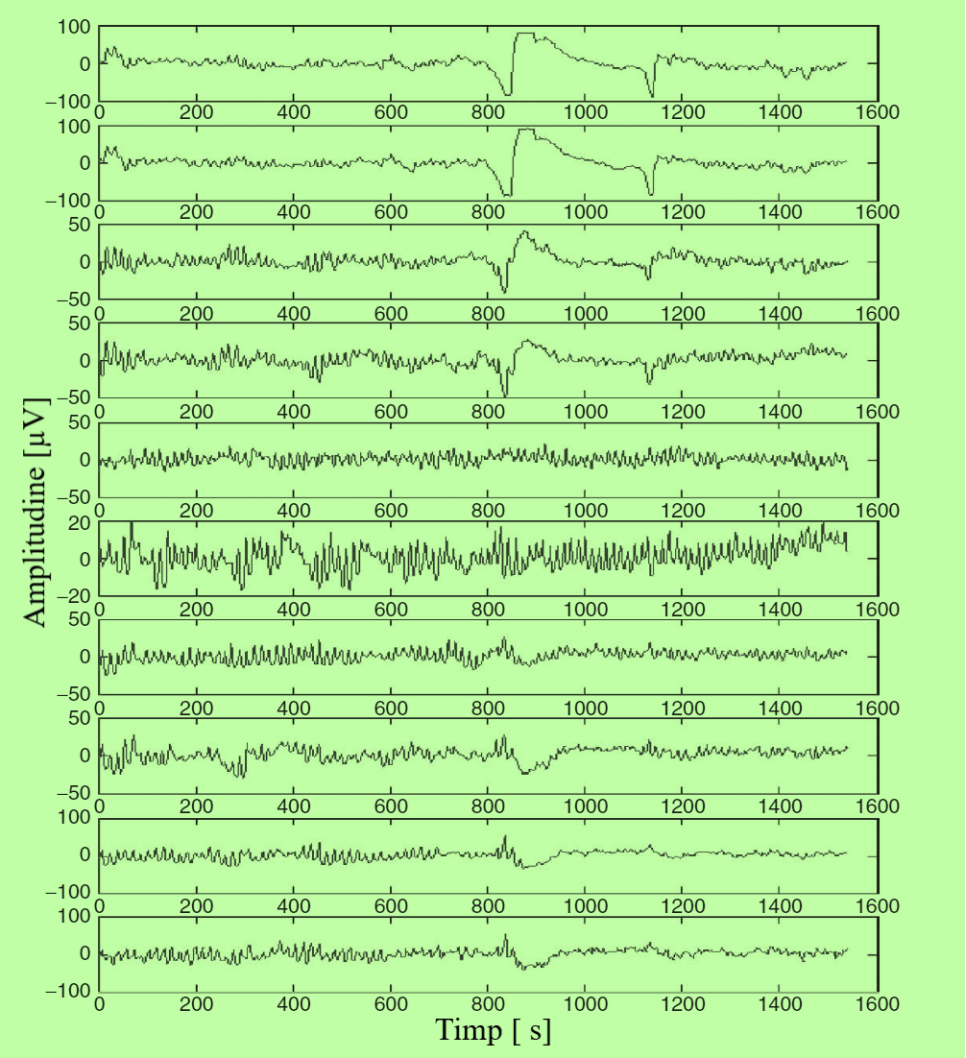


Figura 2.8 Set de semnale EEG normale afectate de artifactul clipitului

2.3. Noţiuni fundamentale ale procesării semnalelor EEG

Semnalele EEG sunt semnăturile activităţilor neurale. Ele sunt captate de aparate EEG cu electrozi multipli fie din interiorul creierului, de pe cortexul de sub craniu, sau din anumite locaţii de pe scalp, şi pot fi înregistrate sub diverse forme. Semnalele sunt, în mod normal, prezentate în raport de timp, dar multe aparate EEG noi sunt capabile să aplice metode simple de procesare a semnalelor cum ar fi reprezentarea Fourier pentru realizarea de analize a frecvenţelor de aceea sunt echipate şi cu unele instrumente de imagistică pentru a vizualiza topografiile EEG (hărţi spaţiale ale activităţii creierului). Până în prezent au fost dezvoltaţi mai mulţi algoritmi pentru procesarea semnalelor EEG. Operaţiile includ, dar nu sunt limitate la acestea, metodele din Figura 2.9.

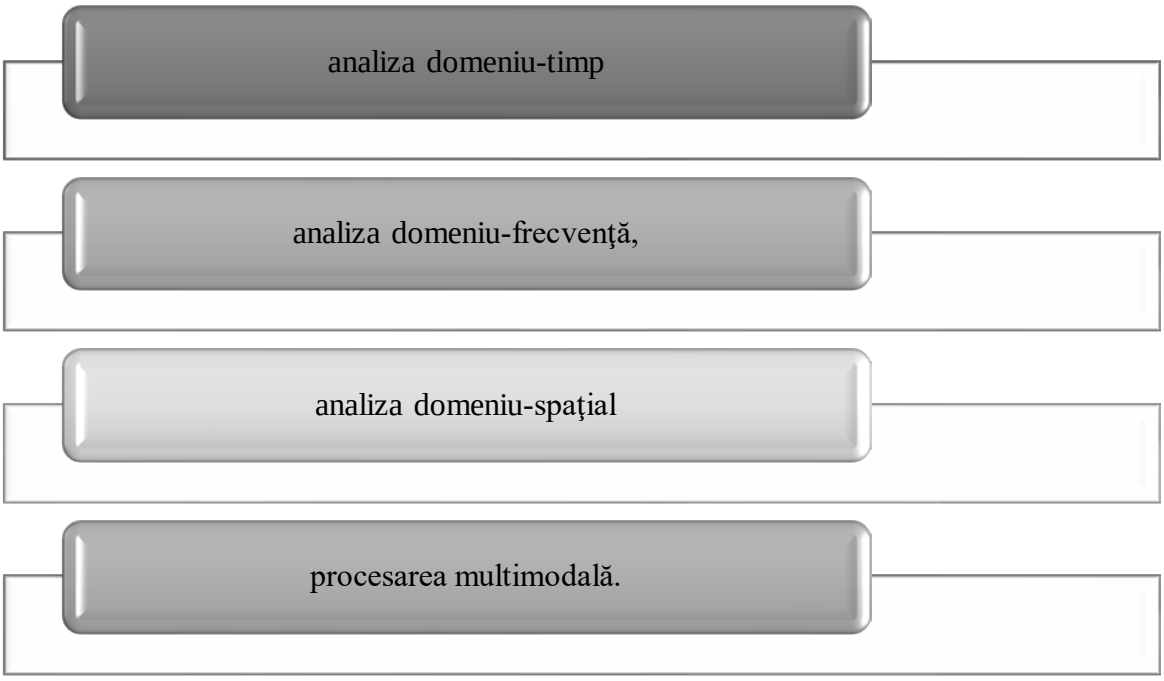


Figura 2.9 Exemple de operații utilizate în procesarea semnalelor EEG

De asemenea, au fost dezvoltaţi câţiva algoritmi pentru vizualizarea activităţii cerebrale din imagini reconstruite doar de către EEG. Separarea surselor dorite din EEG cu senzori multipli reprezintă o altă arie de cercetare. Aceasta poate conduce mai târziu la detectarea anomaliilor creierului cum sunt epilepsia şi sursele corespunzătoare unor activităţi fizice şi mentale variate Modelarea activităţilor neurale este probabil mai dificilă decât modelarea funcţiei oricărui alt organ. Totuşi, au fost propuse unele modele simple de generare a semnalelor. Unele dintre aceste modele au fost extinse pentru a include generarea semnalelor EEG anormale. Localizarea surselor semnalelor creierului este un alt domeniu foarte important de cercetare. Pentru a furniza algoritmi de încredere privind localizarea surselor din interiorul creierului sunt necesare suficiente cunoştinţe despre propagarea undelor electromagnetice precum şi despre cum poate fi exploatată informaţia din semnalele măsurate, pentru separarea şi localizarea surselor din creier. Sursele pot fi considerate dipoli magnetici pentru care trebuie să fie rezolvată o problemă inversă bine cunoscută, sau pot fi considerate ca surse de curent distribuit. Monitorizarea pacienţilor şi monitorizarea somnului cere procesarea în timp real a unor secvenţe EEG lungi (de până la câteva zile). EEG furnizează informaţii importante şi unice despre creierul aflat în stare de somn; cele mai multe activităţi ale creierului din timpul somnului pot fi captate folosind algoritmi, cum ar fi abordarea procedeului de potrivire (MP) [17]–[19]. De asemenea, mulţi cercetători au fost atraşi de monitorizarea, detectarea, şi predicţia epilepsiei. Analiza dinamică a unei serii timp alături de aplicarea unei separări oarbe

a surselor de semnal a permis prezicerea epilepsiilor focale din EEG de scalp. Pe de altă parte, aplicarea analizei domeniu-timp-frecvenţă pentru detectarea atacului la nou-născuţi a pavat calea pentru cercetările din această arie. În secţiunile următoare sunt explicate cele mai multe dintre instrumentele şi algoritmii pentru obiectivele de mai sus şi sunt discutate fundamentele matematice ale acestora.

2.4. Modelarea semnalului EEG

Cel mai probabil, cel dintâi model fizic este bazat pe modelul axonului al lui Hodgkin şi Huxzley, câştigător al Premiului Nobel, publicat în 1952 [20]–[22]. Axonul neural poate fi stimulat, iar canalele de sodiu (Na^+) şi potasiu (K^+) de activitate produse în vecinătatea membranei celulare pot duce la excitarea electrică a axonului neural. Excitaţia apare din efectul potenţialului de membrană asupra mişcării ionilor şi din interacţiunile potenţialului de membrană cu deschiderea şi închiderea canalelor membranare de voltaj activate. Potenţialul de membrană creşte când membrana este polarizată cu o sarcină negativă netă pe suprafaţa interioară şi cu o sarcină pozitivă netă egală dar opusă pe suprafaţa exterioară. Acest potenţial poate fi legat pur şi simplu de volumul de sarcini electrice Q, folosind relaţia 2.1.

$$E = Q/C_m \tag{2.1}$$

C_m este măsura capacităţii membranei în unităţi de F/cm2, iar E este exprimat în V. În practică, pentru a modela acţiunea de potenţial (PA) numărul de sarcini Q^+ de pe surpafaţa interioară şi Q^- de pe suprafaţa exterioară a membranei celulei trebuie să fie corelat matematic cu curentul de stimulare I_{stim} ce trece în interiorul celulei prin electrozii de stimulare. Potenţialul electric (adesea numit forţă electrică) E este calculat apoi folosind ecuaţia (2.1). Modelul Hodgkin şi Huxley este ilustrat în Figura 2.10, unde I_{memb} este rezultatul sarcinilor pozitive ce ies din celulă. Acest curent constă din trei curenţi: Na^+, K^+ şi curenţii de scurgere. Curentul de scurgere este datorat faptului că ionii de Na^+ şi K^+ interni şi externi nu sunt exact egali. Hodgkin şi Huxley au estimat funcţiile de activare şi de inactivare ale curenţilor de Na^+ şi K^+ şi au derivat un model matematic pentru a descrie un PA similar cu aceea a unui calamar uriaş.

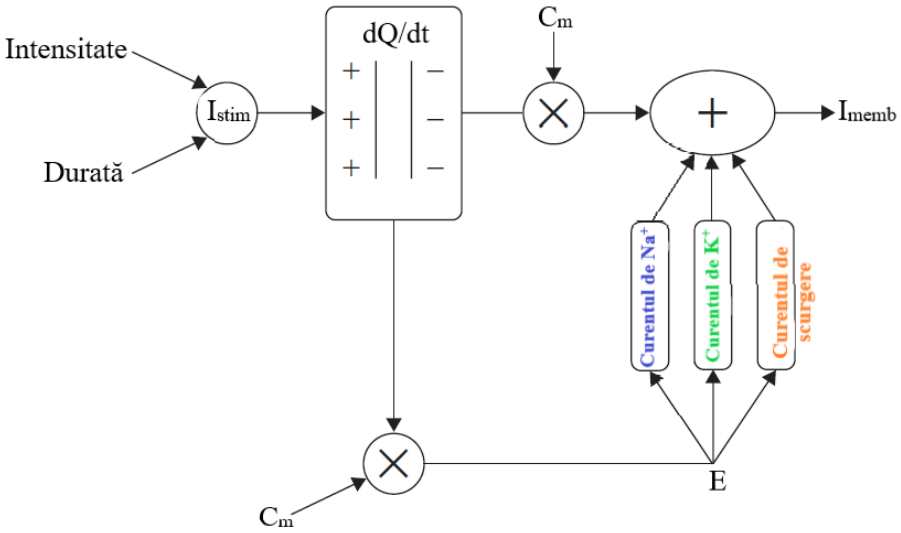


Figura 2.10 Modelul de excitare Hodgkin–Huxley

Acest model este un model neuronal ce utilizează canalele cu porţi voltaice. Versiunile spaţiale ale modelului Hodgkin–Huxley pot fi descrise folosind patru ecuaţii diferenţiale [23]. Curentul de membrană total este suma curentului de capacitate şi a curentului ionic (ecuația 2.2).

$$I_{memb} = C_m \frac{dE}{dt} + I_i \tag{2.2}$$

unde I_i este curentul ionic şi poate fi considerat ca suma celor trei componente individuale: curenţii de Na^+, K^+ şi curenţii de scurgere (ecuația 2.3).

$$I_i = I_{Na^+} + I_{K^+} + I_{scurgere} \tag{2.3}$$

I_{Na^+} poate fi corelat cu conductanţa maximală g_{Na^+}, variabila de activare a_{Na^+}, variabila de inactivare h_{Na^+} şi o forţă conductoare $E - E_{Na^+}$ prin ecuația 2.4. În mod asemănător, I_{K^+} poate fi corelat cu conductanţa maximală g_{K^+}, variabila de activare a_{K^+} şi o forţă conductoare $E - E_{K^+}$ ca în ecuația 2.5. $I_{scurgere}$ este corelat cu conductanţa maximală g_l şi o forţă conductoare $E - E_l$ (ecuația 2.6). Modificările variabilelor a_{Na^+}, a_{K^+} şi h_{Na^+} variază de la 0 la 1 conform ecuațiilor 2.7-2.9 [23].

$$I_{Na^+} = \bar{g}_{Na^+}\mathrm{a}_{\mathrm{Na}^+}{}^3\mathrm{h}_{\mathrm{Na}^+}(\mathrm{E} - \mathrm{E}_{\mathrm{Na}^+}) \quad (2.4)$$

$$I_{Na^+} = \bar{g}_{K^+}\mathrm{a}_{\mathrm{K}^+}(\mathrm{E} - \mathrm{E}_{\mathrm{K}^+}) \quad (2.5)$$

$$I_l = \bar{g}_l(\mathrm{E} - \mathrm{E}_{\mathrm{l}}) \quad (2.6)$$

$$\frac{d\mathrm{a}_{\mathrm{Na}^+}}{dt} = \lambda_t[\alpha_{Na}(E)(1-\alpha_{Na}) - \beta_{Na}(E)\alpha_{Na}] \quad (2.7)$$

$$\frac{d\mathrm{a}_{K^+}}{dt} = \lambda_t[\alpha_K(E)(1-\alpha_k) - \beta_K(E)\alpha_K] \quad (2.8)$$

$$\frac{d\mathrm{h}_{\mathrm{Na}^+}}{dt} = \lambda_t[\alpha_h(E)(1-h_{Na}) - \beta_h(E)h_{Na}] \quad (2.9)$$

unde α(E) şi β(E) sunt funcţiile ratelor de înaintare şi de înapoiere, iar λ_t este un factor dependent de temperatură. Parametrii de înaintare și de înapoiere depind de voltaj și sunt estimaţi empiric de către Hodgkin și Huxley (ecuațiile 2.10-2.15).

$$\alpha_{Na}(E) = \frac{3{,}5 + 0{,}1E}{1 - e^{-(3{,}5+0{,}1E)}} \quad (2.10)$$

$$\beta_{Na}(E) = 4e^{-(E+60)/18} \quad (2.11)$$

$$\alpha_h(E) = 0{,}007e^{-(E+60)/20} \quad (2.12)$$

$$\beta_h(E) = \frac{1}{1 + e^{-(3+0{,}1E)}} \quad (2.13)$$

$$\alpha_k(E) = \frac{0{,}5 + 0{,}01E}{1 - e^{-(5+0{,}1E)}} \quad (2.14)$$

$$\beta_K(E) = 0{,}125e^{-(E+60)/80} \quad (2.15)$$

Asemănător curentului de sodiu din modelul Hodgkin–Huxley, curentul de calciu este un curent cu sens către interior. Întrucât curentul de activare a calciului este un proces rapid în comparaţie cu curentul de potasiu, este modelat ca o funcţie instantanee. Aceasta înseamnă că este calculată funcţia stării constante $\alpha_{Ca}(E)$ pentru fiecare voltaj E. Curentul de calciu nu încorporează niciun proces de inactivare [23]. O simulare a modelului Morris–Lecar este prezentată în Figura 2.11. Canalele de potasiu dependente de calciu sunt activate de calciul intracelular; cu cât este mai mare concentraţia de calciu, cu atât este mai mare activarea canalului. Pentru ca modelul Morris–Lecar să prezinte un comportament pulsativ, trebuie să fie modificaţi cei doi parametri ai constantei timpului maximal şi al curentului de intrare. Figura 2.12 prezintă comportamentul pulsativ al modelului Morris–Lecar. Caracteristicile de bază ale unui astfel de neuron sunt: durata activităţii de vârf, frecvenţa potenţialelor de acţiune în timpul unei pulsații şi durata perioadei de repaus. Odată ce un neuron declanşează un PA este produs un curent sinaptic. Acest curent stimulează neuronul conectat de primul neuron şi poate fi modelat printr-o funcţie alfa multiplicată de o conductanţă maximală şi o forţă conductoare ca în ecuația 2.16, unde t este latenţa sau timpul de declanşare a curentului sinaptic, u este timpul necesar atingerii amplitudinii de vârf, E_{syn} este potenţialul de retur sinaptic, iar $\bar{g}_{syn}$ este conductanţa sinaptică maximală. Parametrul u modifică durata curentului, în timp ce $\bar{g}_{syn}$ modifică puterea curentului.

$$I_{syn} = \bar{g}_{syn} g_{syn}(t)\left[E(t) - E_{syn}\right] \quad (2.16)$$

$$g_{syn}(t) = te^{\left(-\frac{t}{u}\right)} \quad (2.17)$$

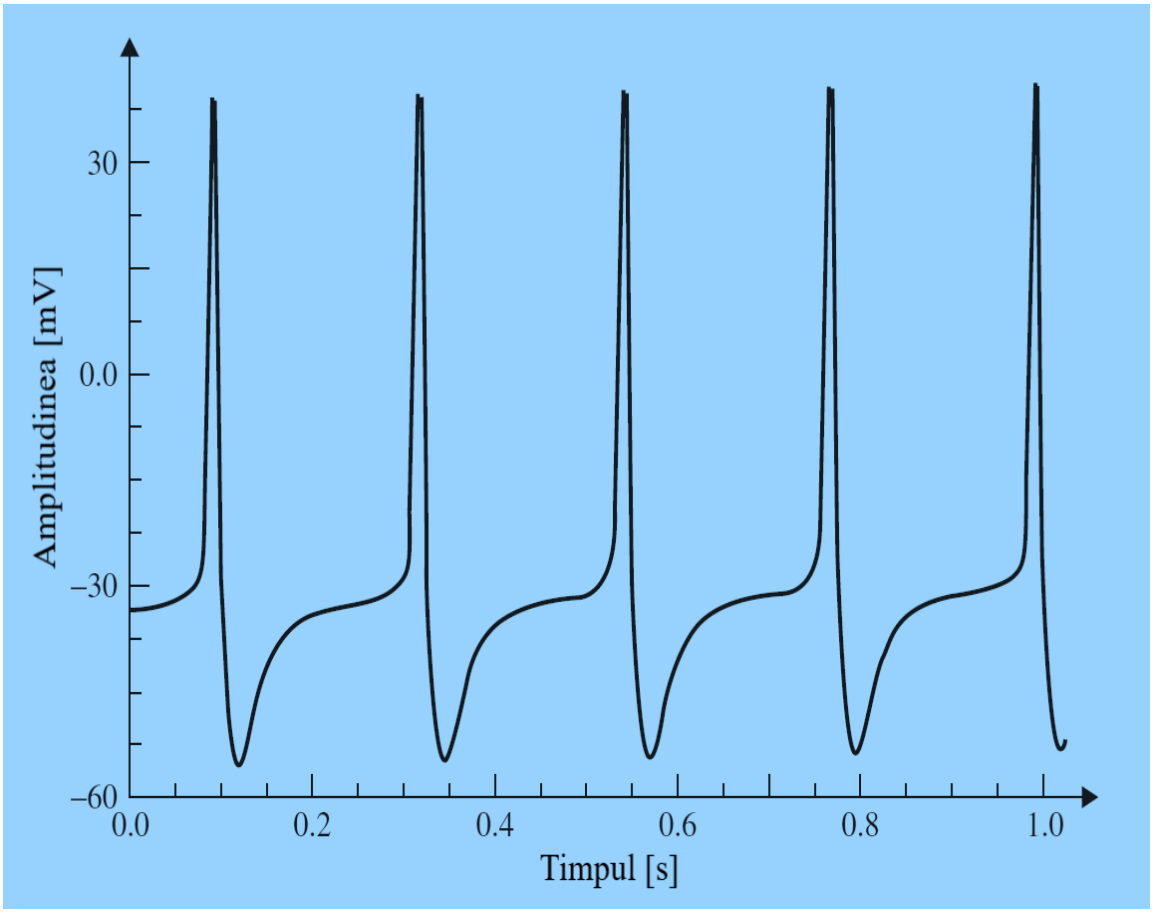


Figura 2.11 Simularea unui PA în modelul Morris–Lecar

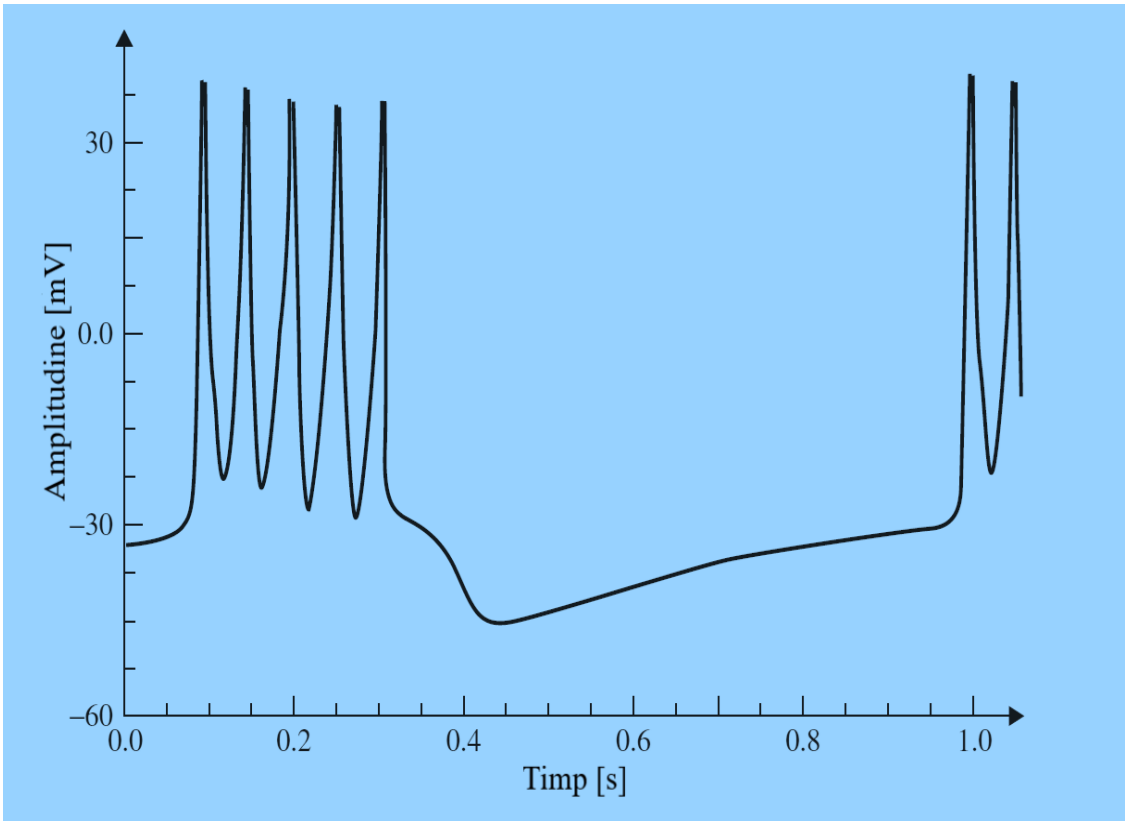


Figura 2.12 O ilustrare a comportamentului de puls ce poate fi generat de modelul Morris–Lecar

Întrucât natura surselor EEG nu poate fi determinată direct din semnalele electrozilor, mulţi cercetători au încercat să modeleze aceste procese pe baza informaţiilor extrase folosing tehnicile de procesare a semnalelor. Metoda predicţiei lineare, descrisă în secţiunile următoare ale acestui capitol este frecvent utilizată pentru a extrage o descriere parametrică.

2.4.1. Modelarea liniară a semnalelor EEG

2.4.1.1. Metoda predicţiei

Obiectivul principal al utilizării metodelor de predicţie este găsirea parametrilor de model ce descriu cel mai bine sistemul de generare a semnalelor. Asemenea modele în general necesită o intrare de tip zgomot. În modelarea autoregresivă (AR) a semnalelor fiecare probă a unei măsurări EEG de canal unic este definită ca fiind corelată linear cu privrire la un număr din alte probe ale sale anterioare (ecuația 2.18).

$$y(n) = -\sum_{k=1}^{p} a_k y(n-k) + x(n) \tag{2.18}$$

Unde k = 1, 2,..,p, sunt parametrii lineari, n arată proba de timp discret normalizată la unitate, iar x(n) este intrarea zgomotului. În modelul predictiv liniar al unei medii mobile autoregresive (ARMA) fiecare probă este obţinută pe baza unui număr de valori de probe de intrare şi ieşire anterioare, adică avem ecuația 2.19.

$$y(n) = -\sum_{k=1}^{p} a_k y(n-k) + \sum_{k=0}^{q} b_k x(n-k) \tag{2.19}$$

Unde k = 1, 2,..,q, sunt paramentri lineari adiţionali. Parametrii p şi q sunt ordinele modelului. Criteriul Akaike poate fi utilizat pentru a determina ordinul modelului potrivit al semnalului de măsurare prin minimizarea următoarei ecuaţii [12] cu privire la ordinul modelului:

$$AIC(i,j) = N ln\left(\sigma_{ij}^2\right) + 2(i+j) \tag{2.20}$$

Unde i şi j reprezintă ordinele modelului AR şi, respectiv, MA (media mobilă), N este numărul de probe de semnal, iar σ_{ij}^2 este puterea zgomotului din modelul ARMA. Într-o abordare AR multivariată (MVAR) este luată în considerare o schemă cu canale multiple. Ca urmare, fiecare probă de semnal este definită atât faţă de probele sale anterioare cât şi faţă de probele anterioare ale celorlalte canale, adică, pentru canalul i avem ecuația 2.21, unde m reprezintă numărul de canale şi $x_i(n)$ reprezintă intrarea zgomotului în canalul i. În mod similar, parametrii de model pot fi calculaţi iterativ pentru a minimiza eroarea dintre valorile reale şi cele prezise [24].

$$y_i(n) = -\sum_{k=1}^{p} a_{ik} y_i(n-k) - \sum_{\substack{j=1 \\ j \neq i}}^{m} \sum_{k=1}^{p} a_{jk} y_j(n-k) + x_i(n) \tag{2.21}$$

Pentru a găsi eficient coeficienţii de model, au fost dezvoltaţi diverşi algoritmi. Prin metoda estimării celei mai probabile maxime (MLE) [25] funcţia probabilităţii este maximizată peste parametrii de sistem formulaţi din semnalele de intrare presupuse reale, distribuite Gausian, şi suficient de lungi, de aproximativ 10 – 20 de secunde (considerând o frecvenţă a probei de f_s = 250 probe/s cum este des utilizat în înregistrările EEG). Utilizând metoda Akaike, gradientul erorii pătrate este minimizat folosint abordarea Newton-Raphson aplicată la ecuaţiile rezultantei nonlineare [24][26]. Aceasta este considerată ca o aproximare a abordării MLE. În metoda Durbin [27], ecuaţiile Yule–Walker, ce corelează coeficienţii modelului la autocorelarea semnalelor, sunt rezolvate iterativ. Abordarea şi rezultatele sunt echivalente celor ce folosesc o schemă bazată pe cel mai mic pătrat [28]. Coeficienţii MVAR sunt adesea calculaţi folosind algoritmul Levinson–Wiggins–Robinson (LWR). Figura 2.13 ilustrează sistemul simplificat [29].

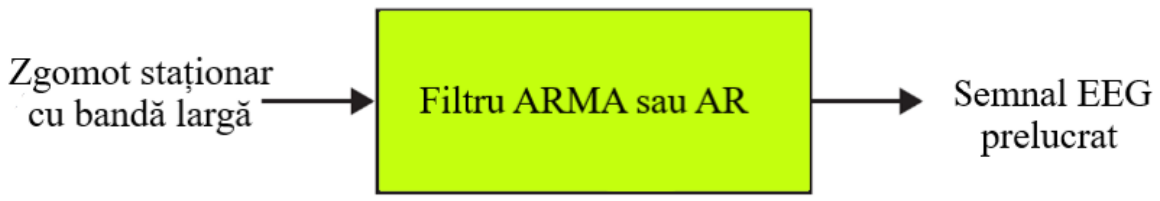


Figura 2.13 Un model linear pentru generarea semnalelor EEG

2.4.1.2. Metoda lui Prony

Metoda Prony a fost utilizată anterior pentru a modela potenţiale de ecou (EPs). Pe baza acestui model, un EP, care este obţinut prin aplicarea unei stimulări scurte audio sau vizuale asupra creierului, poate fi considerat ca impulsul infinit linear (IIR) ca răspuns al unui sistem [30][31]. Încercarea originală în acest domeniu a fost aceea de a găsi un model sinusoidal amortizat exponenţial care să fie potrivit datelor [32]. Această metodă a fost mai târziu modificată pentru semnalele sinusoidale ale modelului. Metoda lui Prony este utilizată pentru a calcula parametrii de predicţie lineară. Unghiurile polilor în planul z al filtrelor LP construite sunt apoi corelaţi cu frecvenţele sinusoidelor amortizate ale termenilor exponenţiali folosiţi pentru modelarea datelor. În consecinţă, atât amplitudinea exponenţialelor cât şi faza iniţială pot fi obţinute urmând metodele folosite pentru modelul AR după cum urmează. Pe baza metodei originale se poate considera că ieșirea unui sistem AR cu excitaţie zero poate fi corelat cu IR sau ca în ecuația 2.22, unde y(n) reprezintă probele de date exponenţiale, p este ordinul de predicţie, Ts este perioada probei (perioada de eşantionare) normalizată la 1, Ak este amplitudinea exponenţialei, a_k este factorul de amortizare. Factorii de amortizare sunt obținuți pe baza ecuației 2.23, iar frecvențele de rezonanță se calculează pe baza ecuației 2.23. Re şi Im reprezintă părţile reale şi imaginare ale unei cantităţi complexe.

$$y(n) = \sum_{k=1}^{p} a_k y(n-k) = \sum_{j=1}^{p} w_j \sum_{k=1}^{p} a_k r_j^{n-k-1} \tag{2.22}$$

$$a_k = \ln|r_k| \tag{2.23}$$

$$f_k = \frac{1}{2\pi} tan^{-1}\left[\frac{Im(r_k)}{Re(r_k)}\right] \tag{2.24}$$

În cazurile în care datele sunt contaminate de zgomot alb performanţa metodei lui Prony este rezonabilă. Totuşi, pentru zgomotul, care nu este alb, informaţia sa nu este uşor de separat de date şi de aceea metoda poate să nu aibă suficient succes [33][34].

2.4.2. Modelarea nonliniară a semnalelor EEG

O abordare similară cu modelarea AR sau MVAR în care ieșirile sunt corelate nonlinear cu probele anterioare, poate fi urmărită pe baza metodelor dezvoltate pentru prevederea creşterilor financiare în studiile economice. Prin metoda heterodispersabilităţii condiţionale autoregresive generalizate (GARCH) fiecare probă se corelează cu probele sale anterioare printr-o funcţie nonlineară (sau sumă de funcţii non lineare). Acest model a fost iniţial introdus pentru volatilitatea variabilă în timp (premiată cu Premiul Nobel în Ştiinţe Economice în 2003). Nonlinearităţile în timp sunt arătate cu ajutorul testelor McLeod-Li şi BDS. Totuşi, ambele teste au o abilitate slabă de a revela tipul real de dependenţa nonlineară [35]–[37]. În general, nu este posibil de distins dacă nonlinearitatea este de natură deterministică sau stochastică şi nici nu se poate face o distincţie între dependenţele multiplicative şi cele aditive. Tipul de nonlinearitate stochastică poate fi determinat pe baza testului Hseih. Atât dependenţele aditive cât şi cele multiplicative pot fi discriminate prin folisirea acestui test. Totuşi, testul în sine nu este utilizat pentru a obţine parametrii de model [38].

Considerând că intrarea într-un sistem nonlinear este u(n), iar semnalul generat ca ieșire al unui asemenea sistem este x(n), o clasă limitată de modele nonlineare potrivite pentru analiza unui asemenea proces este dată de ecuația 2.25.

$$x(n) = g(u(n-1), u(n-2), \dots) + u_n h(u(n-1), u(n-2), \dots) \quad \textbf{(2.25)}$$

Dependenţa multiplicativă înseamnă nonlinearitate în varianţă, care necesită ca funcţia h sa fie nonlineară; dependenţa aditivă, pe de altă parte, înseamnă nonlinearitatea în mediană, ceea ce este valabil dacă funcţia g este nonlineară. Media statistică coniţională şi varianţa sunt respectiv definite prin ecuația 2.26 și 2.27.

$$E[x(n)|_{\chi_{n-1}}] = g(u(n-1), u(n-2), \dots) \quad \textbf{(2.26)}$$

$$Var[x(n)|_{\chi_{n-1}}] = h^2(u(n-1), u(n-2), \dots) \quad \textbf{(2.27)}$$

Unde χ_{n-1} conţine toată informaţia până la momentul n-1. Dacă e(n) reprezintă semnalul rezidual (eroarea), folosind sistemul de predicţie de mai sus, atunci avem ecuația 2.28.

$$Var\left[e(n)|_{\chi_{n-1}}\right] = \sigma^2(n) = \alpha_0 + \sum_{j=1}^{q} \alpha_j e^2(n-j) + \sum_{j=1}^{p} \beta_j \sigma^2(n-1) \quad \textbf{(2.28)}$$

Unde α_j şi β_j sunt coeficienţii de model nonlinear. Al doilea termen din prima sumă corespunde unui termen de zgomot dinamic de medie mobilă (MA) de ordinul q, iar al treilea termen din a doua sumă corespunde unui model autoregresiv (AR) de ordinul p. Se vede că varianţa condiţională curentă a rezidualului la proba de timp n depinde, atât de valorile probelor sale anterioare, cât şi de varianţele anterioare. Deşi în multe aplicaţii practice, cum sunt prognozele preţurilor acţiunilor, ordinele p şi q sunt setate la valori fixe mici cum ar fi (p, q) = (1, 1), pentru o modelare mai exactă a semnalelor naturale, cum sunt semnalele EEG, ordinele trebuie să fie determinate matematic. Coeficienţii de predicţie pentru diferite modele GARCH sau chiar funcţiile nonlineare g şi h sunt estimate recursiv ca pentru modelele ARMA [35]. În mod clar, asemenea modele GARCH simple sunt potrivite doar pentru dependenţa nonlineară multiplicativă. În plus, dependenţele aditive pot fi captate prin extinderea abordării modelării la clasa de modele GARCH-M (GARCH-medie-internă) [39]. O altă limitare a modelului GARCH simplu este eşuarea în adaptarea la asimetriile semnului. Aceasta se întâmplă deoarece în ecuaţiile de actualizare este folosit pătratul reziduului. Mai mult, modelul nu poate face faţă la tranziţiile rapide cum sunt vârfurile. Considerând aceste limitări, au fost propuse numeroase variante ale modelului GARCH. De exemplu, modelul a fost extins şi rafinat pentru a include efectele asimetrice ale salturilor pozitive şi negative cum ar fi modelul exponenţial GARCH (EGARCH) [40], Modelul Glosten, Jagannathan, şi Runkle GARCH (GJR-GARCH) [41], modelul pragului GARCH (TGARCH) [42], modelul puterii asimetrice GARCH (APGARCH) [43] şi modelul pătratic GARCH (QGARCH) [44]. În modeul EGARCH, de exemplu, ecuaţiile de mai sus se modifică în ecuația 2.29.

$$\log\left[\sigma^2(n)\right] = \log\left[\alpha_0\right] + \sum_{j=1}^{q} \alpha_j \log\left[e^2(n-j)\right] + \sum_{j=1}^{p} \beta_j \log\left[\sigma^2(n-j)\right] \quad \textbf{(2.29)}$$

Unde log reprezintă logaritmul natural. Această expresie logaritmică are avantajul de a împiedica varianţa să devină negativă. În aceste modele sunt definite diferite funcţii pentru g şi h. De exemplu, în modelul EGARCH propus de Glosten [45] h(n) este calculat iterativ ca în ecuația 2.30.

$$\mathrm{h}_{(n)} = b + \alpha_1 u^2(n-1)\left(1-\eta_{(n-1)}\right) + \alpha_2 u^2(n-1)\eta_{(n-1)} + k\mathrm{h}_{(n-1)} \quad \textbf{(2.30)}$$

Unde b, α_1, α_2 şi k sunt constante, iar $\eta_{(n)}$ este o funcţie indicator, care este zero când u(n) este negativ şi unu în rest. În afara modelării semnalelor, metoda GARCH are multe alte aplicaţii, în unele lucrări [46], conceptul modelării GARCH a covarianţei este combinat cu filtrarea Kalman pentru a obţine un model mai flexibil privind spaţiul şi timpul pentru rezolvarea reciprocei. Multe metode intră în categoria metodelor celor mai mici pătrate impuse, aplicând regularizarea Tikhonov [47]. Localizarea surselor din creier utilizând informaţia EEG este un astfel de exemplu. Această tehnică a devenit cunoscută drept tomografia electromagnetică de joasă rezoluţie (LORETA) [48]. Printre numereoasele opţiuni posibile pentru dinamica metodei GARCH, pentru estimarea secvenţială a parametrului varianţă al filtrului Kalman a fost utilizat EGARCH [40]. Metodele menționate anterior sunt folosite pentru a modela datele existente, dar pentru a genera semnale EEG cu acurateţe trebuie construit un model foarte complex care să exploateze dinamica fiziologică şi diversele activităţi mentale ale creierului. Un astfel de model ar trebui să încorporeze deasemenea, modificările semnalelor creierului datorate anomaliilor şi debuturilor de boală. Secţiunea ce urmează tratează interacţiunea dintre diferitele componente ale creierului pentru stabilirea unui model mai realist de generare a semnalelor EEG.

2.4.2.1. Generarea EEG pe baza modelării activităţilor neuronale

Obiectivul acestei secţiuni este acela de a prezenta unele modele stabilite pentru generarea de EEG normale şi a unora anormale. Modelele sunt în general nonlineare, unele au fost propuse în [49] pentru modelarea semnalului EEG normal şi altele pentru EEG anormale.

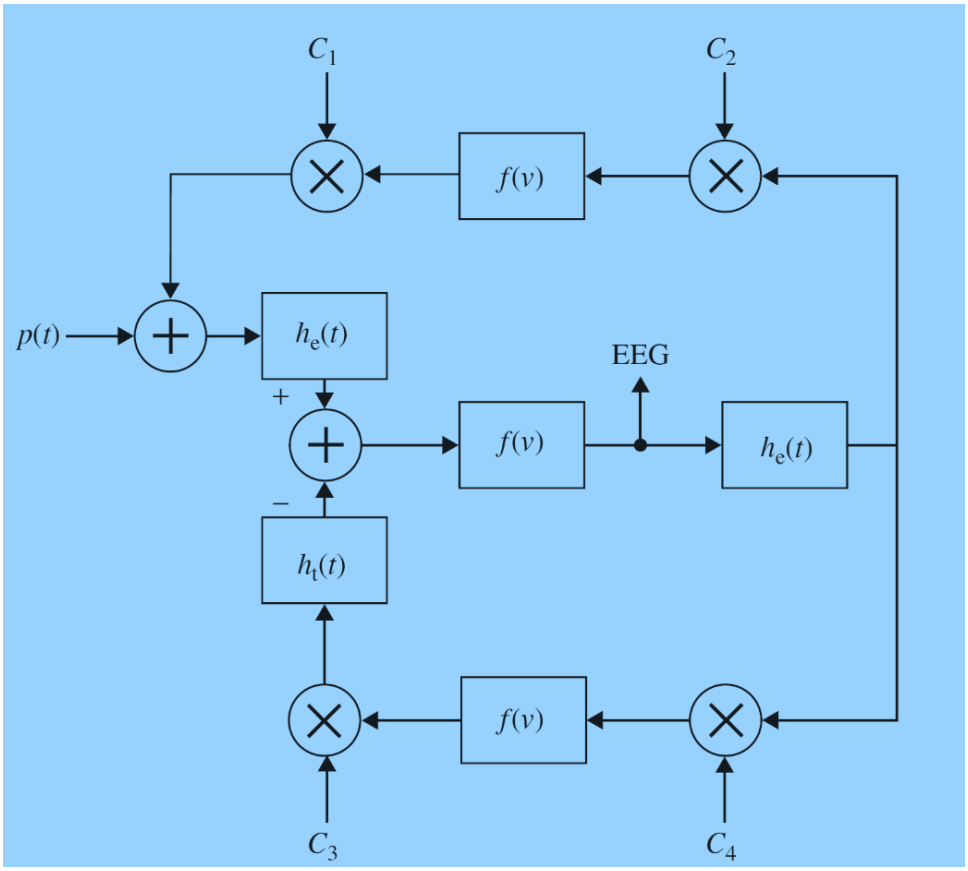


Figura 2.14 Un model concentrat nonlinear pentru generarea activităţii ritmice ale semnalelor EEG; $h_e(t)$ şi $h_i(t)$ sunt potenţialele postsinaptice excitatorii şi inhibitorii, f(v) este în mod normal o funcţie nonlineară simplificată, iar C_i sunt parametrii de interacţiune reprezentând interneuronii şi neuronii talamocorticali

A fost propus un model distribuit simplu, care a constat dintr-un set de neuroni simulaţi, celule de releu talamocorticale şi interneuroni, care incorporează datele fiziologice şi histologice limitate existente la acel moment. Ipotezele de bază au fost suficiente pentru a explica generarea ritmului alfa, adică a EEG în banda de frecvenţe de 8–13 Hz. Un model concentrat nonlinear general poate lua forma prezentată în Figura 2.14. Deşi modelul este analog în natură, toate piesele sunt implementate în formă discretă. Acest model poate lua în considerare caracteristicile majore ale unui model distribuit şi este uşor de investigat rezultatul în zona influenţelor excitatorii şi inhibitorii a celulelor releu talamocorticale şi a interneuronilor [50][51]. În modelul [50] este ilustrată o buclă de feedback incluzând potenţialele postsinaptice inhibitorii, funcţia nonlineară şi parametrii de interacţiune C_3 şi C_4. Celălalt feedback include în principal potenţialele excitatorii, funcţia nonlineară şi parmetrii de interacţiune C_1 şi C_2. Rolul neuronilor excitatori este acela de a excita unul sau doi neuroni inhibitori. Aceştia, în schimb, servesc la inhibarea unei colecţii de neuroni excitatori. Astfel, circuitul neural formează un sistem de feedback. Intrarea p(t) este considerat ca un semnal de

zgomot alb. Acesta este un model general; adesea sunt necesare mai multe ipoteze pentru a perminte generarea de semnale EEG pentru cazurile anormale. De aceea, funcţia f(v) se poate modifica pentru a genera semnalele EEG pentru diverse anomalii ale creierului. În mod corespunzător, pot fi variaţi şi coeficienţii C_i. În plus, ieșirea depinde de zgomotul de mediu şi de măsurare. În unele modele, cum este modelul EEG local (LEM) zgomotul a fost considerat ca o componentă aditivă în ieșire [50].

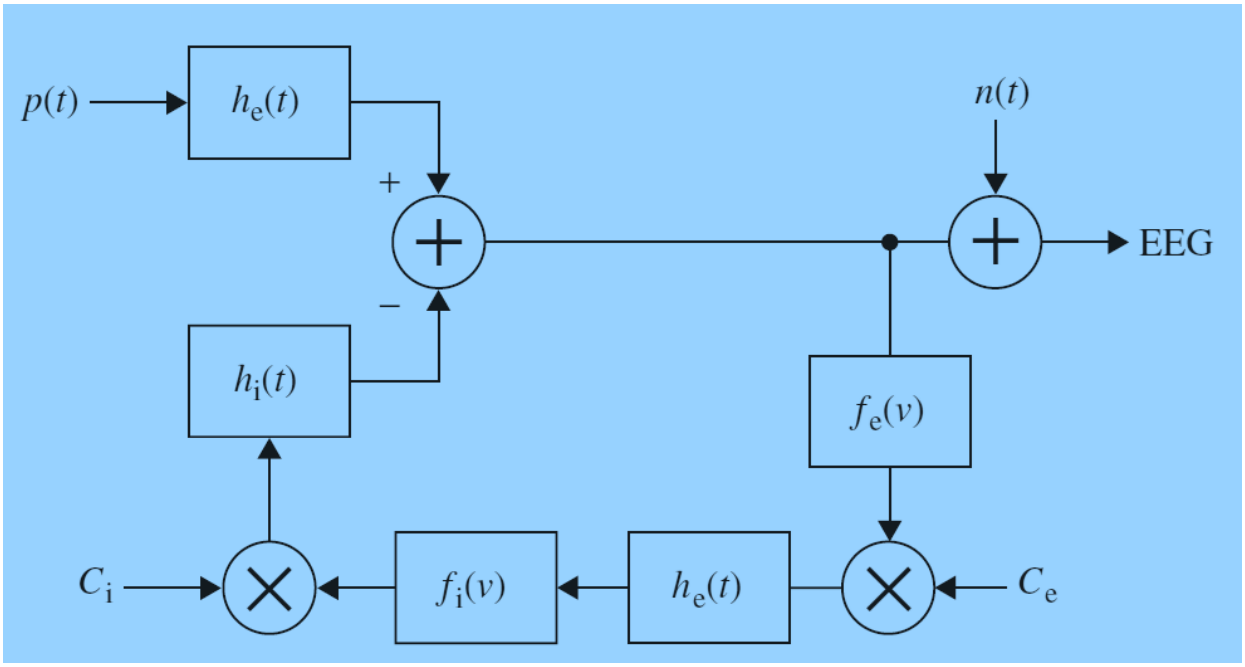


Figura 2.15 Modelul EEG local (LEM). Neuronii releu talamocorticali sunt reprezentaţi prin două sisteme lineare având răspunsuri de impuls $h_e(t)$, pe ramura de sus, şi potenţial postsinaptic inhibitor de $h_i(t)$. Nonlinearitatea acestui sistem este notată $f_e(v)$, reprezentând procesul generator de vârfuri. Activitatea interneuronilor este reprezentată ptrintr-un alt filtru linear $h_e(t)$ pe ramura de jos, care în general poate fi diferit de primul sistem linear şi o funcţie de nonlinearitate $f_i(v)$. C_e şi C_i reprezintă numărul de celule de interneuroni şi neuronii talamocorticali

Figura 2.15 prezintă modelul LEM. Acest model utilizează formula lui Wilson şi Cowan, care au furnizat un set de ecuaţii pentru a descrie activitatea globală (nu EEG în mod specific) într-un cartel de neuroni excitatori şi inhibitori cu un număr mare de interconexiuni. Similar, în LEM, ritmurile EEG se presupun a fi generate de populaţii distincte de neuroni, care au proprietăţi selective de frecvenţă. Aceste populaţii sunt formate prin interconectarea neuronilor individuali şi se presupune că sunt conduse de o intrare întâmplătore. Caracteristicile modelului, cum este interconectivitatea neurală, răspunsul puls al sinapsei şi pragul de excitaţie sunt prezentate de parametrii modelului LEM. Modificările acestor parametri produc ritmurile EEG relevante [52][53]. În Figurile 2.14 și 2.15, notaţiile e şi i se referă la excitator şi respectiv

inhibitor. Intrarea p(t) este presupus a rezulta din însumarea unei serii distribuite la întâmplare de potenţiale întâmplătoare, care conduc celulele excitatorii ale circuitului, producând semnalul continuu EEG de fond. Asemenea semnale îşi au originea într-o altă declanşare spontană mai profundă a sistemului nervos central (SNC). În model, numărul mediu de intrări într-un neuron inhibitor de la neuronii excitatori este desemnat prin C_e şi numărul mediu corespunzător de la neuronii inhibitori la fiecare neuron excitator în parte este C_i. Diferenţa dintre două exponenţiale de descompunere este utilizată pentru modelarea fiecărui potenţial postsinaptic h_e sau h_i:

$$h_e(t) = A[\exp(-\alpha_1 t) - \exp(-\alpha_2 t)] \quad (2.31)$$

$$h_i(t) = B[\exp(-b_1 t) - \exp(-b_2 t)] \quad (2.32)$$

Unde A, B, α_k, şi b_k sunt parametri constanţi, care controlează forma undelor de puls. Potenţialele de membrană au legătură cu densităţile pulsului axonal prin intermediul funcţiilor prag statice f_e şi f_i. Aceste funcţii sunt în general nonlineare, dar pentru a uşura manipulările ele sunt considerate lineare pentru fiecare interval de timp scurt. Folosind modelul, ritmurile normale ale creierului, cum ar fi unda alfa, sunt considerate ca zgomot filtrat. Principala problemă a unui asemenea model este datorată faptului că numai un canal EEG este generat şi nu există modelare pentru relaţiile intercanelare. De aceea, trebuie să fie definit un model mai exact, pentru a permite simularea unui sistem de generare EEG multicanal.

2.4.2.2. Nonlinearitatea mediului

Capul, ca mediu de amestec, combina semnalele EEG care sunt generate local în creier la poziţiile senzorilor. Ca sistem, capul poate fi mai mult sau mai puţin susceptibil la asemenea surse în diferite situaţii. În general, un semnal EEG poate fi considerat ca ieșire al unui sistem nonlinear, care poate fi caracterizat deterministic. Schimbările metabolismului creierului ca rezultat al fenomenelor biologice și fiziologice din corpul uman pot modifica procesul de

amestecare. Unele dintre aceste modificări sunt influenţate de activitatea creierului însuşi. Aceste efecte fac sistemul nonlinear. Analiza unui asemenea sistem este foarte complicată şi până acum nimeni nu a modelat complet sistemul pentru a veni în ajutorul analizei semnalelor creierului. Pe de altă parte, unele măsuri împrumutate din teoria haosului şi analiza dinamicii seriei de timp, cum sunt: disimilaritatea, dimensiunea tractor şi cei mai mari exponenţi Lyapunov (LLE) pot caracteriza comportamentul nonlinear al semnalelor EEG.

2.4.3. Nonstaționaritatea semnalelor EEG

Nonstaționaritatea semnalelor poate fi cuantificată prin măsurarea unor statistici ale semnalelor la diferite intervale de timp. Semnalele pot fi considerate staţionare dacă nu există variaţie considerabilă în statistici. Deşi în general distribuţia EEG multicanal este considerată o gausiană multivariată, proprietăţile medianei şi covarianţa se modifică în general de la segment la segment. Din acest motiv, EEG sunt considerate staţionare numai pe intervale scurte, adică cvazistaţionare. Ipoteza gausiană se verifică în timpul unei stări normale a creierului, dar în timpul activităţilor fizice şi mentale această ipoteză nu este valabilă. Unele exemple de nonstaţionaritate a semnalelor EEG pot fi observate în timpul schimbărilor de stare de alertă şi de stare de veghe (unde există oscilaţii alfa mai puternice), în timpul clipitului, în timpul tranziţiilor între diferite stări ictale, şi în cazul semnalelor de potenţial de eveniment (ERP) şi de potenţial eco (EP). Modificarea distribuţiei segmentelor de semnal poate fi măsurată, atât în parametri ai unui proces gaussian, cât şi ca deviaţie a distribuţiei de la curba Gaussiană. Non-gaussianitatea semnalelor poate fi verificată măsurând sau estimând unele momente de ordin mai înalt cum sunt gradul de înclinare, coeficientul Kurt, negentropia şi distanţa Kulback–Laibler (KL). Gradul de înclinare este o măsură a simetriei sau, mai precis, a lipsei simetriei distribuţiei. O distribuţie, sau set de date, este simetrică dacă arată la fel la stânga şi la dreapta faţă de punctul central. Gradul de înclinare pentru un semnal real este definit ca în ecuația 2.33.

$$Grad\ de\ înclinare = \frac{E[(x(n) - \mu)^3]}{\sigma^3} \tag{2.33}$$

Unde μ şi σ sunt media, şi respectiv, deviaţia standard, iar E denotă expectanţa statistică. Dacă distribuţia este mai mult la dreapta faţă de punctul mediu, gradul de înclinare este negativ, şi vice-versa. Pentru o distribuţie simetrică precum cea gaussiană, gradul de înclinare este zero. Coeficientul Kurt este o măsură indiferent dacă datele sunt vârfuite sau plate relativ la o distribuţie normală; adică seturi de date cu coeficienţi Kurt înalţi tind să aibă un vârf distinct lângă mediană, declină relativ repede şi au percursiuni importante. Seturile de date cu un coeficient Kurt scăzut tind să aibă un vârf plat lângă medie mai degrabă decât un vârf ascuţit. O distribuţie uniformă ar fi cazul extrem. Coeficientul Kurt pentru un semnal real x(n) este definit ca în ecuația 2.34.

$$kurt = \frac{m_4[x(n)]}{m_2^2[x(n)]} \tag{2.34}$$

Unde $m_i[x(n)]$ este momentul i central al semnalului x(n). Coeficientul Kurt pentru semnale cu distribuţie normală este trei. De aceea, un coeficient Kurt de exces sau normalizat este folosit deseori şi este definit ca în ecuația 2.35.

$$Ex\ kurt = \frac{m_4[x(n)]}{m_2^2[x(n)]} - 3 \tag{2.35}$$

Coeficientul din ecuația 2.35 este zero pentru semnalele distribuite gaussian. Adesea semnalele sunt considerate ergodice; deci mediile statistice pot fi presupuse identice cu mediile de timp şi astfel pot fi estimate la mediile de timp. Negentropia unui semnal x(n) este definită ca în ecuația 2.36 [52].

$$J_{neg}[x(n)] = H[x_{Gauss}(n)] - H[x(n)] \tag{2.36}$$

Unde $x_{Gauss}(n)$ este un semnal întâmplător gausian cu aceeaşi covarianţă ca şi x(n), iar H este entropia diferenţială [54], definită ca în ecuația 2.37, unde p[x(n)] este distribuția semnalului. Negentropia este întotdeauna non-negativă.

$$H[x(n)] = \int_{-\infty}^{\infty} p[x(n)] log \frac{1}{p[x(n)]} dx(n) \tag{2.37}$$

Distanţa KL dintre două distribuţii p_1 şi p_2 este definită ca în ecuația 2.38. Este clar că distanţa KL este în general asimetrică, de aceea prin schimbarea poziţei lui p_1 şi p_2 în această ecuaţie, distanţa KL se schimbă. Minimul distanţei KL apare atunci când: $p_1[x_1(n)] = p_2[x_2(n)]$.

$$KL = \int_{-\infty}^{\infty} p_1[x_1(n)] log \frac{p_1[x_1(n)]}{p_2[x_2(n)]} dz \tag{2.38}$$

2.4.4. Segmentarea semnalelor EEG

Adesea este necesară identificarea semnalelor EEG pe segmente cu caracteristici similare, care au importanță în special pentru clinicieni şi pentru evaluările neurofiziologilor. În fiecare segment, semnalele sunt considerate staţionare, de obicei cu statistici de impedanţă şi frecvenţă similare. Ca exemplu, un EEG înregistrat la un pacient epileptic poate fi împărţit în trei segmente, preictal, ictal şi postictal. Fiecare poate avea o durată diferită. Figura 2.16 reprezintă o secvenţă EEG ce include toate aceste segmente.

În segmentarea unui semnal EEG pot fie exploatate proprietăţile de timp sau frecvenţă ale semnalelor. Aceasta conduce eventual la o măsurătoare a disimilarităţii notate cu d(m) între cadrele EEG adiacente, în care m este o valoare întreagă de indexare a cadrului, iar diferenţa este calculată între m și m-1 cadru de semnal (consecutiv). O segmentare eficientă este posibilă prin evidenţierea şi exploatarea efectivă a informaţiei de diagnostic din semnale cu ajutorul clinicienilor specializaţi. Totuşi, accesul la asemenea specialişti nu este întotdeauna posibil şi de aceea, sunt necesare metode algoritmice. Un număr de măsuri de disimilaritate diferite pot fi definite pe baza fundamentelor procesării digitale ale semnalelor. Un criteriu se bazează pe autocorelaţiile segmentului m, definit ca în ecuația 2.39.

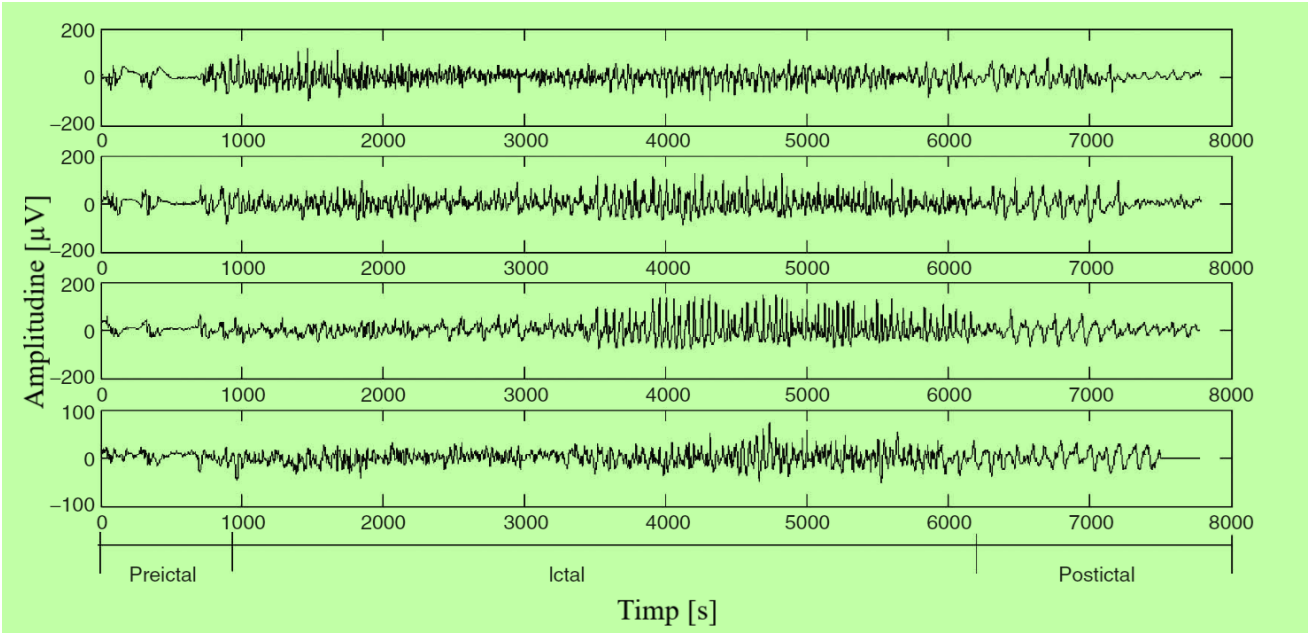


Figura 2.16 Un set EEG de semnale de atac tonic–clonic incluzând trei segment de comportament: preictal, ictal, şi postictal

$$r_x(k,m) = E[x(n,m)x(n+k,m)] \tag{2.39}$$

Funcţia autocorelării cadrului m cu lungime N pentru un interval de timp presupus n, n + 1,.., n + (N-1) poate fi aproximat ca în ecuația 2.40, iar criteriul este definit ca în relația 2.41.

$$\hat{r}_x(k,m) = \begin{cases} \frac{1}{N}\sum_{l=0}^{N-1k} x(l+m+k)x(l+m), k = 0,\dots,N-1 \\ 0, k = N, N+1, \dots \end{cases} \tag{2.40}$$

$$d_1(m) = \frac{-\sum_{k=-\infty}^{\infty}[\hat{r}_x(k,m) - \hat{r}_x(k,m-1)]^2}{\hat{r}_x(0,m)\hat{r}_x(0,m-1)} \tag{2.41}$$

Un al doilea criteriu poate fi bazat pe statisticile de ordin înalt. Semnalele cu distribuţii mai uniforme cum sunt ritmurile normale ale creierului au un coeficient Kurt scăzut, în timp ce semnalele de atac sau de potenţialele de eveniment (semnalele ERP) au adesea valori ridicate ale coeficientului Kurt. Coeficientul Kurt este definit ca şi cumulantul de ordin patru la

intervale de timp zero. Un discriminant de nivelul al doilea $d_2(m)$ este atunci definit ca și în ecuația 2.42.

$$d_2(m) = kurt_x(m) - kurt_x(m-1) \tag{2.42}$$

Unde m se referă la cadrul semnalului EEG. Un al treilea criteriu este definit din măsura erorii spectrale a periodogramei. O periodogramă a cadrului m este obţinută prin transformarea Fourier de timp discret a funcţiei de corelaţie a semnalului EEG:

$$S_x(\omega, m) = \sum_{k=-\infty}^{\infty} \hat{r}_x(k, m) e^{-j\omega k} \ , \omega \in [-\pi, \pi] \tag{2.43}$$

Unde $\hat{r}_x(k, m)$ este funcţia de autocorelaţie a cadrului m cum este definită mai sus. Criteriul este atunci definit pe baza periodogramei normalizate ca în ecuația 2.44.

$$d_3(m) = \frac{\int_{-\pi}^{\pi} [S_x(\omega, m) - S_x(\omega, m-1)]^2 d\omega}{S_x(\omega, m) d\omega \int_{-\pi}^{\pi} [S_x(\omega, m-1)\, d\omega} \tag{2.44}$$

Autocorelația probei fereastrei de test pentru măsurarea atât a lui $d_1(m)$, cât şi a lui $d_3(m)$ poate fi adaptată prin următoarea ecuaţie recursivă aplicate la fereastra test de mărime N:

$$\begin{aligned} \hat{r}_x(k, m) = \hat{r}_x(k, m-1) + \frac{1}{N} [x(m-1+N)x(m-1+N-k) \\ - x(m-1+k)x(m-1)] \end{aligned} \tag{2.45}$$

Astfel complexitatea calculului poate fi redusă în practică. Un al patrulea criteriu corespunde energiei de eroare în modelarea bazată pe autoregresie (AR) a semnalelor. Eroarea de predicţie în modelul AR al cadrului m este pur şi simplu definită ca în ecuația 2.46, unde p este ordinul de predicție.

$$e(n,m) = x(n,m) - \sum_{k=1}^{p} a_k(m)x(n-k,m) \quad (2.46)$$

Pentru un anumit p, coeficienţii pot fi găsiţi direct (de exemplu metoda lui Durbin) asfel încât să fie minimizată energia semnalului de eroare (rezidual). În această abordare se presupune că cadrele de lungime N sunt suprapuse cu probă. Coeficienţii de predicţie estimaţi pentru cadrul (m − 1) sunt apoi utilizaţi pentru a prezice prima probă din cadrul m. Dacă această eroare este mică, este probabil ca statisticile cadrului m să fie similare cu cele ale cadrului (m – 1). Pe de altă parte, o valoare mare este probabil să indice o modificare. Un indicator pentru al patrulea criteriu poate fi atunci diferenţa dintre acest semnal de predicţie, care dă un vârf la graniţa dintre segmente, adică avem ecuația 2.47, unde ∇_m gradientul cu privire la m, aproximat printr-o operaţie de diferenţă de ordin prim. Figura 2.17 arată rezidualul şi gradientul definiţi în ecuaţia 2.47.

$$d_4(m) = \max\left[\nabla_m \hat{e}(1,m)\right] \quad (2.47)$$

În final, un al cincilea criteriu $d_5(m)$ poate fi definit folosing un spectru pe bază de AR de semnale în acelaşi mod ca şi reprezentarea frecvenţei de termen scurt (STFT) la $d_3(m)$. Modelul AR de mai sus este un model univariat, adică modelează un EEG de canal unic. Un criteriu similar poate fi definit câmd sunt luate în considerare semnale EEG cu canale multiple. În asemenea cazuri, este analizat un model AR multivariat (MVAR). MVAR poate fi folosit, de asemenea, pentru caracterizarea şi cuantificarea propagării semnalui în creier. Deşi criteriile de mai sus pot fi efectiv utilizate la segmentarea semnalelor EEG, pot fi definite sisteme mai bune pentru detectare anumitor anomalii. Pentru aceasta, trebuie identificate şi folosite trăsăturile, care descriu cel mai bine comportamentul semnalelor. Astfel problema segmentării devine o problemă de clasificare pentru care pot fi utilizaţi diferiţi clasificatori [29].

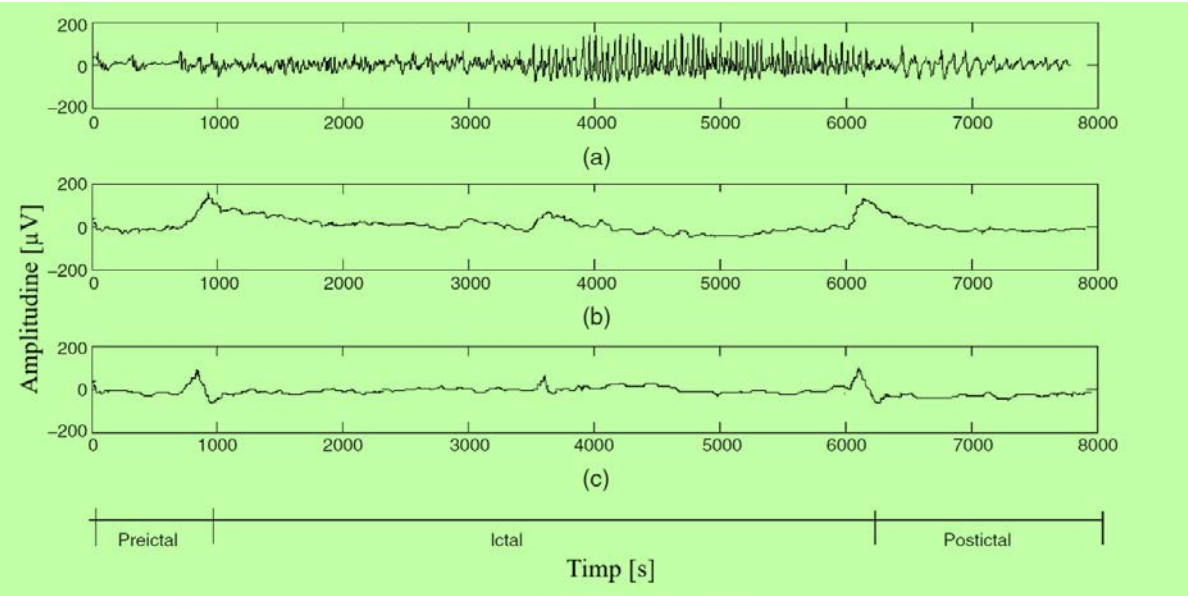


Figura 2.17 (a) Un semnal EEG de atac incluzând segmentele: preictal, ictal şi postictal, (b) semnalul de eroare, şi (c) gradientul aproximativ al semnalului, care relevă vârful la graniţa dintre segmente. Numărul coeficienţilor de predicţie este p = 12

3. Concluzii

În cadrul acestui raport, intitulat *„Analiza și procesarea extinsă a parametrilor fiziologici în evaluarea comportamentului uman”*, s-a analizat în detaliu procesarea undelor EEG, punând accent pe metodele avansate de înregistrare, condiționare și modelare a semnalelor EEG. În mod specific, au fost abordate aspecte esențiale precum condiționarea semnalelor, tehnicile de modelare liniară și neliniară a undelor EEG. Aceste etape au permis o înțelegere mai profundă a dinamicii semnalelor EEG și a modului în care acestea reflectă stările emoționale și comportamentele critice. De asemenea, raportul a explorat problemele legate de nonstaționaritatea semnalelor EEG, precum și strategiile de segmentare necesare pentru identificarea tiparelor specifice în diferite contexte. Această analiză detaliată contribuie la construirea unui cadru teoretic solid pentru utilizarea semnalelor EEG în medii critice, cu aplicabilitate în monitorizarea personalului operativ și detectarea comportamentelor disimulate. Pe lângă aspectele teoretice și practice legate de procesarea EEG, raportul a evidențiat provocările legate de artefacte și zgomot, oferind soluții avansate pentru ameliorarea acestora. Prin utilizarea unor tehnici precum analiza componentelor independente (ICA) sau metode de filtrare adaptivă, s-a demonstrat cum poate fi îmbunătățită calitatea datelor EEG, esențială pentru interpretări precise.

În raportul următor al tezei de doctorat *„Contribuții privind sistemele de evaluare automată a comportamentului uman pentru personalul din infrastructuri critice”*, analiza undelor EEG va fi continuată printr-o focalizare asupra transformărilor semnalelor EEG și a analizei frecvenței. Vor fi abordate subiecte precum transformata wavelet (discretă și continuă), funcția ambiguității, distribuția Wigner–Ville, precum și alte metode avansate de modelare, cum ar fi coerența și analiza autoregresivă multivariată (MVAR). Mai mult decât atât, se vor detalia tehnici de filtrare și eliminare a zgomotului, incluzând metode hibride și algoritmi de clasificare, pentru a extinde posibilitățile de interpretare și utilizare a datelor EEG. Raportul 4 va introduce, de asemenea, concepte fundamentale din inteligența artificială, cum ar fi învățarea supervizată și nesupervizată, explorând utilizarea algoritmilor avansați precum învățarea profundă (deep learning) în procesarea EEG. Această abordare progresivă urmărește să integreze rezultatele din prezentul raport cu perspectivele oferite de analiza viitoare, creând astfel un sistem integrat pentru evaluarea comportamentului uman în timp real, adaptat cerințelor infrastructurilor critice.

4. Bibliografie

[1] R. Caton, “The Electric Currents of the Brain,” *American Journal of EEG Technology*, 1970, doi: 10.1080/00029238.1970.11080764.

[2] W. G. Walter, “Slow potential waves in the human brain associated with expectancy, attention and decision,” *Arch Psychiatr Nervenkr Z Gesamte Neurol Psychiatr*, 1964, doi: 10.1007/BF00341700.

[3] F. Vasile, E. Dossi, and N. Rouach, “Human astrocytes: structure and functions in the healthy brain,” *Brain Structure and Function*. 2017. doi: 10.1007/s00429-017-1383-5.

[4] M. Telpan, “FUNDAMENTALS OF EEG MEASUREMENT M . Teplan,” *Measurement Science Review*, 2002.

[5] E. St. Louis *et al.*, *Electroencephalography (EEG): An Introductory Text and Atlas of Normal and Abnormal Findings in Adults, Children, and Infants*. 2016. doi: 10.5698/978-0-9979756-0-4.

[6] S. Ashwal and R. Rust, “Child neurology in the 20th century,” *Pediatr Res*, 2003, doi: 10.1203/01.PDR.0000047655.66475.52.

[7] E. Niedermeyer, “The Normal EEG of the Waking Adult,” *Electroencephalography: Basic Principles, Clinical Applications and Related Fields*, 1999.

[8] V. A. Grin, Y. D. Kropotov, V. A. Ponomarev, L. S. Chutko, and E. A. Yakovenko, “Effect of Biofeedback Training of Sensorimotor and b 1 EEG Rhythms on Attention Parameters,” *Text*, 2001.

[9] G. Pfurtscheller, D. Flotzinger, and C. Neuper, “Differentiation between finger, toe and tongue movement in man based on 40 Hz EEG,” *Electroencephalogr Clin Neurophysiol*, 1994, doi: 10.1016/0013-4694(94)90137-6.

[10] A. Biasiucci, B. Franceschiello, and M. M. Murray, “Electroencephalography,” *Current Biology*. 2019. doi: 10.1016/j.cub.2018.11.052.

[11] P. L. Silbert, K. Radhakrishnan, J. Johnson, and D. W. Klass, “The significance of the phi rhythm,” *Electroencephalogr Clin Neurophysiol*, 1995, doi: 10.1016/0013-4694(95)00076-B.

[12] J. A. Pineda, “The functional significance of mu rhythms: Translating ‘seeing’ and ‘hearing’ into ‘doing,’” *Brain Research Reviews*. 2005. doi: 10.1016/j.brainresrev.2005.04.005.

[13] “A glossary of terms most commonly used by clinical electroencephalographers.,” *Electroencephalogr Clin Neurophysiol*, vol. 37, no. 5, pp. 538–548, 1974, doi: 10.1016/0013-4694(74)90099-6.

[14] J. Gotman, “Automatic recognition of epileptic seizures in the EEG,” *Electroencephalogr Clin Neurophysiol*, 1982, doi: 10.1016/0013-4694(82)90038-4.

[15] M. Al-Hakim, “Essentials of Clinical Neurophysiology,” *Neurology*, 1993, doi: 10.1212/wnl.43.8.1634-b.

[16] L. G. Fehmi and T. Collura, “Effects of electrode placement upon EEG biofeedback training: The monopolar-bipolar controversy,” *J Neurother*, 2007, doi: 10.1300/J184v11n02_04.

[17] F. Lopes Da Silva, “Functional localization of brain sources using EEG and/or MEG data: Volume conductor and source models,” 2004. doi: 10.1016/j.mri.2004.10.010.

[18] U. Malinowska, P. J. Durka, K. J. Blinowska, W. Szelenberger, and A. Wakarow, “Micro- and macrostructure of sleep EEG,” *IEEE Engineering in Medicine and Biology Magazine*, 2006, doi: 10.1109/MEMB.2006.1657784.

[19] P. J. Durka, D. Ircha, and K. J. Blinowska, “Stochastic time-frequency dictionaries for matching pursuit,” *IEEE Transactions on Signal Processing*, 2001, doi: 10.1109/78.905866.

[20] G. B. Benedek and F. M. H. Villars, *Physics With Illustrative Examples From Medicine and Biology*. 2000. doi: 10.1007/978-1-4612-1242-3.

[21] D. C. Eaton, “Ionic channels of excitable membranes. Bertil Hille. Sunderland, Ma: Sinauer Associates, 1984,” *J Neurosci Res*, 1985, doi: 10.1002/jnr.490130415.

[22] A. L. Hodgkin and A. F. Huxley, “A quantitative description of membrane current and its application to conduction and excitation in nerve,” *J Physiol*, 1952, doi: 10.1113/jphysiol.1952.sp004764.

[23] D. A. Baxter and J. H. Byrne, “Simulator for neural networks and action potentials.,” *Methods in molecular biology (Clifton, N.J.)*. 2007. doi: 10.1007/978-1-59745-520-6_8.

[24] S. M. Kay, *Fundamentals of Statistical Signal Processing (III): Practical Algorithm Development*. 2001.

[25] C. Gueguen and L. L. Scharf, “EXACT MAXIMUM LIKELIHOOD IDENTIFICATION OF ARMA MODELS: A SIGNAL PROCESSING PERSPECTIVE.,” 1980.

[26] H. Akaike, “A New Look at the Statistical Model Identification,” *IEEE Trans Automat Contr*, 1974, doi: 10.1109/TAC.1974.1100705.

[27] J. Durbin, “Efficient Estimation of Parameters in Moving-Average Models,” *Biometrika*, 1959, doi: 10.2307/2333528.

[28] W. F. Trench, “An Algorithm for the Inversion of Finite Toeplitz Matrices,” *Journal of the Society for Industrial and Applied Mathematics*, 1964, doi: 10.1137/0112045.

[29] M. Morf, A. Vieira, D. T. L. Lee, and T. Kailath, “Recursive Multichannel Maximum Entropy Spectral Estimation,” *IEEE Transactions on Geoscience Electronics*, 1978, doi: 10.1109/TGE.1978.294569.

[30] M. von Spreckelsen, M. von Spreckelsen, and B. Bromm, “Estimation of Single-Evoked Cerebral Potentials by Means of Parametric Modeling and Kalman Filtering,” *IEEE Trans Biomed Eng*, 1988, doi: 10.1109/10.7270.

[31] T. Demiralp and A. Ademoğlu, “Modeling of evoked potentials as decaying sinusoidal oscillations by PRONY-method,” 1992. doi: 10.1109/IEMBS.1992.5761536.

[32] R. Prony, “Essai éxperimental et analytique: sur les lois de la dilatabilité des fluides élastique et sur celles de la force expansive de la vapeur de l’alkool, à diférentes températures,” *Journal de l’École Polytechnique Floréal et Plairial*, 1795.

[33] Demiralp and Ademoglu, “Modeling Of Evoked Potentials As Decaying Sinusoidal Oscillations By Prony-method,” 2005. doi: 10.1109/iembs.1992.592749.

[34] D. Bouattoura, P. Gaillard, P. Villon, and F. Langevin, “Multilead evoked potentials modelling based on the Prony’s method,” 1996. doi: 10.1109/tencon.1996.608403.

[35] M. M. Dacorogna, U. A. Müller, O. V. Pictet, and R. B. Olsen, “Modelling Short-Term Volatility with GARCH and HARCH Models,” *SSRN Electronic Journal*, 2005, doi: 10.2139/ssrn.36960.

[36] A. I. McLeod and W. K. Li, “DIAGNOSTIC CHECKING ARMA TIME SERIES MODELS USING SQUARED-RESIDUAL AUTOCORRELATIONS,” *J Time Ser Anal*, 1983, doi: 10.1111/j.1467-9892.1983.tb00373.x.

[37] W. D. RAY, “Nonlinear Dynamics, Chaos and Instability Statistical Theory and Economic Evidence.,” *Journal of the Operational Research Society*, 1993, doi: 10.1057/jors.1993.37.

[38] D. A. Hsieh, “Testing for Nonlinear Dependence in Daily Foreign Exchange Rates,” *The Journal of Business*, 1989, doi: 10.1086/296466.

[39] R. F. Engle, D. M. Lilien, and R. P. Robins, “Estimating Time Varying Risk Premia in the Term Structure: The Arch-M Model,” *Econometrica*, 1987, doi: 10.2307/1913242.

[40] D. B. Nelson, “Stationarity and persistence in the garch(1,1) model,” *Econ Theory*, 1990, doi: 10.1017/S0266466600005296.

[41] L. R. GLOSTEN, R. JAGANNATHAN, and D. E. RUNKLE, “On the Relation between the Expected Value and the Volatility of the Nominal Excess Return on Stocks,” *J Finance*, 1993, doi: 10.1111/j.1540-6261.1993.tb05128.x.

[42] J. M. Zakoian, “Threshold heteroskedastic models,” *J Econ Dyn Control*, 1994, doi: 10.1016/0165-1889(94)90039-6.

[43] Z. Ding, C. W. J. Granger, and R. F. Engle, “A long memory property of stock market returns and a new model,” *J Empir Finance*, 1993, doi: 10.1016/0927-5398(93)90006-D.

[44] E. Sentana, “Quadratic arch models,” *Review of Economic Studies*, 1995, doi: 10.2307/2298081.

[45] L. R. Glosten *et al.*, “On the Relation between the Expected Value and the Volatility of the Nominal Excess Return on Stocks,” *J Finance*, vol. 48, no. 5, pp. 1779–1801, Dec. 1993, doi: 10.1111/J.1540-6261.1993.TB05128.X.

[46] A. Galka, O. Yamashita, and T. Ozaki, “GARCH modelling of covariance in dynamical estimation of inverse solutions,” *Physics Letters, Section A: General, Atomic and Solid State Physics*, 2004, doi: 10.1016/j.physleta.2004.10.045.

[47] C. W. Groetsch, A. N. Tikhonov, and A. V. Goncharsky, “Ill-Posed Problems in the Natural Sciences,” *Math Comput*, 1989, doi: 10.2307/2008377.

[48] R. D. Pascual-Marqui, M. Esslen, K. Kochi, and D. Lehmann, “Functional imaging with low-resolution brain electromagnetic tomography (LORETA): A review,” 2002.

[49] T. D. Lagerlund, F. W. Sharbrough, and N. E. Busacker, “Spatial filtering of multichannel electroencephalographic recordings through principal component analysis by singular value decomposition,” *Journal of Clinical Neurophysiology*. 1997. doi: 10.1097/00004691-199701000-00007.

[50] F. H. Lopes da Silva, A. Hoeks, H. Smits, and L. H. Zetterberg, “Model of brain rhythmic activity - The alpha-rhythm of the thalamus,” *Kybernetik*, 1974, doi: 10.1007/BF00270757.

[51] F. H. Lopes da Silva, A. van Rotterdam, P. Barts, E. van Heusden, and W. Burr, “Models of Neuronal Populations: The Basic Mechanisms of Rhythmicity,” *Prog Brain Res*, 1976, doi: 10.1016/S0079-6123(08)60995-4.

[52] H. R. Wilson and J. D. Cowan, “Excitatory and Inhibitory Interactions in Localized Populations of Model Neurons,” *Biophys J*, vol. 12, no. 1, pp. 1–24, Jan. 1972, doi: 10.1016/S0006-3495(72)86068-5.

[53] P. C. Bressloff, “Stochastic neural field theory and the system-size expansion,” *SIAM J Appl Math*, 2009, doi: 10.1137/090756971.

[54] T. M. Cover and J. A. Thomas, *Elements of Information Theory*. 2005. doi: 10.1002/047174882X.