Raport 4

Analiza și procesarea avansată a semnalelor EEG pentru evaluarea comportamentului uman în medii critice

Student: Nicolescu Șerban-Teodor

CUPRINS

1. Introducere 4

2. Metode de Prelucrare şi Analiză a Semnalelor EEG 6

2.1. Transformările Semnalelor EEG şi Analiza Frecvenţei 6

2.2. Transformata Wavelet 9

2.2.1. Transformata Wavelet Continuă 9

2.2.2. Exemple de unde wavelet continue 10

2.2.3. Transformata Wavelet Discretă 12

2.2.4. Analiza de Multirezoluţie 13

2.2.5. Transformata Wavelet Utilizând Transformata Fourier 16

2.2.6. Reconstrucţia Datelor din Coeficienţii de Undă Wavelet 17

2.2.7. Funcţia Ambiguităţii şi Distribuţia Wigner–Ville 19

2.3. Coerenţa, Modelarea Autoregresivă Multivariată (MVAR) şi Funcţia de Transfer direcţionat (DTF) 22

2.4. Filtrarea şi Eliminarea Zgomotului din Semnalele EEG 26

2.5. Tipuri de artefacte 26

2.5.1. Artefacte Oculare 26

2.5.2. Artefacte Musculare 27

2.5.3. Artefacte Cardiace 27

2.5.4. Artefacte Extrinseci 28

2.6. Tehnici de Eliminare a Artefactelor 28

2.6.1. Metode de Regresie 28

2.6.2. Transformarea Wavelet 29

2.6.3. BSS 30

2.6.4. Analiza Componentelor Principale (PCA) 31

2.6.5. Analiza Componentelor Independente (ICA) 31

2.6.6. Analiza corelației canonice (CCA) 32

2.6.7. Metoda Bazată pe Imagistica Sursei 33

2.6.8. Descompunerea Empirică a Modurilor 34
2.6.9. Metode de Filtrare 35
2.6.9.1. Filtrarea Adaptivă 36
2.6.9.2. Filtrarea Wiener 37
2.6.9.3. Metode de Descompunere Dispersate 37
2.6.9.4. Metode Hibride 38
2.6.9.5. EMD-BSS 38
2.6.9.6. Wavelet-BSS 39
2.6.9.7. BSS și Mașina vectorială de suport 40
2.7. Estimarea Parametrilor Semnalelor EEG 40
2.7.1. Localizarea Sursei EEG 41
2.7.2. Abordări Generale ale Localizării sursei 42
2.7.3. Ipoteza de Dipol 43
2.7.4. Metoda ICA 46
2.7.5. Algoritmul MUSIC 46
2.7.6. Algoritmul LORETA 51
2.7.7. Algoritmul FOCUSS 54
2.7.8. LORETA Standardizat 54
2.7.9. Alte Soluții ale Normei Minime Ponderate 56
2.7.10. Indici de Evaluare 58
2.7.11. Metoda ICA–LORETA unificate 60
2.7.12. Metoda BSS Constrânsă Partial 63
2.7.13. *Determinarea Numărului de Surse* 64
2.7.14. Sumar și concluzii 66
3. Concluzii 68
4. Bibliografie 70

1. Introducere

Teza de doctorat *„Contribuții privind sistemele de evaluare automată a comportamentului uman pentru personalul din infrastructuri critice”* are ca obiectiv principal dezvoltarea unor tehnici avansate de procesare și analiză a semnalelor fiziologice, în special a semnalelor EEG, pentru evaluarea comportamentului uman în medii de risc ridicat. În cadrul infrastructurilor critice, unde deciziile trebuie luate rapid și corect, monitorizarea stărilor cognitive și emoționale ale personalului devine esențială. Această cercetare își propune să contribuie la crearea unor sisteme automate care să poată evalua și interpreta comportamentele umane într-un mod rapid, precis și fiabil, ajutând astfel la îmbunătățirea performanței și siguranței personalului în condiții extreme. În raportul anterior, intitulat *„Analiza și procesarea extinsă a parametrilor fiziologici în evaluarea comportamentului uman”*, s-a realizat o analiză detaliată a procesării semnalelor EEG, concentrându-se pe tehnicile avansate de condiționare și modelare a semnalelor, atât în forme liniare cât și neliniare. De asemenea, au fost abordate provocările legate de zgomot și artefacte, precum și soluțiile de îmbunătățire a calității datelor EEG prin tehnici precum analiza componentelor independente (ICA) și metodele de filtrare adaptivă. Aceste studii au oferit o înțelegere profundă a dinamicii semnalelor EEG și a modului în care acestea pot fi utilizate pentru a evalua comportamentele critice ale personalului în medii de lucru cu risc înalt.

Raportul 4 continuă acest demers, aducând un aport semnificativ în domeniul procesării semnalelor EEG, printr-o abordare mai detaliată a tehnicilor de transformare a semnalelor și analiza frecvenței acestora. Se va pune un accent deosebit pe utilizarea transformatei wavelet (discrete și continue), a funcției ambiguității și a distribuției Wigner-Ville, tehnici esențiale pentru analiza detaliată a semnalelor EEG pe mai multe scale de frecvență. Aceste instrumente permit o reprezentare mai precisă și mai detaliată a semnalelor EEG, esențială pentru captarea schimbărilor subtile în stările cognitive și emoționale ale personalului, care pot fi indicatori ai comportamentelor critice. Mai mult decât atât, raportul 4 va analiza și aplica tehnici avansate de filtrare și eliminare a zgomotului, care sunt esențiale pentru îmbunătățirea calității datelor EEG. Se va explora utilizarea unor metode hibride de filtrare, care combină tehnici tradiționale de procesare cu algoritmi de învățare automată, pentru a îmbunătăți performanța și fiabilitatea sistemelor de evaluare. Aceste tehnici vor ajuta

la reducerea influenței artefactelor și la extragerea de informații relevante din semnalele EEG, care pot fi utilizate ulterior în clasificarea comportamentelor umane.

Așadar, **raportul 4** al tezei reprezintă o continuare logică a cercetărilor din raportul anterior, aprofundând analiza semnalelor EEG prin tehnici avansate de transformare și filtrare. Scopul final al acestei cercetări este de a contribui la dezvoltarea unor sisteme de evaluare automată a comportamentului uman, care să sprijine deciziile rapide și precise ale personalului din infrastructuri critice, într-un mod sigur și eficient. Astfel, acest raport își propune să îmbunătățească tehnologiile existente de monitorizare a comportamentului și să adâncească aplicabilitatea semnalelor EEG în contextul unor medii complexe și riscante.

2. Metode de Prelucrare și Analiză a Semnalelor EEG

Semnalele EEG (electroencefalografice) reprezintă o sursă de informații despre activitatea electrică a creierului, fiind utilizate pentru a evalua stările cognitive și emoționale ale unui individ. Datorită complexității și variabilității acestora, prelucrarea și analiza semnalelor EEG reprezintă un domeniu esențial în cercetarea comportamentului uman, în special în medii critice, unde rapiditatea și precizia sunt cruciale. În acest capitol, vor fi prezentate metodele avansate de prelucrare a semnalelor EEG, care permit extragerea de informații relevante din semnale ce sunt adesea afectate de zgomot și artefacte.

2.1. Transformările Semnalelor EEG şi Analiza Frecvenţei

Dacă semnalele sunt staţionare din punct de vedere statistic este normal să fie caracterizate în domeniul timp sau frecvenţă. Transformările din domeniul frecvenţei al unui semnal de lungime finită poate fi găsită folosind transformări lineare cum sunt: Transformarea Fourier Discretă (DFT), Transformarea Cosinus Discretă (DCT), sau alte transformări semi-optimale, care au miezuri independente ale semnalului. Totuşi, rezultatele acestor transformări pot fi degradate prin pete spectrale datorate ferestrelor de domeniu-timp pe termen scurt ale semnalelor şi miezurilor de transformare fixe. O transformare optimă cum este transpunerea Karhunen–Lo´eve (KLT) necesită informaţii statistice, care pot să nu fie disponibile în practică. Metodele de estimare a spectrului paramentric cum sunt cele bazate pe modelarea AR sau ARMA pot fi îmbunătăţite prin DFT în reprezentarea caracteristicilor domeniului-frecvenţă ale semnalului, dar pot suferi de estimarea deficitară a paramentrilor modelului în principal datorită lungimii limitate a semnalelor măsurate. De exemplu, pentru a modela semnale EEG folosind un model AR, sunt necesare valori exacte ale ordinului şi coeficienţilor de predicţie. Un ordin de predicţie înalt poate rezulta prin divizarea vârfurilor adevărate în spectrul de frecvenţe, iar un ordin de predicţie scăzut rezultă din combinarea vârfurilor aflate în proximitate în domeniul de frecvenţă. Pentru un model AR al semnalului x(n), eroarea sau semnalul conductor este considerat zgomot alb cu mediană zero. De aceea, prin aplicarea Transpunerii Z la ecuaţia 2.1, scăzând indexul de blocaj m, şi înlocuind z cu $e^{j\omega}$ obținem ecuația 2.2.

$$\frac{X_p(\omega)}{E(\omega)} = \frac{1}{1 - \sum_{k=1}^{p} a_k e^{-jk\omega}} \tag{2.1}$$

Unde E(ω) = Kω (constant) este spectrul de putere al zgomotului alb iar $X_p(\omega)$ este folosit pentru a nota spectrul de putere al semnalului. Deci avem ecuația 2.49.

$$X_p(\omega) = \frac{K\omega}{1 - \sum_{k=1}^{p} a_k e^{-jk\omega}} \tag{2.2}$$

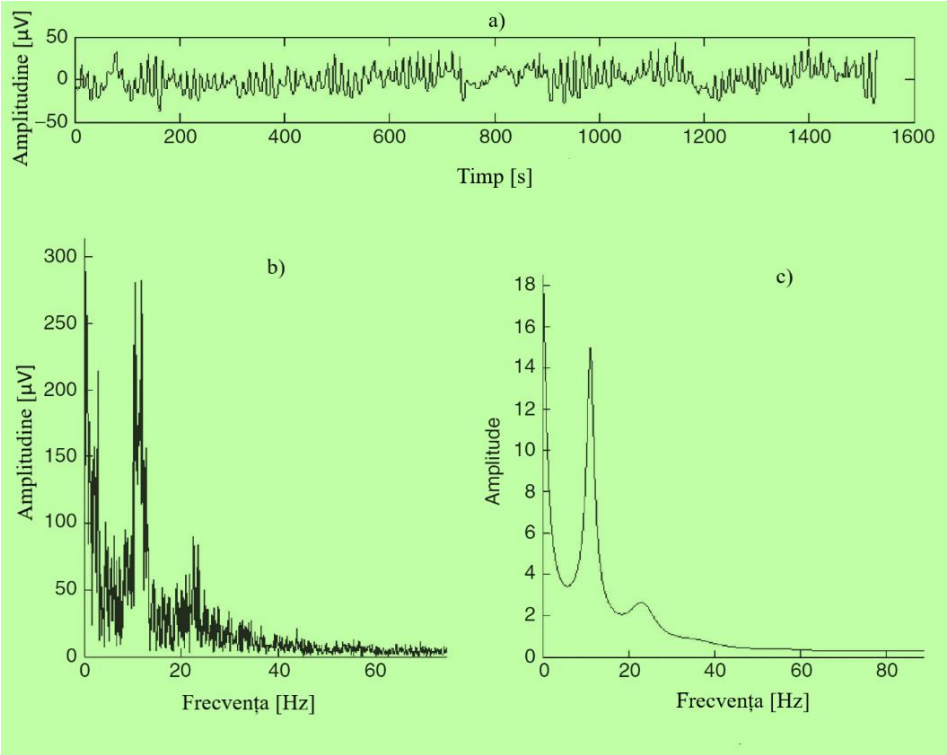


Figura 2.1 Spectru EEG canal unic: (a) un segment al semnalului EEG cu un ritm alfa dominant, (b) spectrul semnalului din (a) folosind DFT, şi (c) spectrul semnalului din (a) folosind modelul AR de 12 ordine

În modelarea AR practică acestea ar fi estimate din măsurătorile lungimilor finite, astfel degradând estimarea spectrului. Figura 2.1 redă o comparaţie a sepctrului unui segment EEG de aprozimativ 1.550 de probe ale unui EEG cu canal unic folosind, atât analiza DFT, cât şi modelarea AR. Fluctuaţiile din rezultatul DFT prezentate în Figura 2.1 (b) sunt o consecinţă a inconsistenței statistice a tehnicilor de estimare spectrală a puterii asemănătoare periodogramei. Rezultatele obţinute prin tehnica AR (Figura 2.1 (c)) depăşesc această problemă, dacă modelul se potriveşte datelor reale. Semnalele EEG sunt adesea nonstaţionare

statistic, mai ales acolo unde este capturat un eveniment anormal în semnale. În aceste cazuri componentele domeniului frecvenţă sunt integrate pe parcursul intervalului de observaţie şi nu prezintă cu acurateţe caracteristicile de intervalului de observaţie. Soluţia acestei probleme este o abordare timp-frecvenţă (TF). În cazul semnalelor EEG pe multicanale, unde poziţia geometrică a electrozilor reflectă dimensiunea spaţială, a devenit obişnuită analiza spaţiu-timp-frecvenţă (STF) prin metode de procesare multimodale. Transformata Fourier de timp scurt (STFT) este definită ca Transformata Fourier de Timp Discretă evaluată pe parcursul unei ferestre de alunecare. STFT poate fi calculat ca în ecuația 2.3.

$$X(n,\omega) = \sum_{r=-\infty}^{\infty} x(\tau)\omega(n-\tau)e^{-j\omega r} \tag{2.3}$$

Unde indicele de timp discret n se referă la poziţia ferestrei ω(n). Prin analogie cu periodograma, o spectrogramă este definită prin ecuația 2.51.

$$S_x(n,\omega) = |X(n,\omega)|^2 \tag{2.4}$$

Pe baza principiului incertitudinii, adică $\sigma_t^2\sigma_\omega^2 \geq \frac{1}{4}$, unde σ_t^2 şi σ_ω^2 sunt varianţele domeniilor timp şi frecvenţă, nu poate fi obţinută o rezoluţie perfectă atât în domeniul timp cât şi în domeniul frecvenţă. Ferestrele sunt alese în mod tipic pentru a elimina discontinuităţile la marginile blocajelor şi pentru a menţine pozitivitatea estimării spectrului de putere. Alegerea are un impact, de asemenea asupra rezoluţiei spectrale a tehnicii rezultante, care, pentru a simplifica, corespunde separării de frecvenţă minime necesare pentru a rezolva două componente de frecvenţă cu amplitudini egale [1][2]. Figura 2.2 corespunde reprezentării TF a unui segment EEG în timpul evoluţiei de la stadiile preictal la cel ictal şi postictal. Astfel, se observă efectul rezoluţiei timpului, folosind o fereastră Hanning cu durate diferite de 1 şi 2 secunde. Este important faptul că în această imagine se observă clar devierea frecvenţei în timpul perioadei ictale.

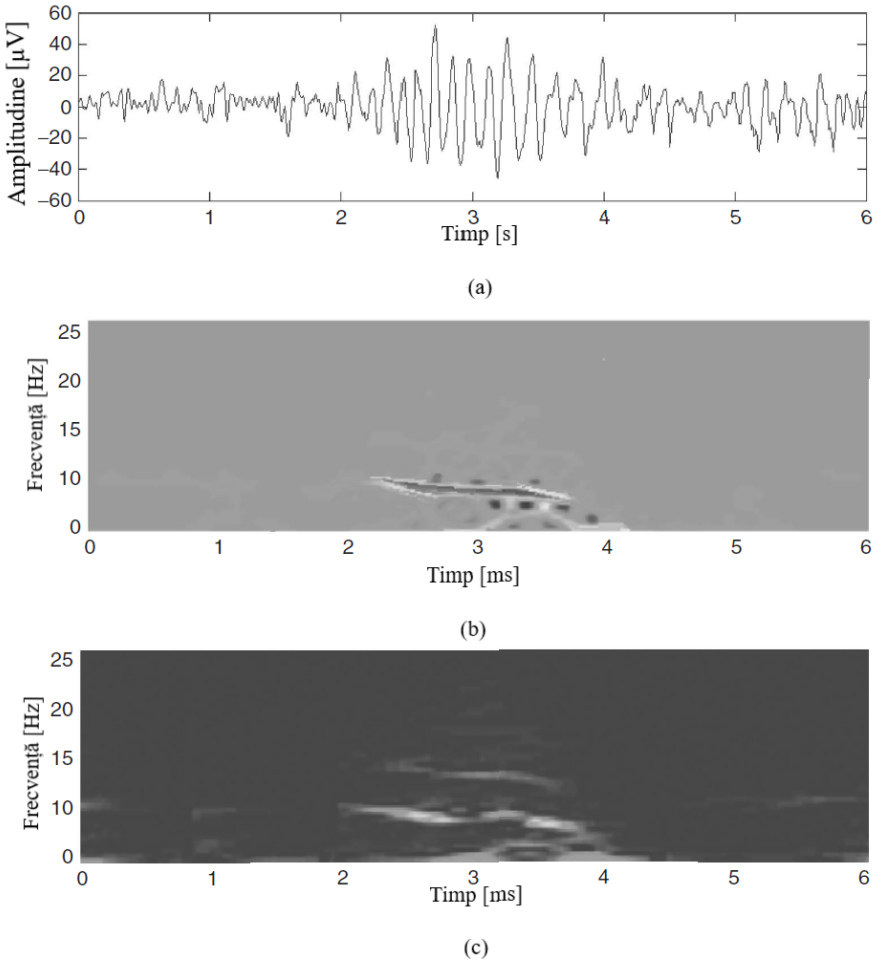


Figura 2.2 Reprezentarea TF a unui segment EEG în timpul evoluției de la stadiile preictal la cel ictal și postictal

2.2. Transformata Wavelet

Transformata Wavelet (WT) este o alternativă de analiză timp-frecvenţă [3][4]. Spre deosebire de STFT, metoda pe bază de WT poate localiza mai bine componentele semnalului în spaţiul timp-frecvenţă. Acest lucru exploatează eficient dependenţa dintre componentele de timp şi frecvenţă. Ca urmare, obiectivul principal al introducerii WT de către Morlet [3] a fost mai aproape de a avea un timp de coerenţă proporţional cu perioada de eşantionare.

2.2.1. Transformata Wavelet Continuă

Definiţia Morlet–Grossmann a transformării undei Wavelet continue pentru un semnal unidimensional f(t) este data de ecuația 2.5.

$$W(a,b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{\infty} f(t) \Psi^* \left(\frac{t-b}{a} \right) dt \quad (2.5)$$

Ψ(t) este unda Wavelet analizată, a (>0) este parametrul de scală (invers proporţional cu frecvenţa), iar b este parametrul de poziţie. Transformarea este lineară şi este invariantă la translaţii şi dilataţii, adică avem:

$$Dacă\ f(t) \rightarrow W(a,b)\ atunci\ f(t-\tau) \rightarrow W(a,b-\tau) \quad (2.6)$$

$$f(\sigma t) \rightarrow \frac{1}{\sqrt{\sigma}} W(\sigma a, \sigma b) \quad (2.7)$$

Ultima proprietate face ca transformarea undei Wavelet să fie foarte potrivită pentru analiza structurilor ierarhice. Este similară unui microscop matematic cu proprietăţi, care nu depind de puterea de mărire. Se consideră, o funcţie W(a, b), care este Transformata Wavelet a unei funcţii date f(t). A fost demonstrat [5][6] că funcția f(t) poate fi aflată conform ecuației 2.5.

$$f(t) = \frac{1}{C_\varphi} \int_0^{\infty} \frac{1}{\sqrt{a}} W(a,b) \varphi \left(\frac{t-b}{a} \right) \frac{dadb}{a^2} \quad (2.8)$$

$$C_\varphi = \int_0^{\infty} \frac{\widehat{\Psi^*}(V) \hat{\varphi}(V)}{V} dV = \int_{-\infty}^{0} \frac{\widehat{\Psi^*}(V) \hat{\varphi}(V)}{V} dV \quad (2.9)$$

Deşi adesea se consideră că Ψ(t) = φ(t), alte alternative ale lui φ(t) pot scoate în evidenţă anumite trăsături pentru unele aplicaţii specifice [7]. Reconstrucţia lui f(t) depinde de definirea lui C_φ (condiţia de admisibilitate). Cazul lui Ψ(t) = φ(t), implică $\widehat{\Psi}(0) = 0$; adică mediana funcţiei undei wavelet este zero.

2.2.2. Exemple de unde wavelet continue

Au fost definite diferite unde pentru Transformatele Wavelet continue. Unda Wavelet a lui Morlet este o formă de undă complexă definită în ecuația 2.10.

$$\Psi(t) = \frac{1}{\sqrt{2\pi}} e^{\frac{-t^2}{2} + j2\pi b_0 t} \tag{2.10}$$

Această undă poate fi descompusă în părţile sale constituente reale şi imaginare ca:

$$\Psi_r(t) = \frac{1}{\sqrt{2\pi}} e^{\frac{-t^2}{2}} \cos(2\pi b_0 t) \tag{2.11}$$

$$\Psi_i(t) = \frac{1}{\sqrt{2\pi}} e^{\frac{-t^2}{2}} \sin(2\pi b_0 t) \tag{2.12}$$

Unde b_0 este o constantă şi se consideră că $b_0 > 0$ pentru a satisface condiţia de admisibilitate. Figura 2.20 prezintă părţile reale şi respectiv imaginare.

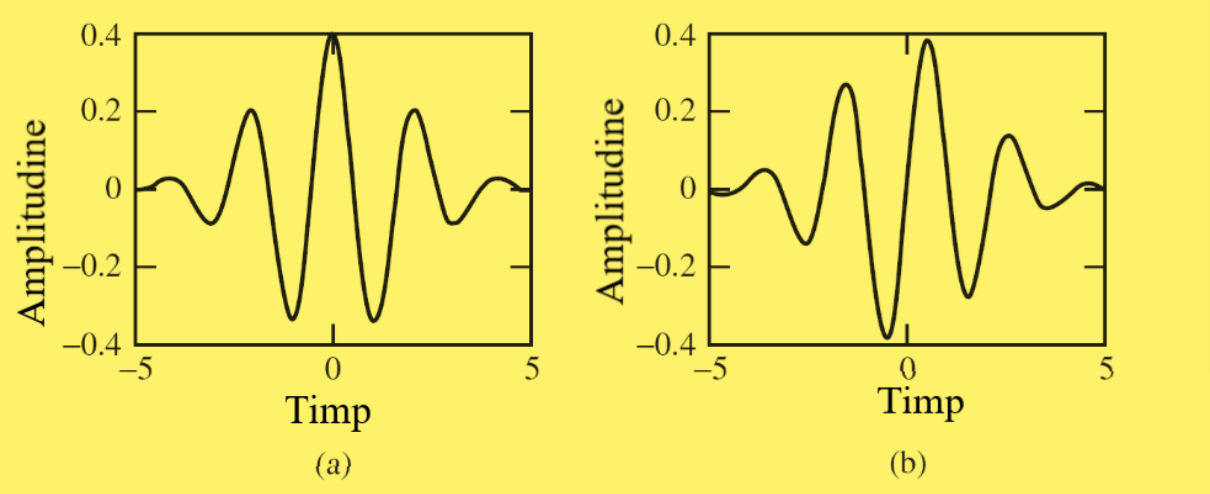


Figura 2.3 Unda scurtă a lui Morlet:părţi (a) reale şi (b) imaginare

Pălăria mexicană definită de Murenzi [7] este descrisă prin ecuația 2.13, fiind a doua derivată a unei unde gaussiene (Figura 2.4).

$$\Psi(t) = (1 - t^2)e^{-0.5t^2} \tag{2.13}$$

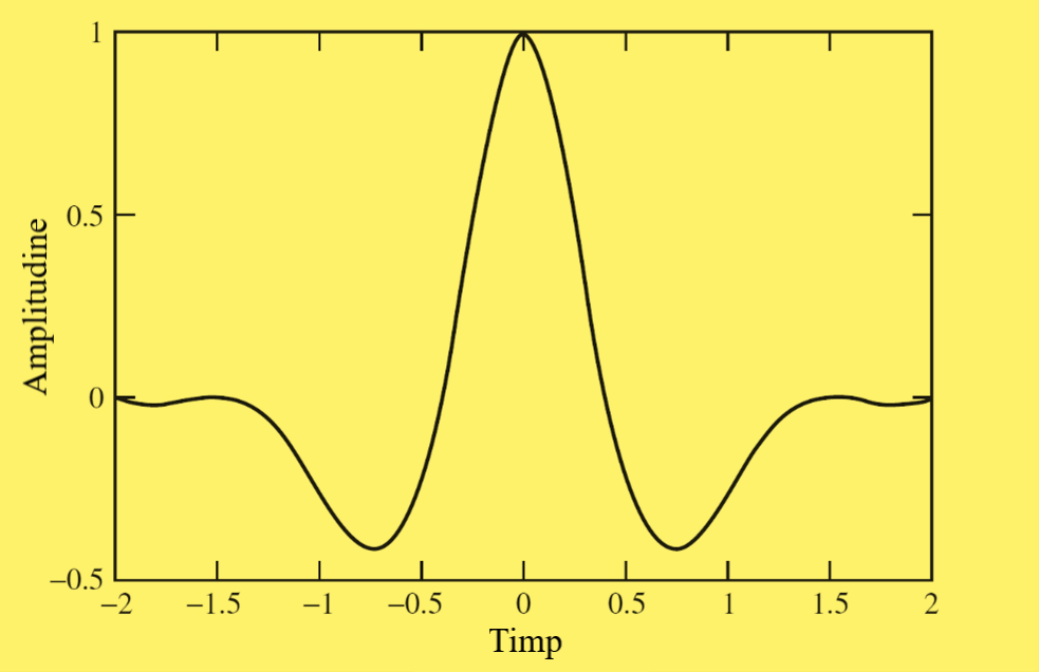


Figura 2.4 Unda scurtă a pălărie mexican

2.2.3. Transformata Wavelet Discretă

Pentru a procesa semnalele digitale este necesară o aproximare discretă a coeficienţilor de undă scurtă. Transformata Wavelet Discretă (DWT) poate fi derivată în conformitate cu teorema eşantionării dacă este procesat un semnal cu bandă-limitată de frecvenţă. Forma continuă a WT poate fi discreditată de unele consideraţii simple asupra modificării tiparului undei scurte prin dilataţie. Întrucât în general funcţia undei Wavelet Ψ(t) nu este în bandă limitată este necesară suprimarea valorilor componentelor de frecvenţă de deasupra jumătăţii de frecvenţă de eşantionare pentru a evita efectele de dublare (suprapunerea în frecvenţă). Un spaţiu Fourier poate fi utilizat pentru a calcula transformata scală-cu-scală. Numărul elementelor pentru o scală poate fi redus dacă este redusă şi lăţimea de bandă a frecvenţei. Aceasta necesită o undă Wavelet de bandă limitată. Descompunerea propusă de Littlewood şi Paley furnizează o ilustrare foarte informativă a reducţiei elementelor scală-cu-scală [8]. Descompunerea este bazată pe o dihotomie de stadiu a benzii de frecvenţă. Unda Wavelet asociată este bine localizată în spaţiul Fourier, unde permite realizare unei analize rezonabile, chiar dacă nu în spaţiul original. Căutarea unei transformate discrete care să fie bine localizată în ambele spaţii conduce la o analiză de multi-rezoluţii.

2.2.4. Analiza de Multirezoluţie

Analiza de multirezolutie rezultă din subsistemele încorporate generate prin interpolaţiile (sau dezeşantionarea şi filtrarea) semnalului la scale diferite. O funcţie f(t) este proiectată la fiecare treaptă j în subsistemul V_j. Această proiecţie este definită prin produsul scalar $C_j(k)$ al lui f(t) cu funcţia de scalare φ(t), care este dilatată şi translatată ca:

$$C_j(k) = \langle f(t), 2^{-j}\phi(2^{-j}t - k)\rangle \tag{2.14}$$

$$\frac{1}{2}\phi\left(\frac{t}{2}\right) = \sum_{n=-\infty}^{\infty} h(n)\phi(t-n) \tag{2.15}$$

În ecuația 2.16 partea dreaptă este convoluţia lui h şi ϕ. Prin luarea transformatei Fourier a ambelor părţi avem:

$$\phi(2\omega) = H(\omega)\,\phi(\omega) \tag{2.16}$$

Unde H(ω) şi $\phi(\omega)$ sunt transformatele Fourier ale lui h(t) şi $\phi(t)$, pentru un spaţiu de frecvenţă discretă, adică folosind DFT ecuaţia 2.17 permite calcularea coeficientului undei Wavelet $C_{j+1}(k)$:

$$C_{j+1}(k) = \sum_{n=-\infty}^{\infty} C_j(n)h(n-2k) \tag{2.17}$$

Unde k este indicele de frecvenţă discretă, iar N este lungimea semnalului. La fiecare treaptă, numărul produselor scalare este împărţit la doi şi în consecinţă semnalul este netezit. Modificând această procedură este construită prima parte a bancului de filtrare. Pentru a restaura datele originale, Mallat foloseşte proprietăţile undelor Wavelet ortogonale, dar teoria a fost generalizată la o clasă largă de filtre prin introducerea a altor două filtre, numite şi filtre conjugate. Restaurarea este realizată cu ajutorul ecuației 2.18.

$$C_j(k) = 2\sum_{l=0}^{\frac{N}{2}-1}[C_{j+1}(l)\tilde{h}(k+2l) + \omega_{j+1}(l)\tilde{g}(k+2l)] \quad (2.18)$$

Unde ω_{j+1} sunt coeficienţii de undă Wavelet. Pentru o restaurare exactă, trebuie să fie satisfăcute două condiţii pentru filtrele conjugate:

Condiţia dedublării:

$$H\left(\omega+\frac{1}{2}\right)\tilde{H}(\omega) + G\left(\omega+\frac{1}{2}\right)\tilde{G}(\omega) = 0 \;\forall\; \omega \quad (2.19)$$

Restaurarea exactă:

$$H(\omega)\tilde{H}(\omega) + G(\omega)\tilde{G}(\omega) = 1 \;\forall\; \omega \quad (2.20)$$

În descompunere, intrarea este înfăşurată succesiv cu formele domeniului de timp ale celor două filtre H (frecvenţe joase) şi G (frecvenţe înalte). Fiecare funcţie ce rezultă este redusă prin suprimarea fiecărei a doua probe. Semnalul de frecvenţă înaltă este lăsat neatins, iar descompunerea continuă cu semnalul de frecvenţă joasă (Figura 2.5). În reconstrucţie, eşantionarea este restaurată prin inserarea unui zero după fiecare probă, sunt aplicate filtrele conjugate $\tilde{H}$ şi $\tilde{G}$, apoi rezultatele sunt adunate, iar suma este multiplicată de 2 ori. Reconstrucţia continuă până la cea mai mică scală (Figura 2.5). Undele scurte ortogonale corespund cazului restrâns în care avem:

$$G(\omega) = e^{-2\pi\omega}\left(\omega+\frac{1}{2}\right) \quad (2.21)$$

$$\tilde{H}(\omega) = H^*(\omega) \quad (2.22)$$

$$\tilde{G}(\omega) = G^*(\omega) \quad (2.23)$$

$$|H(\omega)|^2 + \left|H\left(\omega+\frac{1}{2}\right)\right|^2 = 1 \;\forall\; \omega \quad (2.24)$$

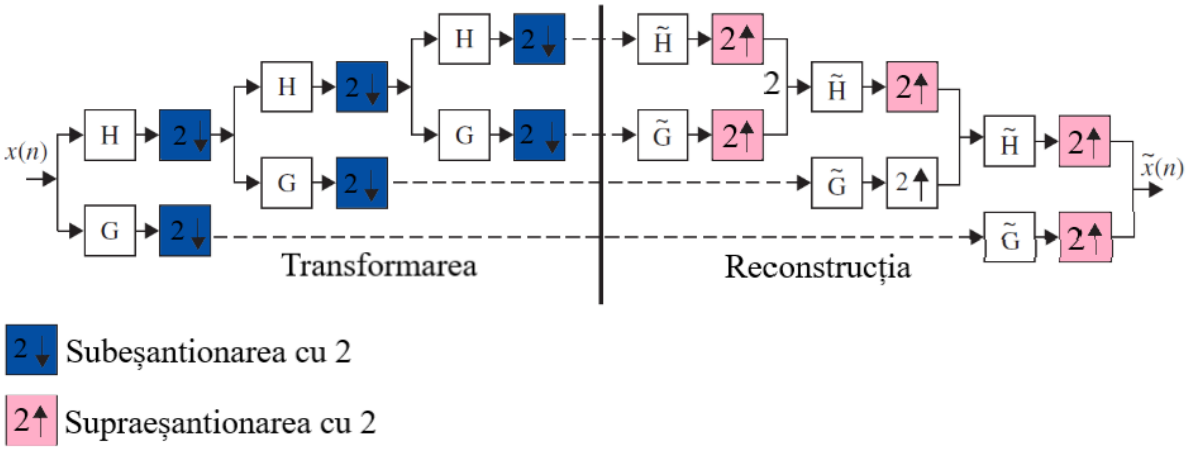


Figura 2.5 Bancul de filtrare asociat cu analiza de rezoluţie multiplă

Se poate observa că acest set satisface cele două relaţii de bază descrise în ecuațiile 2.25 și 2.26. Undele scurte ale lui Daubechie's sunt singurele soluţii compacte care satisfac condiţiile de mai sus. Pentru undele scurte biortogonale, atunci avem:

$$G(\omega) = e^{-2\pi\omega}\tilde{H}^*\left(\omega + \frac{1}{2}\right) \tag{2.25}$$

$$\tilde{G}(\omega) = e^{2\pi\omega}H^*\left(\omega + \frac{1}{2}\right) \tag{2.26}$$

$$H(\omega)\,\tilde{H}(\omega) + H^*\left(\grave{u} + \frac{1}{2}\right)H^*\left(\omega + \frac{1}{2}\right) = 1 \quad \forall\,\omega \tag{2.27}$$

Ecuațiile 2.26 şi 2.27 trebuie să fie şi ele satisfăcute. Pot fi utilizate o categorie mare de funcţii de unde scurte compacte. Au fost propuse multe seturi de filtre, în special pentru encodare. A fost demonstrat că alegerea acestor filtre trebuie să urmărească regularitatea scalării şi funcţiile undelor scurte. Complexitatea este proporţională cu N și atunci algoritmul furnizează o piramidă de N elemente [9].

2.2.5. Transformata Wavelet Utilizând Transformata Fourier

Se consideră produsele scalare $c_0(k) = \langle f(t)\, \varphi(t - k)\rangle$ pentru unde Wavelet continue. Dacă φ(t) este banda limitată la jumătate din frecvenţa eşantionată, datele pot fi eşantionate corect. Datele pentru rezoluţia j = 1 sunt definite în ecuația 2.75:

$$c_1(k) = \left\langle f(t)\, \frac{1}{2}\varphi\left(\frac{t}{2} - k\right)\right\rangle \tag{2.28}$$

Setul $c_1(k)$ poate fi calculat din $c_0(k)$ cu un filtru de timp discret cu frecvenţa răspuns H(ω) ce se regăsește în ecuația 2.76:

$$H(\omega) = \begin{cases} \dfrac{\Phi(2\omega)}{\Phi(\omega)} \text{ dacă } |\omega| < \omega_c \\ 0 \quad \text{dacă } \omega_c \le |\omega| < \dfrac{1}{2} \end{cases} \tag{2.29}$$

$$H(\omega + m) = H(\omega) \tag{2.30}$$

$$C_{j+1}(\omega) = C_j(\omega) H\left(2^j \omega\right) \tag{2.31}$$

Frecvenţa de întrerupere este redusă cu un factor 2 la fiecare treaptă, permiţând reducerea numărului de probe cu acest factor. Coeficienţii de undă Wavelet la scala j + 1 sunt:

$$\omega_{j+1} = \left\langle f(t),\, 2^{-(j+1)} \Psi\left(\, 2^{-(j+1)} t - k\right)\right\rangle \tag{2.32}$$

$$W_{j+1}(\omega) = C_j(\omega) G(2^j \omega) \tag{2.33}$$

Unde G este următorul filtru de timp discret definit în ecuația 2.81:

$$G(\omega) = \begin{cases} \dfrac{\psi(2\omega)}{\Phi(\omega)} \text{ dacă } |\omega| < \omega_c \\ 0 \text{ dacă } \omega_c \le |\omega| < \dfrac{1}{2} \end{cases} \tag{2.34}$$

$$G(\omega + m) = G(\omega) \tag{2.35}$$

Banda de frecvenţă este, de asemenea, redusă cu un factor de doi la fiecare treaptă. Aceste relaţii sunt de asemenea valide pentru DWT.

2.2.6. Reconstrucţia Datelor din Coeficienții de Undă Wavelet

Reconstrucţia datelor din coeficienţii lor de undă wavelet poate fi realizată treaptă-cu-treaptă, pornind de la cea mai joasă rezoluţie. La fiecare scală, avem:

$$C_{j+1} = H(2^j\omega)\, C_j(\omega) \tag{2.36}$$

$$W_{j+1} = G(2^j\omega)\, C_j(\omega) \tag{2.37}$$

$C_j(\omega)$ este restaurat prin minimizarea Exprimată în ecuația 2.85.

$$P_h(2^j\omega)\left|C_{j+1}(\omega) - H(2^j\omega)C_j(\omega)\right|^2 + P_g(2^j\omega)\left|W_{j+1}(\omega) - G(2^j\omega)C_j(\omega)\right|^2 \tag{2.38}$$

Folosind un estimator al de cel-mai-mic pătrat, $P_h(\omega)$ şi $P_g(\omega)$ sunt funcţii ponderale ce permit o soluţie generală pentru restaurarea lui $C_j(\omega)$. Relaţia lui $C_j(\omega)$ este sub formă de:

$$C_j\,(\omega) \;=\; C_{j+1}(\omega)\,\tilde{H}(2^j\omega) \;+\; W_{j+1}(\omega)\,\tilde{G}(2^j\omega) \tag{2.39}$$

Unde filtrele conjugate au expresiile:

$$\tilde{H}(\omega) \;=\; \frac{P_h(\omega)H^*(\omega)}{P_h(\omega)|H(\omega)|^2 \;+\; P_g(\omega)|G(\omega)|^2} \tag{2.40}$$

$$\widetilde{H}(\omega) = \frac{P_g(\omega)G^*(\omega)}{P_h(\omega)|H(\omega)|^2 + P_g(\omega)|G(\omega)|^2} \quad (2.41)$$

Este evident să observăm că aceste filtre satisfact condiţia de reconstrucţie exactă ca în ecuaţia 2.41. De fapt ecuaţiile 2.42 şi 2.43 dau soluţile generale ale acestei ecuaţii. În această analiză condiţia de eşantionare Shannon este respectată întotdeauna. Denominatorul este simplificat dacă:

$$(\omega) = \sqrt{1 - |H(\omega)|^2} \quad (2.42)$$

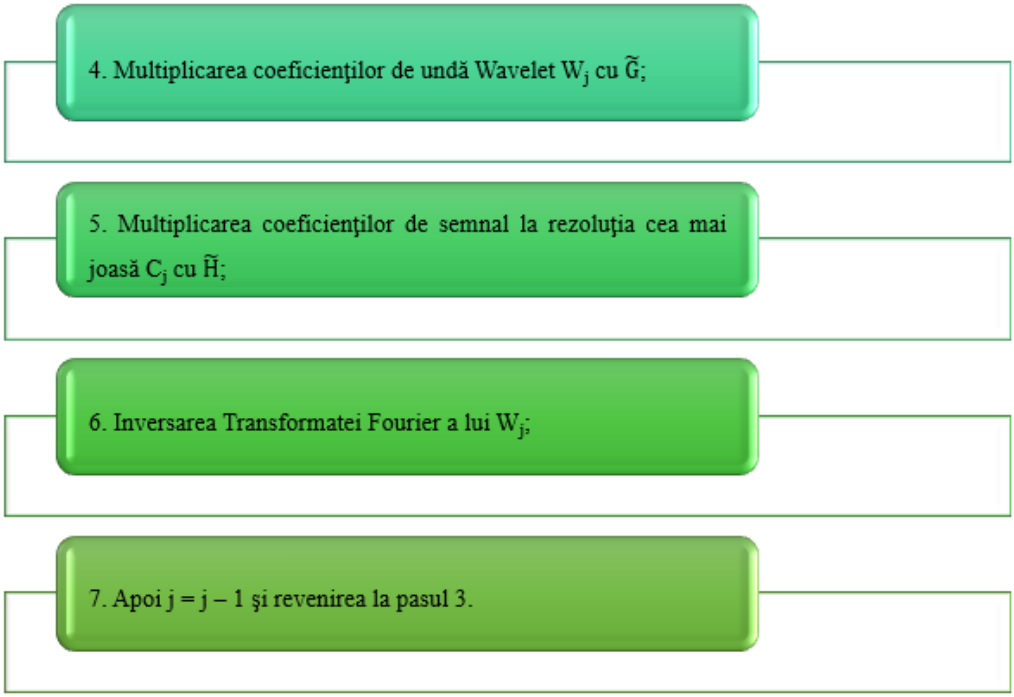
Aceasta corespunde cazului în care unda scurtă este diferenţa dintre pătratele a două rezoluţii:

$$|\psi(2\omega)|^2 = |\Phi(\omega)|^2 - |\Phi(2\omega)|^2 \quad (2.43)$$

Utilizarea unei funcţii de scalare de bandă limitată permite reducţia eşantionării la fiecare scală şi limitează complexitatea calculului. Transformarea undei Wavelet a fost utilizată pe scară largă în analiza semnalului EEG. Aplicarea ei la detectarea atacurilor, în special pentru nou născuţi, modelarea potenţialelor de neuron, şi detectarea potenţialelor eco (EP) şi a potenţialelor de eveniment (ERP) etc.

Algoritmul de reconstrucţie urmează următorii paşii:

1. Calculul Transformatei Fourier Rapide (TFR) a semnalului la rezoluţia joasă;
2. Setarea lui j la np şi realizarea următorilor paşi de iteraţie;
3. Calculul lui TFR al coeficienţilor de undă Wavelet la scala j;



2.2.7. Funcţia Ambiguităţii şi Distribuţia Wigner–Ville

Funcţia ambiguităţii pentru un semnal cu timp continuu este definită în ecuația 2.44. Această funcţie are valoarea sa maximă la origine ca în ecuatia 2.45.

$$A_x(\tau, \nu) = \int_{-\infty}^{\infty} x^* \left(t - \frac{\tau}{2}\right) x\left(t + \frac{\tau}{2}\right) e^{j\nu t}\, dt \tag{2.44}$$

$$A_x(0, 0) = \int_{-\infty}^{\infty} |x(t)|^2\, dt \tag{2.45}$$

De exemplu, un semnal cu timp continuu este considerat format din două semnale modulate cu frecvenţe de purtător cum ar fi cel din ecuația 2.46, atunci funcţia de ambiguitate $A_x(\tau, \nu)$ sub forma descrisă în ecuația 2.47.

$$x(t) = x_1(t) + x_2(t) = s_1(t)e^{j\omega_1 t} + s_2(t)e^{j\omega_2 t} \tag{2.46}$$

$$A_x(\tau, \nu) = A_{x_1}(\tau, \nu) + A_{x_2}(\tau, \nu) + termenii\ de\ intersectare \tag{2.47}$$

Acest concept este foarte important în separarea semnalelor folosind domeniul TF. Figura 2.6 demonstrează acest concept. Distribuţia de frecvenţe Wigner–Ville a unui semnal x(t) este atunci definită ca transformata bidimensională Fourier a funcţiei ambiguităţii:

$$X_{WV}(t,\omega) = \frac{1}{2\pi}\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} A_x(\tau,\nu)e^{-j\nu t}\, e^{-j\omega t}\, d\nu\, d\tau$$
$$= \frac{1}{2\tau}\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} x^*\left(\beta-\frac{\tau}{2}\right) x\left(\beta+\frac{\tau}{2}\right) e^{j\nu(t-\beta)} \quad (2.48)$$

Ceea ce modifică forma duală a funcţiei ambiguităţii ca:

$$X_{WV}(t,\omega) = \int_{-\infty}^{\infty} x^*\left(t-\frac{\tau}{2}\right) x\left(t+\frac{\tau}{2}\right) e^{-j\omega\tau}\, d\tau \quad (2.49)$$

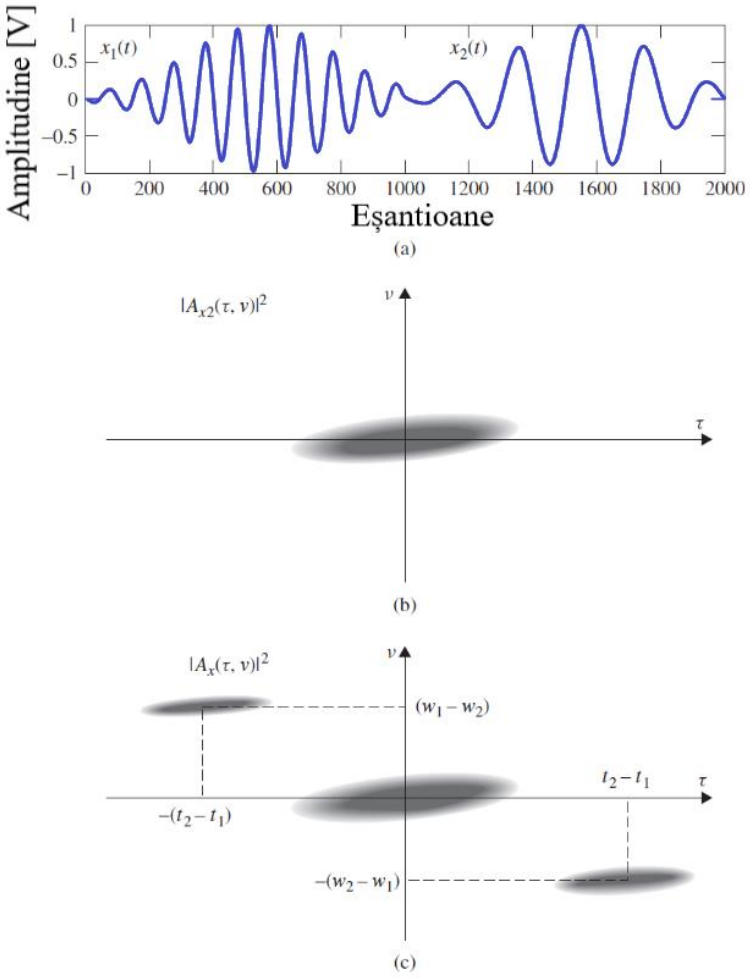


Figura 2.6 a) Un segment al unui semnal constând din două componente modulate, (b) o funcţie de ambiguitate doar pentru $x_1(t)$, şi (c) funcţia de ambiguitate pentru $x(t) = x_1(t) + x_2(t)$

Poate fi deci obţinută o formă pătratică a reprezentării TF cu distribuţia Wigner–Ville folosind semnalul în domeniul de frecvenţă ca în ecuația 2.50.

$$X_{WV}(t,\,\omega) \;=\; \int_{-\infty}^{\infty} X^{*}\left(\omega - \frac{\nu}{2}\right) X\left(\omega + \frac{\nu}{2}\right) e^{-j\nu t}\, d\nu \tag{2.50}$$

Distribuţia Wigner–Ville este reală şi are o rezoluţie foarte bună, atât în domeniul timp, cât şi în domeniul frecvenţă. De asemenea, are proprietăţi de suport de timp şi de frecvenţă, adică, dacă x(t) = 0 pentru |t| > t_0, atunci X_{WV}(t, ω) = 0 pentru |t | > t_0 şi dacă X(ω) = 0 pentru |ω| > ω_0, atunci X_{WV}(t, ω) = 0 pentru |ω| > ω_0. Are de asemenea, condiţii de timp marginal şi de forma ecuației 2.51. Frecvența marginală este descrisă în ecuația 2.53.

$$\frac{1}{2\pi}\int_{-\infty}^{\infty} X_{WV}(t,\,\omega)\, d\omega \;=\; |X(t)|^{2} \tag{2.51}$$

$$\int_{-\infty}^{\infty} X_{WV}(t,\,\omega)\, dt \;=\; |X(\omega)|^{2} \tag{2.52}$$

Dacă x(t) este suma a două semnale x_1(t) şi x_2(t), adică x(t) = x_1(t) + x_2(t), distribuţia Wigner–Ville a lui x(t) faţă de distribuţiile lui x_1(t) şi x_2(t) vor fi definite ca în ecuația 2.53, unde Re arată partea reală a unei valori complexe.

$$X_{WV}(t,\,\omega) = X_{1WV}(t,\,\omega) + X_{2WV}(t,\,\omega) + 2Re[X_{12WV}(t,\,\omega)] \tag{2.53}$$

$$X_{12WV}(t,\,\omega) \;=\; \int_{-\infty}^{\infty} x_1^{*}\left(t - \frac{\tau}{2}\right) x_2\left(t + \frac{\tau}{2}\right) e^{-j\omega\tau}\, d\tau \tag{2.54}$$

O pseudo-distribuţie Wigner–Ville (PDWV) este definită în ecuația 2.55, aplicând funcţia de fereastră, w(τ), centrată la τ = 0 la corelaţiile pe bază de timp:

$$\breve{X}_{WV}(t,\,\omega) \;=\; \int_{-\infty}^{\infty} x^{*}\left(t - \frac{\tau}{2}\right) x\left(t + \frac{\tau}{2}\right) \omega(\tau\,) e^{-j\omega\tau} d\tau \tag{2.55}$$

Pentru a suprima termenii de intersectare nedoriţi distribuţia bi-dimensionala WV poate fi înfăşurată (convolută) cu o fereastră de domeniu TF. Ferastra este un filtru trece-jos

bidimensional, care satisface condiţiile marginale (de incertitudine) de timp şi frecvenţă, cum au fost descrise anterior. Aceasta poate fi calculată ca în ecuația 2.56.

$$C_x\,(t,\,\omega)\;=\;\frac{1}{2\tau}\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}X_{WV}(t',\omega')\Phi(t-t',\,\omega-\omega')\,dt'\,d\omega' \tag{2.56}$$

$$\Phi(t,\omega)\;=\;\frac{1}{2\tau}\int_{-\infty}^{\infty}\int_{-\infty}^{\infty}\varphi(\tau,\,\nu)e^{-j\nu t}\,e^{-j\omega\tau}\,d\nu d\tau \tag{2.57}$$

φ este adesea selectat dintr-un set de semnale bine cunoscute, aşa-numitele clasa lui Cohen. Cel mai popular membru al clasei lui Cohen de funcţii este funcţia în formă de clopot definită ca în ecuația 2.58 [10].

$$\varphi(\tau,\,\nu)\;=\;e^{-\omega^2\tau^2/(4\pi^2\sigma)},\;\sigma>0 \tag{2.58}$$

2.3. Coerenţa, Modelarea Autoregresivă Multivariată (MVAR) şi Funcţia de Transfer direcţionat (DTF)

În unele aplicaţii cum este detectarea şi clasificarea mişcării degetului, este foarte folositor să se stabilească cum se propagă semnalele asociate mişcării prin reţeaua neurală a creierului. Există o mişcare consistentă a semnalelor sursei de la regiunile occipitale la cele temporale. De asemenea, este clar că în timpul sarcinilor mentale diferite regiuni din creier comunică una cu alta. Interacţiunea şi schimbul de informaţii dintre canalele EEG poate fi singurul indiciu pentru înţelegerea acestui proces. Aceasta necesită recunoaşterea perioadelor de tranziţie ale sincronizării dintre diferitele regiuni din creier. Fenomenele nu sunt uşor de observat prin inspecţia vizuală a EEG. De aceea, trebuie să fie folosite tehnici de procesare a semnalelor pentru a realiza asemenea relaţii cauzale. O serie timp se spune că este cauza unei alteia, dacă informaţia conţinută în acea serie timp permite predicţia celeilalte serii de timp. Statisticile spaţiale ale semnalelor EEG de scalp sunt de obicei prezentate ca şi coerenţă în benzi de frecvenţă. Aceste coerenţe rezultă atât din corelaţiile dintre sursele neocorticale şi conducţia de volum prin ţesuturile capului, adică în creier, lichidul cerebrospinal, craniu şi

scalp. De aceea, coerenţa spectrală este o metodă comună de determinarea a sincronicităţii în activitatea EEG [11]. Coerenţa este descrisă în ecuația 2.59.

$$C_{\mathrm{oh}_{\mathrm{ij}}^{2}}(\omega) = \frac{E[C_{\mathrm{ij}}(\omega)|^2]}{E[C_{\mathrm{ii}}(\omega)]E[C_{\mathrm{jj}}(\omega)]} \tag{2.59}$$

Unde $C_{ij}(\omega) = X_i(\omega)X_j^*(\omega)$ este Transformata Fourier a coeficienţilor de cros-corelaţie dintre canalul i şi canalul j al semnalului EEG. Figura 2.7 arată un exemplu de coerenţă cros-spectrală cu circa o secunde înainte de mişcarea degetului. O măsură a acestei coerenţe, cum ar fi o medie în banda de frecvenţă este capabilă să detecteze o sincronizare pe un interval de timp zero şi o sincronizare pe un interval de timp non-zero, care poate apărea când există o întârziere semnificativă între cele două situri de populaţii neuronale. Totuşi, nu furnizează nicio informație cu privire la direcţionalitea cuplării dintre cele două situri [12]. Cauzalitatea Granger (numită şi cauzalitatea Wiener–Granger) [13] este o altă măsură care încearcă să extragă şi să cuantifice direcţionalitatea din EEG. Cauzalitatea Granger se bazează pe estimări AR bivariate ale datelor. Într-un mediu cu canale multiple această cauzalitate este calculată din combinaţiile în perechi ale electrozilor. Această metodă a fost folosită pentur a evalua direcţionalitatea mișcării sursă de la potenţialul de câmp local din sistemul vizual al pisicilor [13]. Pentru date multivariate în înregistrarea multicanal, aplicarea cauzalităţii Granger nu este eficientă din punct de vedere computaţional. Funcţia de transfer direcţionat (DTF), care este o extensie a cauzalităţii Granger este obţinută din datele multicanal şi poate fi folosită pentru detectarea şi cuantificarea direcţiilor de cuplare [14]. Avantajul DTF faţă de coerenţa spectrală este că poate determina direcţionalitatea în cuplare când spectrele de frecvenţă ale celor două regiuni ale creierului au spectre suprapuse. DTF a fost adoptat de unii cercetători pentru a determina direcţionalitatea în cuplare deoarece s-a demonstrat că există un flux direcţionat de informaţie sau schimb de mesaje între senzori în jurul ariei motorii senzoriale înainte de mişcarea degetului [15]–[17].

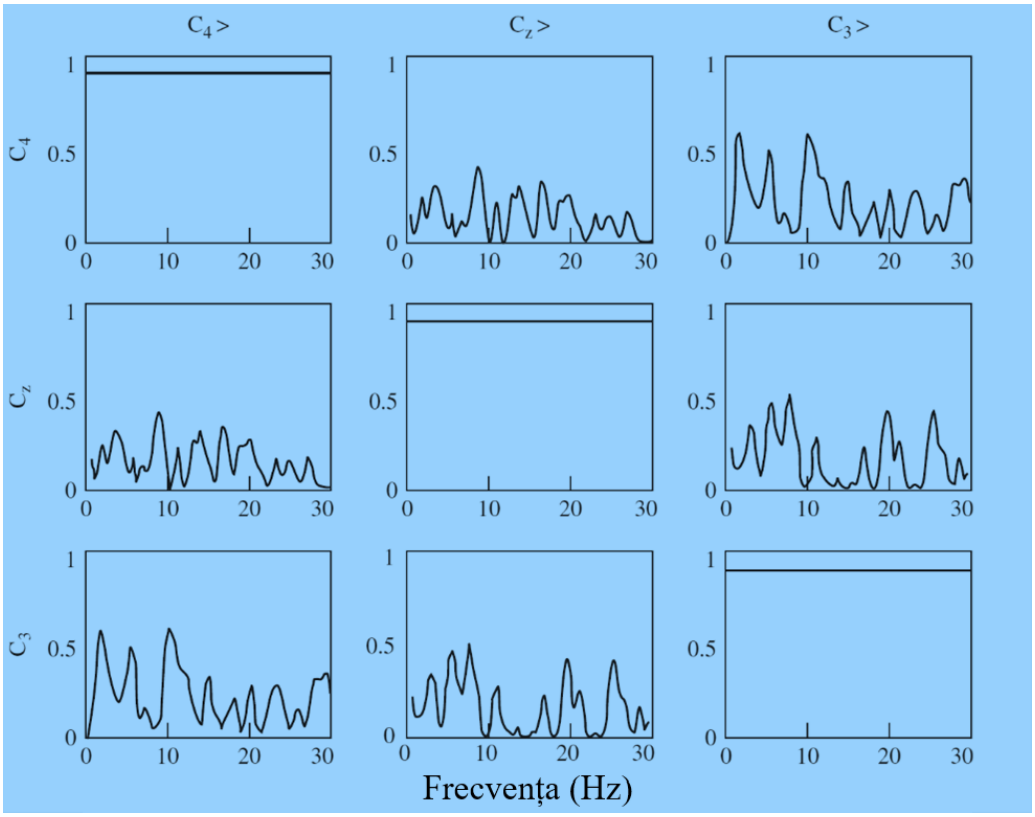


Figura 2.7 Coerenţa cros-spectrală pentru un set de trei electrozi EEG, cu o secundă înainte de mişcarea degetului drept. Fiecare bloc se referă la un electrod.

DTF se bazează pe ajustarea semnalelor EEG la un moel MVAR. Presupunând că x(n) este un semnal EEG de canal M, se poate modela în formă vectorială ca:

$$x(n) = -\sum_{k=1}^{p} L_k x(\mathrm{n}-\mathrm{k}) + v(n) \qquad (2.60)$$

Unde n este indicele de timp discret, p este ordinul de predicţie, ν(n) este zgomotul de meiană-zero iar L_k este în general o matrice de forma M × p a coeficienţilor de predicţie. O metodă similară cu algoritmul Durbin pentru semnale de canal unic şi anume algoritmul Levinson–Wiggins–Robinson (LWR) este folosită pentur calcularea coeficienţilor MVAR [18]. Criteriul Akaike AIC este de asemenea folosit pentru estimarea ordinului de predicţie p. Multiplicând ambele părţi ale equaţiei cu $x^T(n - k)$ şi calculând expectanţa statistică, este obţinută ecuaţia Yule–Walker definită în ecuația 2.61:

$$\sum_{k-0}^{p} L_k R(-k + p) = 0; \qquad L_0 = I \tag{2.61}$$

Unde R(q) = E[x(n)x^T(n + q)] este matricea de covarianţă a lui x(n), şi cros-corelaţiile semnalului şi zgomotului sunt zero deoarece sunt presupuse a fi necorelate. În mod similar, autocorelaţia zgomotului este zero pentru o schimbare non-zero deoarece probele de zgomot nu sunt corelate. Segmentul de date este considerat suficient de îngust pentru ca semnalul să rămână statistic staţionar în acel interval şi destul de larg pentru a permite estimarea cu acurateţe a coeficienţilor de predicţie. Pentru coeficienţii de model MVAR daţi poate fi calculat un spectru multivariat. Aici se presupune că semnalul rezidual v(n), este zgomot alb, ca urmare avem:

$$L_f(\omega)X(\omega) = V(\omega) \tag{2.62}$$

$$L_f(\omega) = \sum_{m=o}^{p} L_m e^{-j\omega m} \tag{2.63}$$

$$X(\omega) = L_f^{-1}(\omega) \times \sigma_V^2 I = H(\omega) \tag{2.64}$$

Ecuația 2.111 reprezintă spectrul model al semnalelor matricei de transfer a sistemului MVAR. DTF sau relaţia cauzală dintre canalul i şi canalul j poate fi definită direct din coeficienţii de transpunere [17] descriși prin ecuația 2.65. Electrodul i este cauzal faţa de j la o frecvenţă f dacă se respectă ecuația 2.66:

$$\Theta_{ij}^2(\omega) = |H_{ij}(\omega)|^2 \tag{2.65}$$

$$\Theta_{ij}^2(\omega) > 0 \tag{2.66}$$

O DTF ce variază cu timpul poate fi de asemenea generată (în principal pentru a urmări semnalele sursă) prin calcularea DTF pentru ferestre scurte ca să se obţină DTF pentru timp sucrt DTF (SDTF) [18]. Ca o importantă trăsătură a clasificării miscărilor degetului stând şi drept, sau a urmăririi surselor legate de sarcina mentală, SDTF joacă un rol important.

2.4. Filtrarea şi Eliminarea Zgomotului din Semnalele EEG

Artefactele de semnal sunt mai semnificative în timpul colectării datelor EEG din sistemele de înregistrare [19][20]. Aceste artefacte pot contamina calitatea datelor EEG. În acest sens, este necesară o cunoaștere cuprinzătoare a tipurilor de artefacte/zgomot pentru a le putea elimina eficient. Artefactele sunt semnale nedorite, care provin în principal din zgomotul din mediul înconjurător, erori experimentale și artefacte fiziologice. Mai mult, artefactele de mediu și eroarea experimentală, care provin din factori externi, sunt clasificate ca artefacte extrinseci, în timp ce cele fiziologice din corpul însuși (de exemplu, clipitul ochilor, activitatea musculară, bătăile inimii) pot fi clasificate ca artefacte intrinseci [21]–[23]. Figura 2.25 prezintă cele trei artefacte fiziologice majore din literatura de specialitate. Artefactele de mediu pot fi eliminate printr-un simplu filtru datorită faptului că frecvența acestor artefacte nu este în concordanță cu semnalele dorite [22]. O procedură și o planificare corespunzătoare pot reduce cu ușurință eroarea experimentală. Cu toate acestea, artefactele fiziologice sunt mai dificil de eliminat deoarece necesită algoritmi specifici [20]. În continuare se vor prezenta principalele artefacte fiziologice care afectează datele EEG.

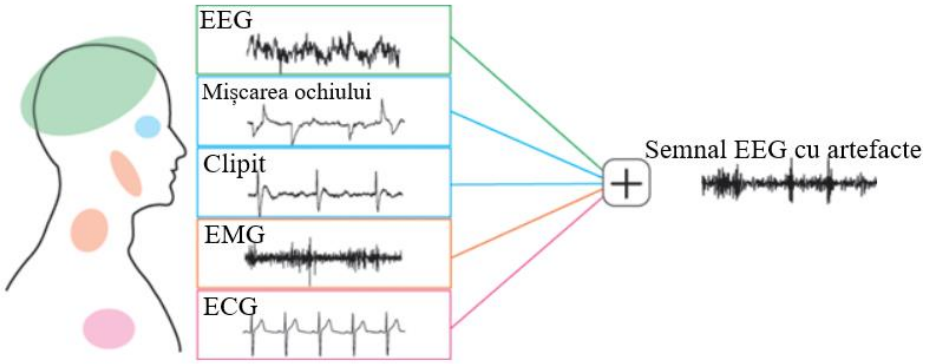


Figura 2.8 Configurația unui semnal EEG observat, care conține rtefacte biologice

2.5. Tipuri de artefacte

2.5.1. Artefacte Oculare

Artefactele oculare generează artefacte semnificative în înregistrările EEG. Originea artefactelor oculare este reprezentată de mișcarea și clipitul ochilor, care se pot propaga pe scalp și pot fi înregistrate de activitatea EEG. Mai exact, artefactele de mișcare oculară se produc prin modificări ale orientării dipolului retinei și al corneei, iar artefactele de clipire sunt

cauzate de conductanța oculară datorată modificărilor contactului corneei cu pleoapa. În plus, din cauza efectului de conducere a volumului, atât artefactul ocular, cât și activitatea EEG se propagă la suprafața capului și sunt înregistrate de electrozi. Astfel de semnale oculare pot fi înregistrate cu ajutorul electrooculogramei (EOG). Amplitudinea EOG este, în general, de multe ori mai mare decât cea a EEG, iar frecvența sa este similară cu frecvența semnalelor EEG. Este demn de remarcat faptul că nu numai datele EEG pot fi contaminate de EOG, dar, la rândul lor, EOG poate fi, de asemenea, contaminată de EEG. În consecință, o interferență bidirecțională va introduce o eroare de eliminare atunci când înlăturăm artefactele EOG [23], [24]–[26].

2.5.2. Artefacte Musculare

Contaminarea datelor EEG de către activitatea musculară este o problemă dificilă deoarece apare de la diferite tipuri de grupuri musculare [27][28]. Aceste artefacte pot fi cauzate de contracția și întinderea oricărui mușchi aflat în apropierea locurilor de înregistrare a semnalului EEG. În teorie, artefactele musculare măsurate prin electromiogramă (EMG) au o distribuție largă de la 0 la > 200 Hz [27]-[30]. Gradul de contracție și de întindere a mușchilor va afecta amplitudinea și forma de undă a artefactelor. Este extrem de dificil să se obțină activitatea dintr-o măsurătoare pe un singur canal în comparație cu EOG și urmărirea ochilor. Prin urmare, artefactele EMG sunt deosebit de dificil de eliminat. În plus, contaminarea EMG și EEG au o independență statistică substanțială una față de cealaltă, atât din punct de vedere temporal, cât și spațial. Acest lucru implică faptul că analiza componentelor independente ar putea fi o metodă adecvată pentru a elimina contaminarea EMG [31].

2.5.3. Artefacte Cardiace

Artefactele cardiace pot fi introduse atunci când electrozii sunt plasați pe sau în apropierea unui vas de sânge, unde mișcarea de expansiune și contracție este datorată inimii. Astfel de artefacte numite artefacte de puls, a căror frecvență este de aproximativ 1,2 Hz, pot apărea în cadrul semnalelor EEG ca o formă de undă similară și atunci este greu de eliminat. Spre deosebire de artefactele datorate pulsului, ECG poate fi măsurat cu un model regulat caracteristic și poate fi înregistrat în afara activității cerebrale, prin urmare, eliminarea acestor artefacte poate fi mai ușoară prin simpla utilizare a unei forme de undă de referință [32].

2.5.4. Artefacte Extrinseci

În plus față de artefactele menționate mai sus, sursele externe de artefacte au, de asemenea, un efect dăunător asupra măsurătorilor semnalelor EEG. Artefactele instrumentale (artefacte extrinseci) provin din poziționarea greșită a electrozilor și din mișcările cablurilor. Aceste artefacte pot fi îndepărtate printr-o procedură și o planificare corespunzătoare. Interferențele electromagnetice emise din mediul înconjurător reprezintă un alt tip de artefacte externe care afectează înregistrările EEG. Astfel de artefacte provenite din surse din mediul înconjurător pot fi ușor degradate printr-un filtru simplu datorită benzii sale de frecvență care se poate distinge. În ciuda benzii largi de frecvență a zgomotului alb, un filtru de înaltă frecvență poate totuși elimina majoritatea artefactelor [33]. Deoarece activitatea unei zone cerebrale poate fi observată în mai multe canale, coerența dintre canalele EEG va introduce artefacte de volum. Literatura relevantă pentru a aborda artefactul de volum poate fi găsită în [34][35].

2.6. Tehnici de Eliminare a Artefactelor

2.6.1. Metode de Regresie

Metoda tradițională de eliminare a artefactelor din semnalele EEG este reprezentată de metodele de regresie. Aceasta se aplică sub ipoteza că fiecare canal este suma cumulativă a datelor EEG pure și a unei proporții de artefacte. Analiza de regresie definește mai întâi relația de amplitudine dintre canalul de referință și canalul EEG prin factori de transmisie, iar apoi scade artefactele estimate din EEG. Astfel, acest algoritm necesită canale de referință exogene (de exemplu, EOG, ECG) pentru a omite diferite artefacte [36]. Atunci când avem de-a face cu activitatea oculară, datele EEG pot fi obținute ca în ecuația 2.67.

$$EEG_{cor} = EEG_{raw} - \gamma F(HEOG) - \delta F(VEOG) \tag{2.67}$$

Unde γ și δ depind de coeficientul de transmisie dintre EOG și EEG, iar EEG_{cor} și EEG_{raw} reprezintă datele EEG corectate și, respectiv, datele EEG brute. HEOG și VEOG desemnează înregistrările din canalele EOG orizontal și vertical. Hillyard și Gallambos [37] au propus pentru prima dată abordări bazate pe regresia în domeniul timpului pentru a elimina activitatea oculară. Whitton [38] a introdus regresia în domeniul frecvenței și a combinat această metodă cu software-ul de detectare EEG. Cu toate acestea, fie în domeniul timpului, fie în domeniul frecvenței, astfel de abordări de regresie sunt afectate de metodele bidirecționale [22]. Acest lucru se datorează faptului că potențialele oculare contaminează datele EEG, iar în mod similar, datele EEG pot contamina înregistrarea oculară. În acest scop, Wallstrom a folosit o filtrare înainte de a aplica tehnici de regresie adaptivă bayesiană [39][40]. Procedând astfel, problemele de contaminare bidirecțională sunt reduse substanțial. Deși modelul simplificat și cerințele computaționale reduse ale metodelor de regresie, necesita unul sau mai multe canale de referință de regresie, acestea limitau capacitatea acestora de a elimina EOG și ECG. Cu toate acestea, în ciuda faptului că cercetările preferă metodele bazate pe separarea oarbă a surselor, algoritmii bazați pe regresie sunt încă standardul de aur pentru a evalua performanța noii abordări.

2.6.2. Transformarea Wavelet

Transformarea Wavelet, care transformă un semnal din domeniul timp în domeniul frecvență, are caracteristici timp-frecvență bune în raport cu transformarea Fourier, datorită unui compromis mai ușor de reglat și a superiorității analizei semnalelor nestaționare [41]. Transformarea se realizează prin selectarea subansamblurilor j și a decalajului temporal k al undei notată cu $\psi(\mathrm{t})$. Din punct de vedere matematic avem ecuația 2.68, unde j și k sunt numere întregi. Apoi, transformarea Wavelet poate fi realizată prin ecuația 2.69, care reprezintă produsul intern al semnalului în domeniul temporal și al funcției Wavelet.

$$\psi_{j,k}(\mathrm{t}) = 2^{\frac{j}{2}}\psi\left(2^{j}\mathrm{t} - \mathrm{k}\right) \tag{2.68}$$

$$W_{\psi} = \langle f, \psi_{j,k} \rangle \tag{2.69}$$

DWT (Transformata Wavelet Discretă) derivată din Transformata Wavelet Continuă și poate fi aplicată atunci când semnalul de intrare/descompunerea pot fi exprimate sunt forma:

$$X_{a,L}[n] = \sum_{k=1}^{N} X_{a-1,L}[2n-k]g[k] \quad (2.70)$$

$$X_{a,H}[n] = \sum_{k=1}^{N} X_{a-1,L}[2n-k]h[k] \quad (2.71)$$

Unde g[k] este filtrul trece-jos pentru a genera componenta de frecvență joasă și h[k] este filtrul trece-sus pentru a obține componenta de frecvență înaltă. După descompunerea datelor EEG cu ajutorul transformării Wavelet, se aplică pragul pentru a elimina semnalul care conține artefacte. Detaliile rămase sunt adunate pentru a reconstrui semnalul curat. Cu toate acestea DWT nu reușește să identifice complet artefactele care se suprapun cu proprietățile spectrale, de aceea în lucrările recente se preferă combinarea DWT cu alte metode, cum ar fi ICA [42].

2.6.3. BSS

Metoda BSS include o varietate de algoritmi de învățare nesupravegheată, fără informații prealabile și canale de referință suplimentare. Metodologia generală a BSS poate fi descrisă după cum urmează. Fie X semnalele observate obținute de la electrozii scalpului. De asemenea, fie S semnalele sursă, care includ semnalele originale și artefactele. Aceste semnale sursă sunt amestecate liniar de o matrice necunoscută A (ecuația 2.72) pentru a obține semnalele observate. Algoritmul BSS este o versiune inversată (ecuația 2.73), unde U este estimarea surselor, iar W este amestecul invers al lui X.

$$X = AS \quad (2.72)$$

$$U = WX \quad (2.73)$$

Apoi, componentele care reprezintă artefactele sunt eliminate, iar componentele rămase reconstruiesc datele EEG pentru a atinge scopul de denaturare. În cele ce urmează, sunt descrise câteva lucrări reprezentative care au adoptat algoritmii BSS.

2.6.4. Analiza Componentelor Principale (PCA)

PCA este una dintre cele mai simple și mai utilizate tehnici BSS, al cărui algoritm se bazează pe valorile Eigen ale matricei de covarianță [43]. În această metodă, mai întâi se convertește variabilele corelate în variabile necorelate folosind transformarea ortogonală. Astfel de variabile necorelate se numesc componente principale (PC). Aceste PC-uri ale semnalelor EEG vor fi implementate utilizând descompunerea valorilor unice (SVD). Berg și Scherg [44] au introdus pentru prima dată analiza componentelor principale pentru a elimina artefactele oculare. În această lucrare, componentele principale care reprezintă clipirile și mișcările oculare erau extrase prin PCA de varianță. Apoi, datele EEG fără artefacte au fost obținute prin respingerea componentelor aferente printr-o operație inversă. Casarotto [98] a demonstrat că PCA are o performanță mai eficientă din punct de vedere computațional decât metodele de regresie liniară. Cu toate acestea, cerința ca componentele artefactelor să fie necorelate cu datele EEG este, în general, greu de îndeplinit. În afară de aceasta, PCA nu reușește să separe interferențele atunci când potențialul de derivă și datele EEG sunt similare. În consecință, în cercetările prezente se preferă alte metode flexibile, cum ar fi ICA.

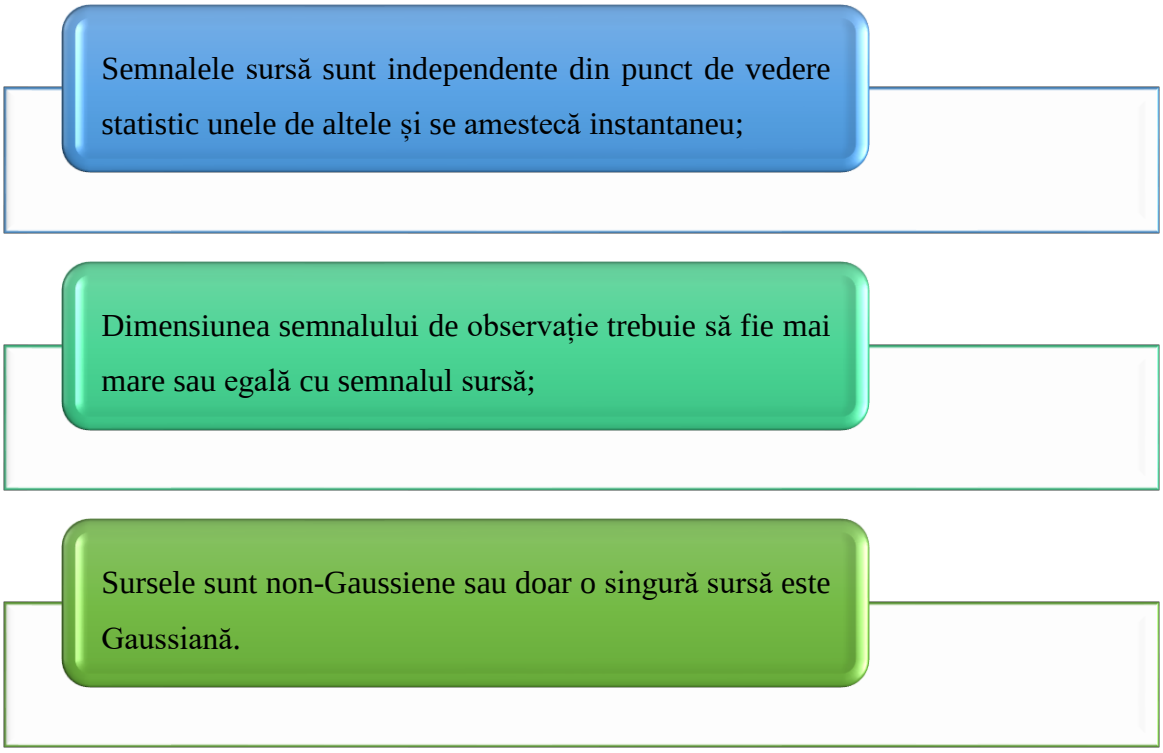
2.6.5. Analiza Componentelor Independente (ICA)

O altă metodă cunoscută sub numele de ICA presupune ca sursele de semnal să fie amestecuri liniare instantanee de surse cerebrale și artefacte [45]. Odată ce componetele independente (IC) sunt extrase din semnalele originale, semnalul curat reconstruit prin eliminarea IC-urilor conținute de artefacte. Având în vedere că metoda simplă a algoritmului de rețea realizată de Bell și Sejnowski oferă o separare oarbă a semnalelor folosind maximizarea informației, Makeig a aplicat pentru prima dată algoritmul ICA pentru a analiza semnalele EEG și EPR [46]. Spre deosebire de abordările tradiționale de anulare a artefactelor, Vigaro a testat metoda ICA pe date simulate și experimentale și a arătat performanțe bune în separarea semnalelor din amestecurile lor liniare și în extragerea informațiilor despre ochi prezente în semnalele EOG [47][48]. În 2000, Jung a eliminat artefactele din EEG prin ICA extins, iar rezultatele se comparau eficient cu algoritmul de regresie [49]. Romero a aplicat ICA pentru a reduce artefactele EEG în diferite stadii de somn și a constatat că proprietatea bidirecțională a EEG și EOG a avut un efect redus asupra ICA [50]. O metodă care utilizează

probabilitatea și metoda statistică de tip kurtosis pentru a elimina semi-automat artefactele din semnalele EEG a fost discutată de Delorme în [51]. Pentru a evita erorile introduse prin selectarea manuală a componentelor, Joyce [52] a introdus o extragere și eliminare automată a artefactelor de mișcare oculară după analiza ICA. În ultimii ani, studiul privind eliminarea automată a artefactelor pe baza ICA a fost dezvoltat de [53]–[58]. Frølich și Dowding au comparat cinci variante de metode ICA utilizate în mod obișnuit, adecvate pentru activitatea oscilatorie.

2.6.6. Analiza corelației canonice (CCA)

Analiza de corelație canonică este o altă tehnică BSS frecvent utilizată. Spre deosebire de metoda ICA, care utilizează statistici de ordin superior, CCA utilizează statistici de ordinul doi, ceea ce înseamnă un timp de calcul mai scurt. De asemenea, CCA diferă de ICA în ceea ce privește condițiile de separare a componentelor. CCA separă componentele din surse necorelate, în timp ce ICA separă componentele din surse independente din punct de vedere statistic [59]. CCA găsește relația liniară între două variabile aleatoare multidimensionale prin maximizarea corelațiilor pe perechi între cele două seturi de date [60]. Spre deosebire de ICA, care ia în considerare doar distribuția statistică a acelorași valori ale eșantioanelor, CCA ia în considerare autocorelația din semnalele sursă și a demonstrat că are rezultate calitative similare, dar consumă din puterea computațională. CCA a fost aplicată pentru a elimina artefactele musculare din semnalele EEG și a fost discutată pentru prima dată în [61]. Datorită formei activității musculare, care nu are o topografie stereotipată, algoritmii CCA sunt mai performanți decât ICA pentru a elimina artefactele musculare. Ca o extensie a PCA, care este constrânsă să transforme direcții ortogonale, ICA s-a dovedit a fi mai eficientă și mai flexibilă în separarea surselor de semnale EEG de artefacte, în conformitate cu următoarele premise:



În general, toate artefactele, cum ar fi mișcările oculare, clipitul ochilor, activitățile cardiace sunt generate de surse independente între ele, iar conducerea volumului este liniară, ceea ce face ca prima premisă să fie rezonabilă. Cu toate acestea, achiziția semnalului biologiv nu este, de obicei, instantanee liniară și, prin urmare, în [62] a fost propusă o abordare ICA convolutivă (CICA), care ia în considerare contribuțiile ponderate și întârziate ale semnalelor. În plus, ICA poate estima semnalele originale care nu sunt gaussiene, dar, din păcate, sursele nu sunt, de obicei, cunoscute ca fiind gaussiene sau non-gaussiene. O altă problemă este că EEG-ul preluat de pe scalp ofera rezultatul activității comune a mai multor neuroni, prin urmare, separarea semnalelor sursă atunci când numărul de surse este mai mare decât numărul de senzori este semnificativă.

2.6.7. Metoda Bazată pe Imagistica Sursei

Imagistica sursei EEG (ESI) este o tehnică bazată pe modelul, care combină componentele temporale și spațiale ale semnalelor EEG pentru a găsi sursa potențialelor înregistrate la nivelul scalpului [63]. Există două probleme fundamentale în ESI: problema directă și cea inversă. Inversarea stratului de dipol distribuit echivalent din înregistrările scalpului este o inversiune liniară, care poate fi rezolvată prin norma minimă (MN). În practica

curentă, sunt utilizate practic diverse regularizări sau soluții MN ponderate [64]. Apoi, sursa echivalentă distribuită din înregistrările EEG poate fi reconstruită, prima componentă este eliminată după analiza PCA, iar componentele rămase pot fi reconstruite în semnalul EEG fără artefacte [65][66].

2.6.8. Descompunerea Empirică a Modurilor

Descompunerea empirică a modurilor (EMD) a fost discutată pentru prima dată în 1998 ca o tehnică euristică pentru procesarea semnalelor nestaționare și neliniare [120]. Algoritmul EMD descompune semnalul x[n] într-un set de componente cu amplitudine-frecvență modulată, b[n], numite funcții de mod intrinsec (IMF) [64][65]. În întregul set de date și în toate punctele, fiecare IMF trebuie să satisfacă faptul că numărul de extreme este același cu numărul de treceri pe zero sau diferă cel mult cu unul, iar valoarea medie a conținutului definit de maxime și minime trebuie să fie zero. Prin urmare, tehnica EMD este o tehnică empirică, bazată pe date, în timp ce alte metode depind de selectarea funcțiilor de bază, cum ar fi analiza Wavelet [66]. Pentru a calcula IMF-ul unor semnale date avem următorii pași descriși în Figura 2.9. Apoi, semnalul original poate fi reconstruit folosind ecuația 2.74.

$$x[n] = \sum_{k=1}^{m} b_k(n) + r(n) \tag{2.74}$$

Unde r(n) reprezintă semnalul rezidual final [66]. Odată ce IMF a fost determinat, componentele artefacte ale datelor EEG pot fi reflectate, apoi selectate și eliminate. În cele din urmă, semnalul EEG pur poate fi reconstruit prin noile IMF-uri. Un dezavantaj al algoritmului EMD este că sensibilitatea zgomotului generează complicații de amestecare a modurilor [67]. În unele cazuri, IMF-urile rămase reconstruite pot fi introduse într-un mediu suplimentar de eliminare a artefactelor pentru a îmbunătăți calitatea datelor EEG [68].

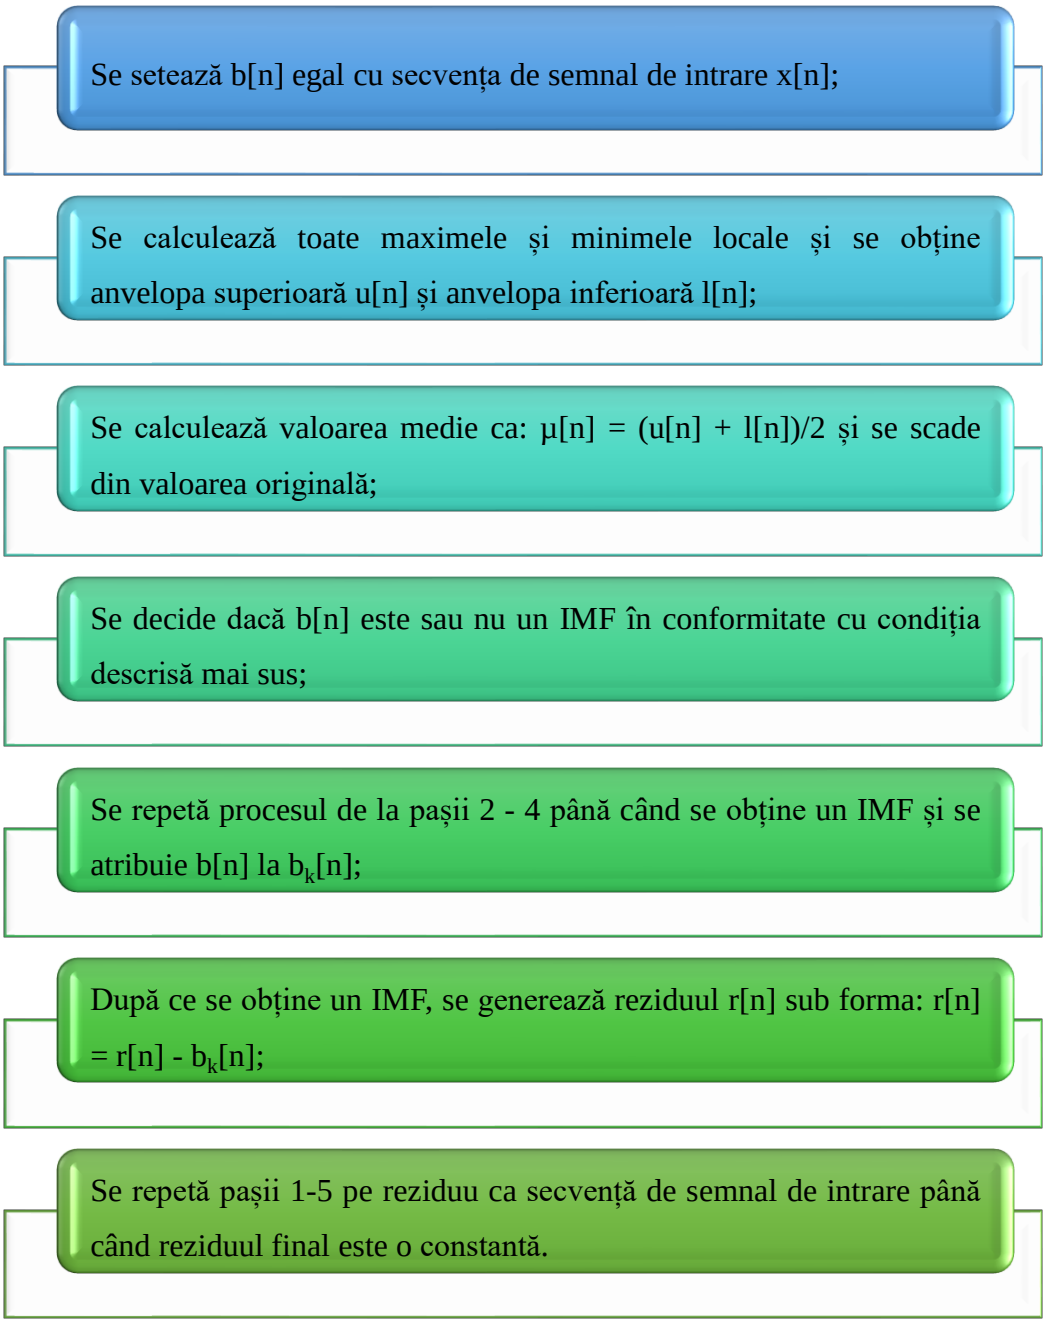


Figura 2.9 Pașii pentru calcularea IMF-urilor

2.6.9. Metode de Filtrare

Numeroase metode de filtrare au fost utilizate pentru eliminarea artefactelor din EEG, de exemplu, filtrarea adaptivă, filtrarea Wiener și filtrarea Bayes, în care diferite metode au fost implementate cu diferite principii de optimizare. Cu toate acestea, pentru a minimiza eroarea pătratică medie între EEG-ul prezis și EEG-ul primar, se va adapta un coeficient de ponderare W.

2.6.9.1. Filtrarea Adaptivă

Mecanismul care stă la baza filtrării adaptive constă în cuantificarea cantității de contaminare artefactuală din intrarea primară, prin ajustarea iterativă a ponderilor în conformitate cu algoritmul de optimizare și scăderea acesteia din semnalele EEG cu artefacte [69]. O ilustrare a filtrării adaptive este prezentată în Figura 2.10. Intrarea primară este modelată ca un amestec de date EEG curate și pure și o sursă de artefacte cu formula descrisă în ecuația 2.75.

$$EEG_{pri}(n) = EEG_{pure}(n) + N(n) \tag{2.75}$$

Unde EEG_{pri} și EEG_{pure} reprezintă semnalul primar și, respectiv, semnalul dorit, iar N reprezintă semnalul de zgomot care este un artefact EOG sau o interferență ECG în funcție de artefactul, care trebuie eliminat.

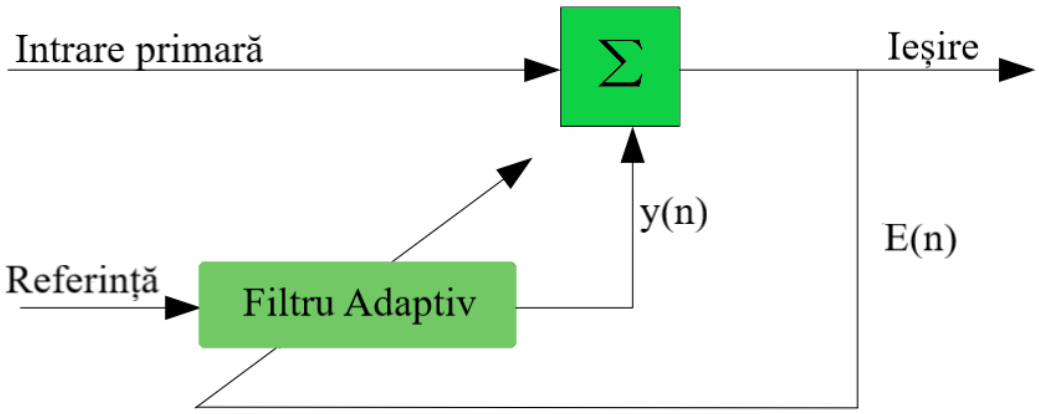


Figura 2.10 Diagrama funcțională a unui sistem de filtrare adaptivă

Canalul de referință este dat ca una dintre intrările în filtru. Pentru a obține semnalul pur, EEGpure se utilizează un algoritm de optimizare, cum ar fi cel mai mic pătrat mediu (LMS) pentru a ajuta filtrul adaptiv să își îmbunătățească parametrul de greutate. Un alt algoritm de optimizare alternativ este algoritmul recursiv al celor mai mici pătrate (RLMS), care converge mai repede decât LMS, dar necesită totuși un cost de calcul ridicat. Dezavantajele sunt că sunt necesari senzori suplimentari pentru a furniza intrări de referință [129][130].

2.6.9.2. Filtrarea Wiener

Filtrarea Wiener este, de asemenea, o filtrare optimă ca și filtrarea adaptivă. Cu toate acestea, tehnica de filtrare Wiener este o tehnică de filtrare statistică liniară utilizată pentru a estima datele EEG reale cu scopul de a dezvolta un filtru liniar invariant în timp pentru a minimiza eroarea medie pătratică între datele EEG pure și semnalul estimat [68]. Filtrul liniar se găsește prin estimarea densităților spectrale de putere ale semnalului măsurat și ale semnalului artefactului, deoarece nu există cunoștințe prealabile privind statisticile [69]. Deși filtrarea Wiener elimină limitarea referinței suplimentare, cerința de calibrare va adăuga complexitatea aplicării sale.

2.6.9.3. Metode de Descompunere Dispersate

Analiza componentelor dispersate (SCA) este o altă metodă de procesare a semnalelor pentru a le descompune în mod dispersat în dicționarul supracomplet [70]. Dicționarul supracomplet poate fi calculat din dicționarul complet prin supraeșantionare. Un dicționar poate fi construit prin forme de undă sau atomi, cum ar fi baza Wavelet, Fourier și Dirac. După supraeșantionare este posibil ca ortogonalitatea să nu fie adevărată, în timp ce bazele din dicționarul complet sunt ortogonale între ele. Dispersia semnalului poate fi măsurată cu l_p ($0 \leq p \leq 1$) astfel:

$$\|x\|_p = \left(\sum_{j=1}^{n} |x_j|^p \right)^{\frac{1}{p}} \tag{2.76}$$

unde x reprezintă semnalul, iar n este dimensiunea lui x [134]. Mallat și Zhang au introdus un algoritm de urmărire a corespondenței (MP), care descompune un semnal în reprezentări dispersate [70]. Descompunerea rarefiată a dicționarului corespunzător semnalului este obținută după mai multe iterații, iar la fiecare iterație se alege o anumită formă de undă cu produsul intern maxim între ea însăși și semnalul rezidual ca fiind cea optimă. O urmărire a corespondenței poate izola structurile de semnal, care sunt coerente în raport cu un dicționar dat. O metodă MP modificată, denumită MP cu două dicționare (TDMP) a fost propusă pentru a descompune semnalul mai puțin dens, iar rezultatele descompunerii certifică faptul că TDMP este superioară MP. În analiza EEG, Li a combinat descompunerea Eigen bazată pe norma L_1

în modele spațiale comune, iar aceasta îmbunătățește în mod eficient robustețea sistemului BCI la valorile aberante EEG. O altă lucrare a dezvoltat o nouă funcție obiect autoregresivă construită în spațiul normei Lp pentru a comprima artefactele în analiza EEG.

2.6.9.4. Metode Hibride

Pe lângă algoritmii concluzionați mai sus, există însă multe metode eficiente și inovatoare. Pentru a exploata avantajul fiecărei metode, recent, mai mulți cercetători au optat pentru utilizarea unei strategii hibride, care reprezintă o combinație a două sau mai multe metode. Câteva dintre principalele metode hibride sunt discutate în cele ce urmează.

2.6.9.5. EMD-BSS

Împreună cu ICA, aceste funcții modale intrinseci (IMF) sunt descompuse de un algoritm EMD sau EEMD. Apoi, aceste IMF-uri sunt transmise ca intrări unui algoritm ICA cu scopul de a estima semnalele sursă. În mod secvențial, reconstruirea noilor IMU-uri se face prin înmulțirea între matricea de amestecare și componentele IC extrase fără artefacte, iar semnalul original poate fi obținut prin însumarea FMI-urilor rămase [71]. Figura 2.11 prezintă schema generală a metodei EMD-BSS.

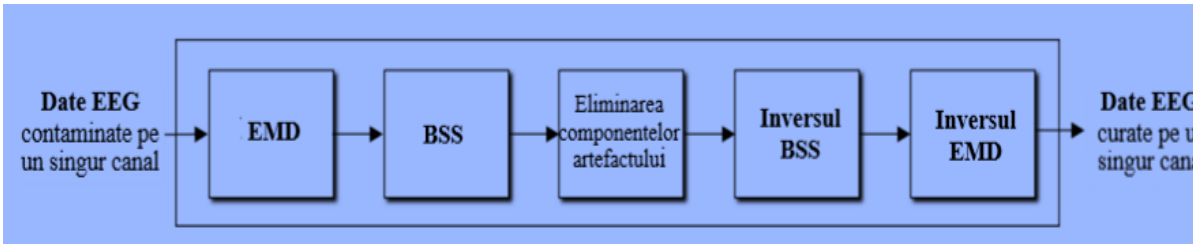


Figura 2.11 Fluxul de proces al metodei EMD-BSS

Studiul EEMD combinat cu ICA pentru a elimina artefactul EMG și artefactul ocular din EEG a fost prezentat pentru prima dată în [72]. În acest articol s-a comparat, de asemenea, acest algoritm cu ICA cu un singur canal și Wavelet - ICA pe semnale EEG reale. Rezultatele arată că algoritmul EEMD-ICA are cea mai bună performanță. Într-o manieră similară cu EEMD-ICA, EEMD-CCA [72]–[74], elimină IMF-urile contaminate și apoi utilizează matricea

de neamestec W, determinată de algoritmul CCA, pentru a reconstrui semnalele sursă [75. O altă metodă a utilizat informațiile de dependență intercanal observate în situațile cu puține canale, prin combinarea descompunerii modale empirice multivariate (MEMD) și CCA [76]. Deși s-a dovedit că MEMD-CCA este unul dintre cele mai promițătoare instrumente pentru eliminarea artefactelor musculare în scenarii cu puține canale, costul de calcul ridicat îl limitează la utilizarea în situații offline.

2.6.9.6. Wavelet-BSS

ICA are o limitare crucială care constă în faptul că numărul de surse trebuie să fie egal cu cel al surselor de măsurare, în timp ce WT nu funcționează atunci când artefactele se suprapun în domeniul spectral. În primul rând, datele EEG înregistrate sunt descompuse prin transformarea Wavelet și apoi rezoluția Wavelet conținută probabil în componentele artefactuale sunt introduse într-un algoritm ICA ales. În cele din urmă, componentele de selectare corupte cu artefacte eliminate și reconstrucția semnalelor EEG fără artefacte se realizează utilizând componentele Wavelet conservate și componentele excluse. Figura 2.29 ilustrează fluxul procesului algoritmilor Wavelet-BSS.

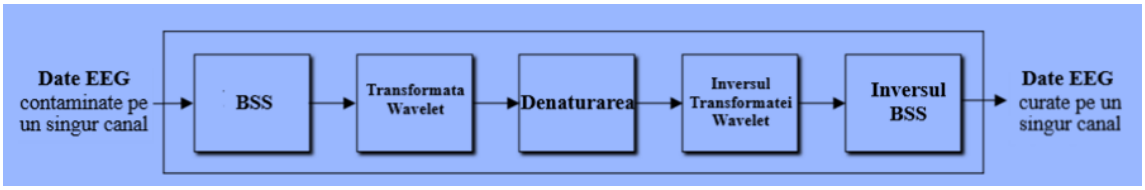


Figura 2.12 Fluxul de proces al metodei BSS-WT

O altă versiune utilizată în mod obișnuit care inversează ordinea ransformării Wavelet și a algoritmului ICA sau CCA. Cu excepția ICA sau CCA, Wavelet poate fi utilizată și împreună cu PCA. În metoda lor, analiza Wavelet descompune semnalele EEG în diferite benzi de frecvență și apoi se aplică PCA pentru a obține noi coeficienți. Metodele convenționale de eliminare a artefactelor liniare netezesc, de obicei, trepidațiile rapide din semnal. Analiza Componentelor Principale pe mai Multe Scări (MSPCA) este o tehnică filtrare neliniară, care păstrează o cantitate substanțială de modificări în înregistrări și oferă performanțe îmbunătățite de eliminare a artefactelor mai mult decât algoritmul PCA simplu [77].

2.6.9.7. BSS și Mașina vectorială de suport

EEG înregistrate sunt descompuse în mai multe componente folosind algoritmi BSS. Apoi, sunt extrase mai multe caracteristici ale componentelor, cum ar fi: caracteristicile temporale, spațiale și statistice. Apoi, caracteristicile sunt utilizate ca intrare pentru un set de clasificatoare SVM liniare pentru a identifica componentele artefactelor. În cele din urmă, componentele rămase sunt utilizate pentru a reconstrui semnale fără artefacte [76]. Figura 2.13 prezintă schema metodei BSS-SVM. Shoker a fuzionat mai întâi BBS și SVM pentru a elimina artefactele de clipire a ochilor. Halder a reintrodus această abordare pentru a clasifica componentele artefactuale în înregistrarea EOG și EMG.

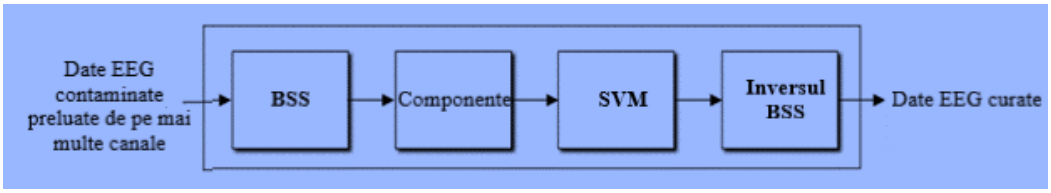


Figura 2.13 Fluxul de proces al metodei BSS-SVM

2.7. Estimarea Parametrilor Semnalelor EEG

În multe aplicaţii cum sunt modelarea, eliminarea zgomotului sau predicţia, unii parametri ai modelelor de semnal trebuie să fie adesea estimaţi. De exemplu, în modelarea AR coeficienţii de predicţie pot fi calculaţi recursiv folosind algoritmul celui mai mic pătrat mediu (CMMPM) ca în ecuația 2.77:

$$a_p(k+1) = a_p(k) - \mu e(k)x(k) \tag{2.77}$$

Unde p este ordinul de predicţie, e este semnalul de eroare (rezidual), iar k este numărul de iteraţie. Acelaşi algoritm poate fi folosit pentru estimarea punctului de intersecţia al unui număr de sfere. Sferele pot fi cele centrate la fiecare elctrod EEG şi raza lor proporţională inversului corelaţiei dintre fiecare componentă independentă estimată (sursă) şi semnaele EEG de scalp. Punctul de intersecţie este atunci legat de localizarea sursei.

2.7.1. Localizarea Sursei EEG

Creierul este împărțit într-un număr mare de regiuni, și fiecare dintre acestea, când sunt active, generează un câmp magnetic local sau curent electric sinaptic. Se poate considera ca activitățile creierului constituie surse de semnal care sunt fie spontane și corespund ritmului normal al creierului, sau sunt legate de mișcările fizice [78]. Localizarea surselor de semnal ale creierului din EEG a fost o arie activă de cercetare în ultimele două decade. O asemenea localizare a surselor este necesar să studieze anomaliile fiziologice, mentale, patologice și funcționale ale creierului, și chiar probleme legate de diferite dizabilități corporale, și, în ultimă instanță să specifice sursele unor anomalii ca tumorile și epilepsia [79]. În acest scop, au fost folosite de asemenea modalitățile de imagistică radiologică. Totuși, aceste tehnici nu pot localiza anomaliile când acestea sunt rezultatul funcționărilor defectuoase. Mai mult, acestea sunt costisitoare și unele pot fi inaccesibile tuturor pacienților la momentul la care sunt necesare.

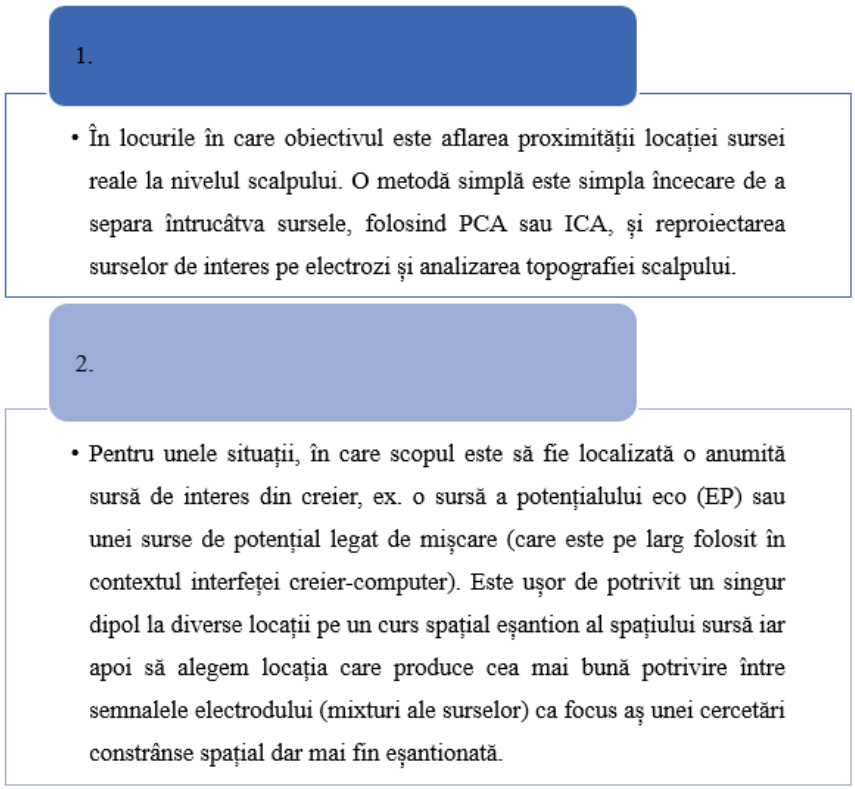


Figura 2.14 Cazurile problemelor simplificate

Recent, fMRI a fost folosită în investigarea anomaliilor funcționale ale creierului cum ar fi epilepsia. Din fMRI, este posibilă detectarea efectului dependenței nivelului de oxigen în sânge (BOLD) în timpul modificărilor metabolice, cum sunt cele cauzate de criza interictală,

sub formă de plasturi albi. Neajunsurile majore ale fMRI, totuși, constau în rezoluția sa temporală slabă și limitările în detectarea detaliilor activităților funcționale și mentale. Drept rezultat, în ciuda limitării de cost pentru această modalitate de imagistică, s-a constatat că în 40-60% dintre cazurile cu activitate interictală în EEG, fMRI nu poate localiza niciun focar sau focare, în special când înregistrarea este simultană cu EEG. Imagistica corticală funcțională și localizarea sursei bazată pe potențialele de scalp necesită o soluție la o problemă inversă prost formulată cu multe soluții posibile. Selectarea unei anumite soluții cere adesea o cunoaștere a priori achiziționat din psihologia generală a creierului și din starea subiectului . Deși în general localizarea surselor creierului este o sarcină dificilă, există unele situații simple în care problema localizării poate fi simplificată și rezolvată sunt exemplificate în Figura 2.14. Problema majoră în acest caz este dacă mediul nu este linear și acest aspect cauzează erori, în special pentru sursele profunde din creier [80][81].

2.7.2. Abordări Generale ale Localizării sursei

Pentru a localiza sursele din creier au fost propuse de cercetători două metode generale, afișate în Figura 2.15.

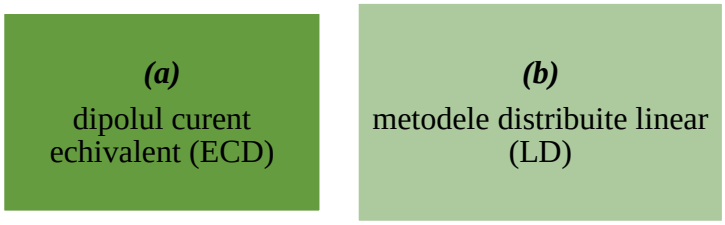


Figura 2.15 Modelele generale de localizare a surselor

În metoda ECD se presupune că semnalele sunt generate de un număr relativ mic de surse focale. În metodele LD sunt luate în considerare simultan toate locațiile surselor posibile [164]. În metodele inverse folosind modelul sursei dipol se consideră sursele ca numere ale dipolilor magnetici discreți localizați în anumite locuri între-un spațiu tridimensional din creier. Dipolii au orientări fixe și amplitudini variabile [82]. Pe de altă parte, în metodele de reconstrucție a sursei distribuite curente, nu este nevoie de nicio cunoaștere a numărului surselor. În general, această problemă este considerată drept o problemă inversă nedeterminată.

O soluție normă L_p este cel mai popular operator de reglare pentru a rezolva această problemă. Această metodă regularizată se bazează pe minimizarea funcției de cost.

$$\psi = \left|\left|\boldsymbol{L_x} - m\right|\right|_p + \lambda\left|\left|\boldsymbol{W_x}\right|\right|_p \quad (2.78)$$

$\boldsymbol{x}$ este vectorul curenților de sursă;

L este matricea câmpului lead;

m sunt măsurătorile EEG;

W este o matrice de ponderare a locației diagonale;

λ este parametrul de reglare;

$1 \leq p \leq 2$, norma, este măsura din spațiul (Banach) în spațiul de vector complet normat.

O normă minimă L_p se referă la criteriul de mai sus când **W** este egal cu matricea de identitate.

2.7.3. Ipoteza de Dipol

Pentru un dipol din locația **L**, câmpul magnetic observat la electrodul i sin locația **R**(i) este obținut așa cum se poate observa în Figura 2.16.

$$\boldsymbol{B}(i) = \frac{\mu}{4\tau}\frac{Q \times (R(i) - L)}{|R(i) - L|} \; pentru \; i = 1, \ldots, n_e \quad (2.79)$$

Q este momentul dipolului;

| . | denotă valoarea absolută;

iar × reprezintă produsul vectorial exterior.

Acesta este frecvent folosit ca model pentru datele magnetoencefalografice observată de magnetometre. Acesta poate fi extins la efectul unui volum ce conține m dipoli la fiecare dintre cei n_e electrozi, așa cum reiese din Figura 2.17.

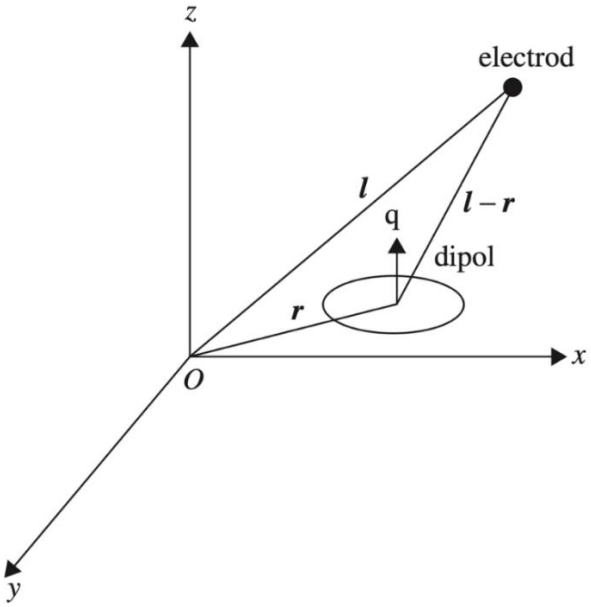


Figura 2.16 Câmpul magnetic B la fiecare electrod este calculat în funcție de momentul dipolului și distanța dintre dipol și electrod

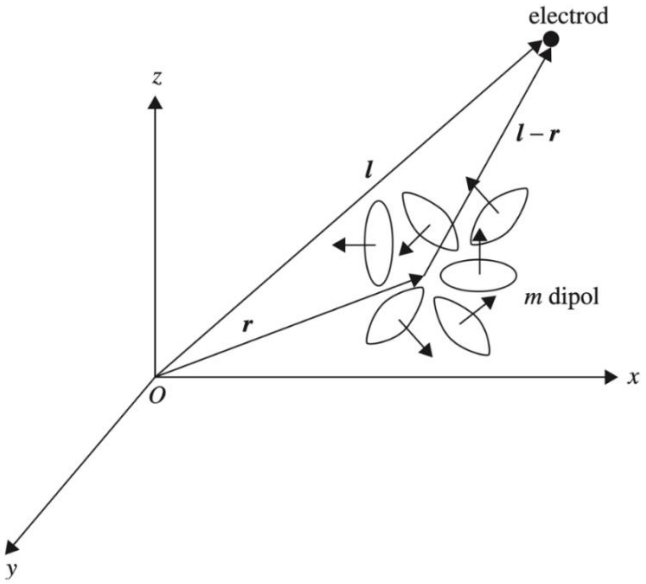


Figura 2.17 Câmpul magnetic B la fiecare electrod este calculat pentru momentele acumulate ale m dipoli și distanța dintre centrul volumului dipolului și electrodului

În cazul a *m*-dipoli câmpul magnetic în punctul *j* este obținută ecuația 2.80.

$$\boldsymbol{BB}(i) = \frac{\mu_0}{4\pi} \sum_{j=1}^{m} \frac{Q_j \times \left(R(i) - L_j\right)}{\left|R(i) - L_j\right|} \; pentru \; i = 1, \dots, n_e \tag{2.80}$$

n_e este numărul de electrozi;

$\mathbf{L}_j$ reprezintă locația celui de-al *j-lea* dipol;

$\mathbf{B} = [B(1), B(2), \ldots, B(n_e)]$, matrice.

Pe de altă parte, momentele dipolului pot fi factorizate în produsul momentelor și puterilor lor de orientare unitară, de exemplu, $\boldsymbol{B} = \boldsymbol{GQ}$ (normalizată în funcție de $\mu_0/4\pi$), unde $\boldsymbol{G} = [\boldsymbol{g}(1), \boldsymbol{g}(2), \ldots, \boldsymbol{g}(m)]$ este mediul de propagare (matricea de mix), iar $\boldsymbol{Q} = [Q1, Q2, \ldots Qm]T$. Vectorul $\boldsymbol{g}(i)$ are dimensiunea 1 × 3 (astfel **G** este *m* × 3). Ca urmare $\boldsymbol{B} = \boldsymbol{GMS}$. **GM** poate fi scris ca o funcție a locației și orientării, cum ar fi **H**(**L**,**M**), și de aceea **B** = **H**(**L**,**M**)**S**. Soluția inițială a acestei probleme folosea o căutare a celor mai mici pătrate care minimizează diferența dintre datele estimate și cele măsurate conform ecuației 2.81, unde **X** este câmpul (potențial) magnetic peste electrozi.

$$J_{ls} = \left|\left|\boldsymbol{X} - \boldsymbol{H}(\boldsymbol{L}, \boldsymbol{M})\boldsymbol{S}\right|\right|_F^2 \tag{2.81}$$

Parametrii de estimat sunt locația, orientarea dipolilor, și magnitudinea pentru fiecare dipol. Aceasta este funcție de cunoașterea numărului de surse (dipoli). Dacă sunt selectați prea puțini dipoli atunci parametrii rezultați sunt influențați de dipolii lipsă. Pe de altă parte, dacă sunt selectați prea mulți dipoli, acuratețea va scădea întrucât unii dintre ei nu sunt surse cerebrale valide. De asemenea, costul calculului este mare datorită unui număr de parametric ce sunt optimizați simultan. Un mod de a depăși acest neajuns este de a converti această problemă într-o problemă de minimizare a proiecției conform ecuației 2.82.

$$\boldsymbol{J}_{ls} = \left|\left|\boldsymbol{X} - \boldsymbol{H}(\boldsymbol{L}, \boldsymbol{M})\boldsymbol{S}\right|\right|_F^2 = \left|\left|\boldsymbol{P}_H^{\perp}\boldsymbol{X}\right|\right|_F^2 \tag{2.82}$$

Matricea $\boldsymbol{P}_H^{\perp}$ proiectează datele în complementul ortogonal al spațiului coloană din **H**(**L**,**M**). **X** poate fi reformulat ca o descompunere de valoare singulară (SVD), ca exemplu **X** = **U**$\boldsymbol{\Sigma}$**V**T. De aceea, reiese ecuațaia 2.83.

$$\boldsymbol{J}_{ls} = \left|\left|\boldsymbol{P}_H^{\perp}\boldsymbol{U}\Sigma\boldsymbol{V}T\right|\right|_F^2 \tag{2.83}$$

În acest caz matricea ortogonală conservă norma Frobenius. Matricea $\mathbf{Z} = \mathbf{U}\boldsymbol{\Sigma}$ este $m \times m$ spre deosebire de $\mathbf{X}$, care este $n_e \times T$, cu T numărul de eșantioane. În general, rangul lui $\mathbf{X}$ satisface ordinul$(\mathbf{X}) \leq m$, $T >> m$, și $\boldsymbol{\Sigma}$ poate avea doar m valori singulare nenule. Aceasta înseamnă că calculul de cost general a fost redus cu o valoare mare. SVD poate de asemenea să fie folosită pentru a reduce calculul de cost pentru $\boldsymbol{P}_H^{\perp} = (\mathbf{I} - \mathbf{H}\mathbf{H}^{\dagger})$. Pseudo inversa $\mathbf{H}^{\dagger}$ poate fi descompusă ca a $\mathbf{V_H}\Sigma_H^{\dagger}\boldsymbol{U}_H^T$, unde $\mathbf{H} = \mathbf{U_H}\,\Sigma_H^{\dagger}\boldsymbol{V}_H^T$. Modelul dipolului, totuși, cere cunoașterea *a priori* a numărului de surse care este în mod obișnuit necunoscut. Multe studii experimentale și experimente clinice au examinat algoritmii de localizare a sursei dezvoltate. Cercetătorii au evaluat diferite metode de localizare a surselor corticale cum este metoda (MDP) a dipolului mișcător, norma L_p minimă, și tomografia de rezoluție joasă (LRT), ca cele pentru LORETA (algoritmul de tomografie electromagnetică de joasă rezoluție) folosind datele EEG simulate și experimentale. În studiul lor, au fost luate în considerație doar potențialele de scalp. În acest studiu, alte metode de localizare a surselor, cum ar fi metoda imagisticii potențialului cortical și metoda vectorului nu au fost incluse. Aceste metode, totuși, folosesc pași similari cu metodele normei minime și respectiv a metodelor dipolului [168].

2.7.4. Metoda ICA

Într-o metodă simplă dezvoltată de cercetători, ICA este folosită pentru a separa sursele EEG. Valorile de corelație a surselor estimate și a mixturilor sunt folosite apoi pentru a construi modelul mediului de amestec. Metoda LS este folosită apoi pentru a găsi sursele folosind inversa acestor corelații, de exemplu $d_{ij} \approx 1/(C_{ij})0.5$, unde d_{ij} arată distanța dintre i și electrodul j, iar C_{ij} arată corelația semnalelor lor. Metoda a fost aplicată pentru a separa și localiza sursa subcomponentelor P3a și P3b pentru cinci subiecți sănătoși și cinci pacienți. Un studiu al componentelor ERP cum sunt P300 și subcomponentele constituente ale acesteia este foarte importante în analiză, diagnostic și monitorizarea tulburărilor mentale și psihiatrice. Locația sursei, amplitudinea, și latența acestor componente trebuie să fie cuantificate și folosite în procesul de clasificare.

2.7.5. Algoritmul MUSIC

Clasificarea semnalelor multiple (Multiple signal classification - MUSIC) a fost folosită pentru a localiza dipolii magnetici din creier utilizând semnale EEG. Într-o formă inițială a acestui algoritm este scanat un model cu un singur dipol într-un volum cranian tridimensional

și sunt calculate proiecțiile într-un subspațiu de semnale estimat. Pentru a localiza sursele, utilizatorul trebuie să caute volumul cranian pentru vârfuri locale multiple în dimensiunea proiecției . Într-o încercare de a evita căutarea exhaustivă prin algoritmul MUSIC a fost dezvoltat un algoritm MUSIC recursiv. Urmând această metodă, sunt automat extrase locațiile surselor dipol rotative sau sincrone, printr-o utilizare recursivă a estimării subspațiului, această metodă încearcă să rezolve problema modului de alegere a locațiilor care dau cele mai bune proiecții pe spațiul semnal (EEG). În absența zgomotului și folosind un model perfect de cap și senzori, modelul de înaintare pentru sursă la locația corectă proiectează în întregime în subspațiul semnal. În practică, totuși, există erori de estimare datorate zgomotului. În găsirea soluției la această problemă sunt formulate două ipoteze care pot să nu fie întotdeauna adevărate: prima, aceea că datele sunt corupte de zgomotul adițional spațial și, a doua, aceea că datele sunt produse de un set de surse dipolare asincrone. Aceste ipoteze sunt îndepărtate în algoritmul MUSIC recursiv propus.

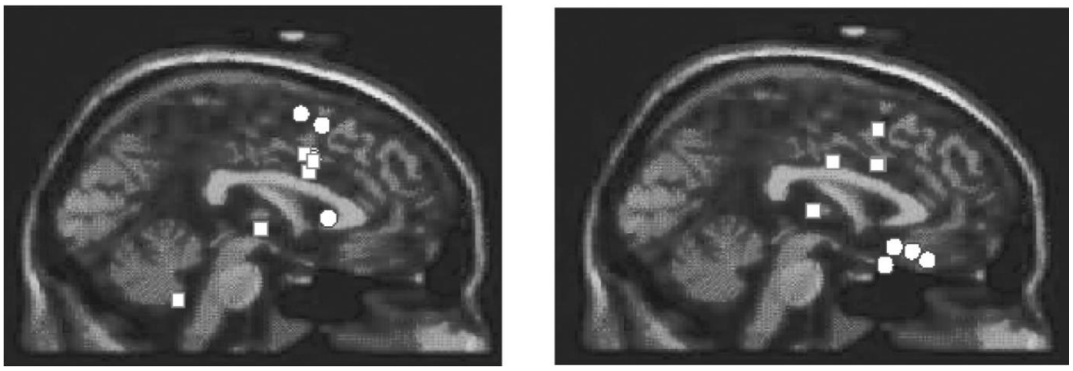


Figura 2.18 Rezultatele localizării pentru (a) pacienții schizofrenici și (b) subiecții normali
Cercurile reprezintă P3a și pătratele reprezintă P3b

Algoritmul MUSIC original pentru estimare surselor cerebrale poate fi descris după cum urmează. Se consideră că modelul cranian de transferare a câmpului dipol la electrozi este $\mathbf{A}(\boldsymbol{\rho}, \boldsymbol{\theta})$, unde $\boldsymbol{\rho}$ și $\boldsymbol{\theta}$ sunt locația dipolului și direcția parametrilor respectivi. Relația dintre observații (EEG), **X**, modelul **A**, și sursele **S** este dat conform ecuației 2.84, unde **E** este matricea zgomotului.

$$\boldsymbol{X} = \boldsymbol{A}\boldsymbol{S}^{T} + \boldsymbol{E} \tag{2.84}$$

Scopul este acela de a estima parametrii $\{\boldsymbol{\rho}, \boldsymbol{\theta}, \mathbf{S}\}$, dat fiind setul de date **X**. Matricea de corelație a lui **X**, de exemplu **Rx**, poate fi descompusă conform ecuației 2.85 sau 2.86.

$$\boldsymbol{X}_F = [\boldsymbol{\Phi}_s, \boldsymbol{\Phi}_e] \begin{bmatrix} \boldsymbol{\Lambda} + n_e \sigma_e^2 \boldsymbol{I} & 0 \\ 0 & n_e \sigma_e^2 \boldsymbol{I} \end{bmatrix} [\boldsymbol{\Phi}_s, \boldsymbol{\Phi}_e]^T \quad (2.85)$$

$$\boldsymbol{R}_X = \boldsymbol{\Phi}_s \boldsymbol{\Lambda}_s \boldsymbol{\Phi}_s^T + \boldsymbol{\Phi}_e \boldsymbol{\Lambda}_e \boldsymbol{\Phi}_e^T \quad (2.86)$$

$\boldsymbol{\Lambda}_s = \boldsymbol{\Lambda} + n_e \sigma_e^2 \boldsymbol{I}$ este matricea diagonală $m \times m$ ce combină atât valorile proprii ale modelului cât și ale zgomotului;

$\Lambda_e = n_e \sigma_e^2 \mathbf{I}$ este matricea diagonală $(n_e - m) \times (n_e - m)$ doar a valorilor proprii ale zgomotului.

Ca urmare, durata subspațiului semnal (Φ_s) și durata subspațiului doar-zgomot (Φ_e) sunt ortogonale. În practică, *T* eșantioanele datelor sunt folosite pentru a estima parametrii de mai sus, de exemplu, ecuația 2.87:

$$\widehat{\boldsymbol{R}}_{\boldsymbol{X}} = \boldsymbol{X}\boldsymbol{X}^T = \widehat{\boldsymbol{\Phi}}_s \widehat{\boldsymbol{\Lambda}}_s \widehat{\boldsymbol{\Phi}}_s^T + \widehat{\boldsymbol{\Phi}}_e \widehat{\boldsymbol{\Lambda}}_e \widehat{\boldsymbol{\Phi}}_e^T \quad (2.87)$$

Unde primii vectori singulari stângi *m* ai descompunerii sunt desemnați ca $\widehat{\Phi}_s$ iar valorile proprii rămase ca $\widehat{\Phi}_e$. Corespunzător, matricea diagonală $\widehat{\Lambda}_s$ conține primele valori proprii *m*, iar $\widehat{\Lambda}_e$ le conține pe cele rămase. Pentru a estima parametrii de mai sus regula generală ce folosește ajustarea celor mai mici pătrate este ecuația 2.88, unde $\| \cdot \|_F$ arată norma Frobenius.

$$\{\widehat{\boldsymbol{\rho}}, \widehat{\boldsymbol{\theta}}, \widehat{\boldsymbol{S}}\} = \arg\min_{\boldsymbol{\rho}, \boldsymbol{\theta}, \boldsymbol{S}} \|\boldsymbol{X} - \boldsymbol{A}(\boldsymbol{\rho}, \boldsymbol{\theta}) \boldsymbol{S}^T\|_F^2 \quad (2.88)$$

$$\{\widehat{\boldsymbol{\rho}}, \widehat{\boldsymbol{\theta}}\} = \arg\min_{\boldsymbol{\rho}, \boldsymbol{\theta}} \left\|\boldsymbol{X} - \boldsymbol{A}\boldsymbol{A}^{\dagger}\boldsymbol{X}\right\|_F^2 \quad (2.89)$$

Unde A† este pseudoinversa Moore–Penrose a lui A. Dat fiind că rangul lui $\mathbf{A}(\boldsymbol{\rho}, \boldsymbol{\theta})$ este *m* iar rangul lui $\widehat{\Phi}_s$ este cel puțin *m*, valoarea de corelație a celui mai mic subspațiu, *Cm* = subcor$\{\mathbf{A}(\boldsymbol{\rho}, \boldsymbol{\theta}), \widehat{\Phi}_s\}_m$, reprezintă corelația de subspațiu minim (unghiul principal maxim) dintre vectorii principali din spațiul coloană a lui $\mathbf{A}(\boldsymbol{\rho}, \boldsymbol{\theta})$ și subspațiul semnal $\widehat{\Phi}_s$. În MUSIC,

corelația subspațiu a unei coloane individuale a lui **A*(ρ, θ)***, cum ar fi de exemplu **a*(ρ$_i$, θ$_i$)*** cu subspațiul semnal trebuie să fie deci egală sau mai mare decât această corelație de subspațiu minimă.

$$C_i = subcorr\{\boldsymbol{a}(\boldsymbol{\rho}_i, \boldsymbol{\theta}_i), \widehat{\boldsymbol{\Phi}}_s\} \geq C_m \quad (2.90)$$

$\widehat{\Phi}_s$ tinde către Φ_s când numărul de eșantioane crește sau SNR devine mai mare. Apoi corelația minimă tinde către unu când este identificat setul corect de parametri, astfel că *m* seturi distincte de parametri ***(ρ$_i$, θ$_i$)*** au corelații de subspațiu ce tind către unu. Ca urmare este urmărită o strategie de căutare pentru a găsi cele *m* vârfuri ale subcorelațiilor metrice.

$$subcorr^2\{\boldsymbol{a}(\boldsymbol{\rho}, \boldsymbol{\theta}), \widehat{\Phi}_s\} = \frac{\boldsymbol{a}^T(\rho, \theta)\widehat{\boldsymbol{\Phi}}_s \widehat{\boldsymbol{\Phi}}_s^T \boldsymbol{a}(\boldsymbol{\rho}, \boldsymbol{\theta})}{\|\boldsymbol{a}^T(\boldsymbol{\rho}, \boldsymbol{\theta})\|_2^2} \quad (2.91)$$

1. Descompunerea lui **X sau XX^T** și selectarea rangului subspațiului semnal pentru abține $\widehat{\boldsymbol{\Phi}}_{\mathbf{s}}$. O ușoară supraspecificare a rangului are un efect minor asupra rezultatului în timp ce nespecificarea lui poate reduce substanțial rezultatul.

2. Din matricea de câștig **G** din fiecare punct (nod) a unei grile dense de locații de surse dipolare și calcularea corelațiilor subspațiului subcorr{**G**(**ρ**$_i$), $\widehat{\boldsymbol{\Phi}}_{\mathbf{s}}$}.

3. Găsirea vârfurilor plotării $\sqrt{1 - C_1^2}$, unde C_1 este corelația subspațiu maximă.

Pentru o estimare perfectă a subspațiului sunt găsite *m* maxime globale egale cu unu. Aceasta necesită căutarea ambelor seturi de parametri ***ρ*** și ***θ***. Într-o metodă cvasiliniară se presupune că **a*(ρ$_i$,θ$_i$)*** =**G*(ρ$_i$θ$_i$)***, unde **G**(.) este numit matricea câștig. Ca urmare, în aplicațiile

localizării surselor EEG sunt găsiți întâi parametrii dipoli $\boldsymbol{\rho}_i$ care maximizează subcorr$\{\mathbf{G}(\boldsymbol{\rho}_i), \widehat{\Phi}_S\}$ iar apoi sunt extrase cvasiliniarele $\boldsymbol{\theta}_i$ corespunzătoare care maximizează corelația subspațiului. Acest mod de calcul evită căutarea explicită a acestor parametri cvasiliniari, reducând complexitatea căutării non-liniare. De aceea, localizarea în general a surselor EEG folosind algoritmul MUSIC clasic poate fi sumarizată în următorii pași de mai jos.

Localizarea a m sau mai puține vârfuri în grilă. La fiecare vârf, rafinarea grile de căutare pentru a îmbunătăți acuratețea locației și verificarea celei de-a doua corelații subspațiu. O a doua corelație subspațiu mare este un indiciu al unui dipol rotativ. Din păcate, sunt înregistrate adesea erori în estimarea subspațiului semnal și corelațiile sunt calculate doar la un set finit de puncte ale grilei. Un algoritm MUSIC recursiv depășește această problemă prin construirea recursivă a modelului topografic independent. În acest model numărul de dipoli este considerat inițial ca fiind unu și căutarea este realizată pentru a localiza un singur dipol. Un al doilea dipol este adăugat apoi și este aflat punctul dipol care maximizează a doua corelație subspațiu, C_2. În această fază nu este necesară recalcularea lui C_1. Numărul de dipoli este mărit și sunt calculate noile corelații subspațiu. Dacă m topografii conțin $m1$ topografii dipolar-singulare și m_2 topografii doi-dipolare, apoi MUSIC recursiv va extrage mai întâi modelele singular-dipolare m_1. La cea de-a $(m_1 + 1)$ reiterare, nu va fi găsită nicio locație unic dipol care corelează bine cu subspațiul. Prin creșterea numărului de elemente dipol la doi, trebuie să fie realizată căutările pentru amândouă simultan astfel că corelația subspațiu este maximizată pentru C_{m1+1}. Procedura continuă să construiască topografiile doi-dipolar m_2 rămase. După aflarea fiecărei perechi de dipoli care maximizează corelația subspațiu corespunzătoare, sunt calculate și corelațiile corespunzătoare. O altă extensie a localizării sursei pe baza MUSIC pentru sursele divers polarizate, și anume aplicate și proiectate recursiv (RAP) MUSIC, folosește fiecare sursă localizată succesiv pentru a forma un colector intermediar al matricei de câștig (similar cu algoritmul MUSIC recursiv) și proiectează atât colectorul de matrice și estimarea subspațiului semnal în complementul său ortogonal. În acest caz subspațiul este redus. Apoi este realizată proiecția MUSIC pentru a găsi următoarea sursă. Această metodă a fost inițial aplicată pentru localizarea magnetoencefalograma (MEG). Într-un studiu recent realizat de cercetători, a fost propus o altă metodă pentru localizarea sursei dipol EEG tridimensională (3D) folosind un algoritm subspațiu nonrecursiv, numit FINES. Metoda folosește proiecțiile pe un subspațiu determinat de un set mic de vectori particulari în spațiul doar-zgomot estimat, în locul întregului subspațiu doar-zgomot estimat ca în cazul lui MUSIC clasic. Subspațiul determinat

prin acest set vectorial este, în sensul unghiului principal, cel mai apropiat subspațiului determinat de colectorul matriceal asociat cu o anumită regiune a creierului. Prin incorporarea cunoașterea colectorului matriceal în identificarea seturilor vectoriale FINES în subspațiul doar-zgomot estimat pentru diferite regiuni cerebrale, această metodă este pretinsă a fi capabilă să estimeze sursele cu o acuratețe sporită și să reducă erorile de estimare. Rezultatele simulării arată că, în comparație cu MUSIC clasic, FINES are o solvabilitate mai bună a două surse dipolare apropiate în spațiu și de asemenea, o acuratețe mai bună a estimării locației sursei. În comparație cu RAP MUSIC, performanța FINES este de asemenea mai bună pentru cazurile studiate când nivelul de zgomot este înalt și/sau corelațiile dintre sursele dipol există. O metodă de utilizare a modelului de craniu generic, în forma unui atlas anatomic, a fost de asemenea propusă pentru a duce la localizarea sursei EEG. Atlasul este ajustat subiectului printr-o deformare flexibilă folosind un set de repere de suprafață. Atlasul deformat este folosit pentru calculul unui model cu elemente definite (FEM) al cartografierii în continuare sau al câmpurilor conductoare intre curenți generatori neurali și electrozii EEG. Aceste câmpuri conductoare sunt folosite pentru a localiza sursele curente din datele EEG ale subiectului iar sursele sunt apoi marcate pe atlasul anatomic. Această metodă furnizează un mecanism pentru compararea localizării surselor la subiecți diferiți, într-un sistem de coordonate bazate pe atlas.

2.7.6. Algoritmul LORETA

Tomografia electromagnetică de joasă rezoluție (LORETA) pentru localizarea surselor cerebrale a fost deja comercializată. În această metodă, potențialele de electrod și matricea X sunt considerate a fi în relația evidențiată în ecuația 2.92.

$$\boldsymbol{X} = \boldsymbol{LS} \tag{2.92}$$

S aste amplitudinea (densitatea) sursei (curente) actuale; **L** este o matrice $n_e \times 3m$ reprezentând coeficienții transmiterii de înaintare din fiecare sursă în matricea senzorilor. **L** a mai fost definit drept miezul răspuns al sistemului sau matricea câmpului conductor. Fiecare coloană **L** conține potențialele observate la electrozi când vectorul sursă are amplitudinea unitate la o locație și orientare și este zero la toate celelalte. Aceasta necesită ca potențialele să fie măsurate linear față de amplitudinile surselor bazate pe principiul superpoziției. În general, aceasta nu este adevărat și ca urmare o asemenea presupunere creează inerent unele erori.

Amplitudinile potrivite ale sursei, $\mathbf{S}_n$, pot fi estimate grosier folosind o căutare exhaustivă prin soluția celor mai mici pătrate inversă (LS), de exemplu ecuația 2.93.

$$\boldsymbol{S}_n = (\boldsymbol{L}^T\boldsymbol{L})^{-1}\boldsymbol{L}^T\boldsymbol{X} \tag{2.93}$$

L poate fi aproximat prin $3m$ simulări ale fluxului de curent din cap, care cere o soluție la bine-cunoscuta ecuație Poisson evidențiată în ecuația 2.94.

$$\nabla . \sigma\nabla\boldsymbol{X} = -\rho \tag{2.94}$$

σ este conductivitatea volumului cranian $(\Omega_{\mathrm{m}})^{-1}$;
ρ este densitatea curentă a volumului de surse $(\mathrm{A/m^3})$.

O metodă de element finit (FEM) sau metoda elementului limită (BEM) este folosită pentru a rezolva această ecuație. În asemenea modele trebuie să fie cunoscute informațiile geometrice despre straturile cerebrale și conductivitățile lor. Dacă nu pot fi folosite unele date cunoscute *a priori* în formulă, modelul analitic este greșit formulat și o soluție unică este greu de realizat. Pe de altă parte, numărul surselor, m, este în mod tipic mult mai mare decât numărul de senzori, n_{e}, iar sistemul din ecuația 2.95 este nedeterminat. De asemenea, în aplicațiile în care trebuie estimate mai multe surse concentrate focal, asemenea metode dau greș. Cum vom vedea mai târziu, în utilizarea unei metode a normei minime, un anumit număr de metode aleg soluția care satisface unele constrângeri, cum ar fi ameliorarea soluției inverse. O metodă este soluția normei minime, care minimizează norma lui S sub constrângerea problemei de înaintare conform ecuației 2.96.

$$\min\left|\left|\boldsymbol{S}\right|\right|_2^2 \; dacă \; \boldsymbol{X} = \boldsymbol{LS} \tag{2.95}$$

cu o soluție precum cea evidențiată în ecuația 2.96.

$$\boldsymbol{S} = \boldsymbol{L}^T(\boldsymbol{L}\boldsymbol{L}^T)^{\dagger}\boldsymbol{X} \tag{2.96}$$

Motivația soluției normei minime este să creeze o soluție împrăștiată cu contribuție zero de la cele mai multe dintre surse. Această metodă are dezavantajul serios al proastei

performanțe de localizare într-un spațiu tridimensional (3D). O variantă a acestei metode este cea a normei minime ponderate (WMN), care compensează lipsa metodei de bază pentru sursele de profunzime, și deci are rezultate mai bune într-un spațiu 3D. În acest caz normele din coloanele lui L sunt normalizate. Ca urmare WMN este formulată în ecuația 2.97.

$$\min\left|\left|\boldsymbol{WS}\right|\right|_2^2 \, dacă \, \boldsymbol{X} = \boldsymbol{LS} \tag{2.97}$$

cu o soluție afișată în ecuația 2.98:

$$\boldsymbol{S} = \boldsymbol{W}^{-1}\boldsymbol{L}^T\left(\boldsymbol{L}\boldsymbol{W}^{-1}\boldsymbol{L}^T\right)^{\dagger}\boldsymbol{X} \tag{2.98}$$

uUnde **W** este o matrice de ponderare cu diagonala $3m \times 3m$, care compensează pentru sursele de profunzime în modul următor din ecuația 2.99.

$$\boldsymbol{W} = diag\left[\frac{1}{\|L_1\|_2}\right], \left[\frac{1}{\|L_2\|_2}\right], \ldots, \left[\frac{1}{\|L_{3m}\|_2}\right] \tag{2.99}$$

$\|\mathbf{L}_i\|_2$ arată norma euclidiană a coloanei de ordinul *i* a lui **L**;

W corespunde inversei distanței dintre surse și electrozi.

Într-o altă metodă similară este folosit un operator de ameliorare laplacian. Acest operator produce o soluție de ameliorare spațială agreând presupunerea fiziologică menționată mai devreme. Funcția care este de interes este atunci ecuatia 2.100.

$$\min\left|\left|\boldsymbol{BWS}\right|\right|_2^2, \qquad dacă \;\; \boldsymbol{X} = \boldsymbol{LS} \tag{2.100}$$

Unde **B** este operatorul Laplacian. Această metodă de normă minimă produce o topografie ameliorată în care vârfurile ce reprezintă locațiile surselor sunt localizate cu acuratețe. Pentru a realiza un model conductor de volum mai realist anatomic a fost folosit în FEM, într-o metodă numită LORETA/FOCUSS standardizată adaptiv (calculatorul de sistem nedeterminat focal) (ALF) [180]. S-a pretins că folosirea acestei metode specifice de aplicare pot fi combinate un număr de soluții de rezolvare diferite ce folosesc intensități diferite ale ochiurilor de plasă pentru a realiza localizarea surselor cu complexități computaționale mai

mici. Inițial, FEM este folosit pentru a aproxima soluțiile ecuației 2.101 cu o reprezentare realistă a volumului conductor bazat pe imaginile de rezonanța magnetică (MR) ale capului uman. Sursele dipolare sunt prezentate folosind metoda aproximației Laplace.

2.7.7. Algoritmul FOCUSS

Algoritmul FOCUSS este o metodă iterativă înalt-rezolutivă WMN care folosește informația din iterațiile anterioare conform ecuației 2.101.

$$\min\left|\left|\boldsymbol{CS}\right|\right|_2^2, \qquad dacă\ \boldsymbol{X} = \boldsymbol{LS} \tag{2.101}$$

Unde $\mathbf{C} = (\mathbf{Q}^{-1})^{\mathrm{T}}\mathbf{Q}^{-1}$ și $\mathbf{Q}_i = \mathbf{W}\mathbf{Q}_{i-1}[\mathrm{diag}(\mathbf{S}_{i-1}(1) \ldots \mathbf{S}_{i-1}(3m)]$, iar soluția pentru iterația i devine așa cum este afișat în ecuația 2.102:

$$\boldsymbol{S}_i = \boldsymbol{Q}_i\boldsymbol{Q}_i^{\boldsymbol{T}}\boldsymbol{L}^T(\boldsymbol{L}\boldsymbol{Q}_i\boldsymbol{Q}_i^T\boldsymbol{L}^T)^{\dagger}\boldsymbol{X} \tag{2.102}$$

Iterațiile se vor opri când nu există schimbare semnificativă în estimare. Rezultatul lui FOCUSS este foarte dependent de inițializarea algoritmului. În practică, algoritmul converge aproape de punctul de inițializare și se poate bloca cu ușurință într-un minim local. S-a sugerat că o inițializare deșteaptă a lui FOCUSS este soluția pentru LORETA.

2.7.8. LORETA Standardizat

O altă opțiune, numită LORETA standardizat (sLORETA), furnizează o soluție unică la problema inversă. Folosește o funcție de cost diferită, care este prezentată în ecuația 2.103:

$$\min[\|\mathbf{X} - \mathbf{LS}\|_2^2 + \lambda\|S\|_2^2] \tag{2.103}$$

Ca urmare, sLORETA folosește regularizarea de ordin zero Tikhonov–Phillips, care furnizează o soluție posibilă la problemele inverse prost formulate, conform ecuației 2.104, unde $\mathbf{s}_i$ indică sursele candidate iar **S** sunt sursele reale.

$$\boldsymbol{s_i} \;=\; \boldsymbol{L_i^T}\left[\boldsymbol{L_i L_i^T} + \boldsymbol{\lambda_i I}\right]^{-1}\boldsymbol{X} \;=\; \boldsymbol{R_i S} \tag{2.104}$$

$\mathbf{R}_i$ este matricea de rezoluție definită ca în ecuația 2.151.

$$\boldsymbol{R_i} \;=\; \boldsymbol{L_i^T}\left[\boldsymbol{L_i L_i^T} + \boldsymbol{\lambda_i I}\right]^{-1}\boldsymbol{L_i} \tag{2.105}$$

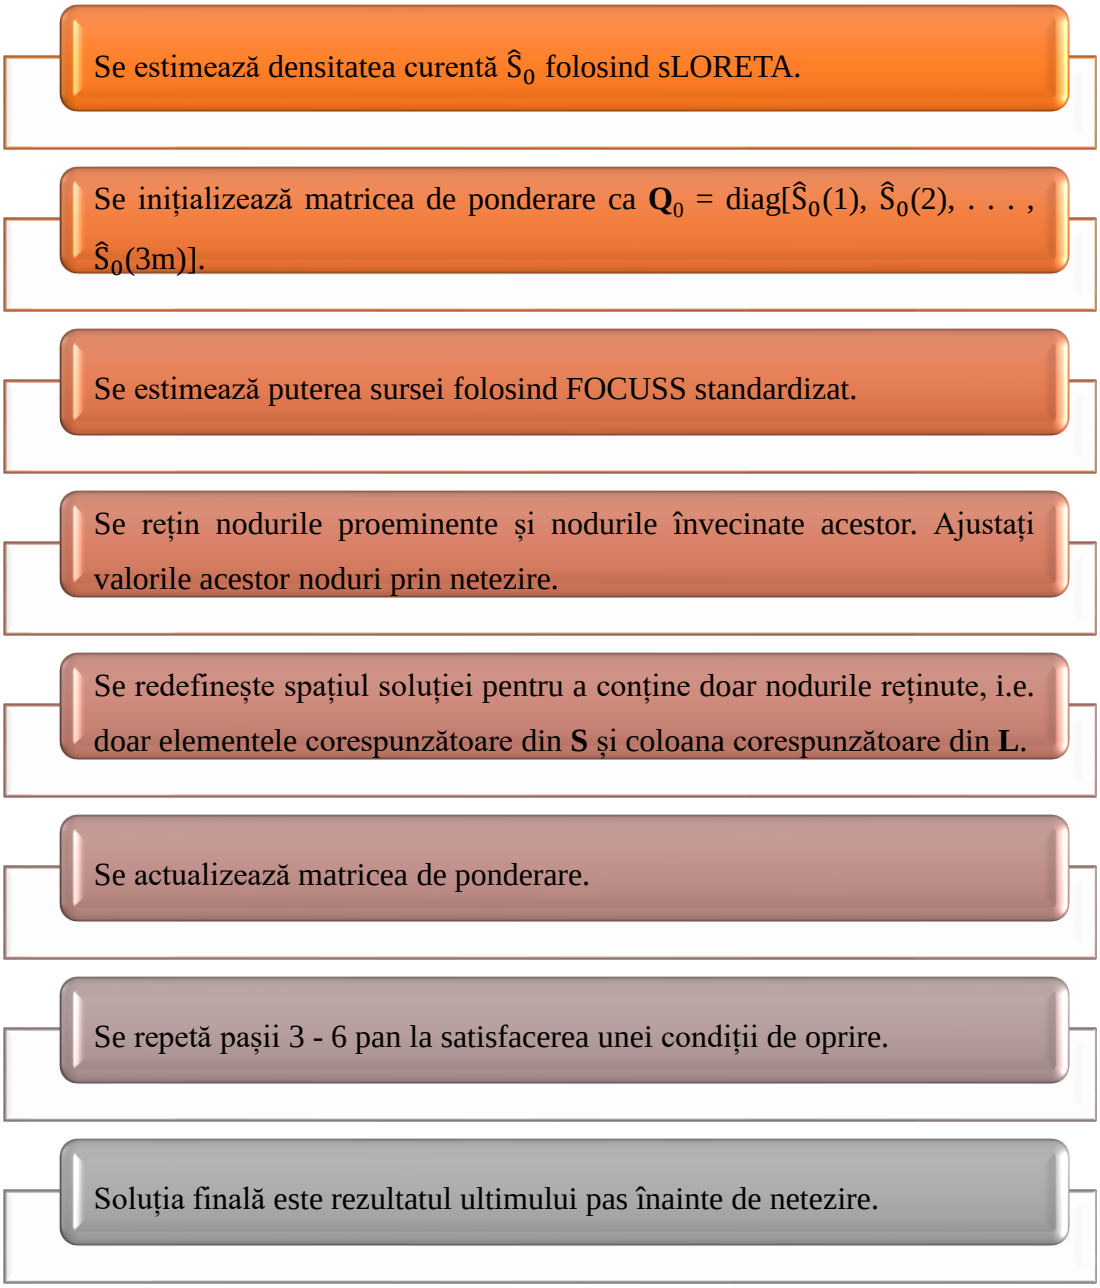
Reconstrucția surselor multiple realizată de iterația finală a lui sLORETA este folosită ca o inițializare pentru algoritmii combinați ALF și norma minimă ponderată (WMN sau FOCUSS). Numărul surselor este redus de fiecare și avem ecuația 2.106, unde $\mathbf{L}_f$ indică câmpul-conductor $n \times m$ final rezultat din sLORETA și $\mathbf{W}_i$ este o matrice de diagonală $3m_f \times 3m_f$, care este rafinată recursiv pe baza densității curente estimate de către Ecuația anterioară.

$$\boldsymbol{s_i} \;=\; \boldsymbol{W_i W_i^T}\,\boldsymbol{L_f^T}\left[\boldsymbol{L_f W_i W_i^T}\,\boldsymbol{L_f^T} + \boldsymbol{\lambda I}\right]^{-1}\boldsymbol{X} \tag{2.106}$$

$$\boldsymbol{W_i} \;=\; diag[s_{i-i}(1), s_{i-1}(2), \ldots, s_{i-1}(3nf)] \tag{2.107}$$

$$\boldsymbol{R_i} \;=\; \boldsymbol{W_i W_i^T}\,\boldsymbol{L_f^T}\left[\boldsymbol{L_f W_i W_i^T}\,\boldsymbol{L_f^T} + \boldsymbol{\lambda I}\right]^{-1}\boldsymbol{L_f} \tag{2.108}$$

Iterațiile sunt continuate până ce soluția nu se mai schimbă semnificativ. Într-o altă metodă dezvoltată, numită LORETA-FOCUSS standard în scădere (SSLOFO), sLORETA este folosită pentru inițializare. Este folosită apoi re-WMN pentru FOCUSS. În timpul procesului rezultatele localizării sunt îmbunătățite în continuare prin folosirea tehnicii de standardizare de mai sus. Algoritmul propus în Referința micșorează spațiul surselor după fiecare iterație a lui FOCUSS, deci reducând încărcătura computațională. Pentru ca algoritmul să nu fie blocat într-un minim local este realizată o operație de netezire. SSLOFO global este sumarizat pentru aceasta în pașii următori:



Condiția de oprire poate fi când este definit un prag sau când nu există schimbare neglijabilă în ponderi în iterațiile următoare.

2.7.9. Alte Soluții ale Normei Minime Ponderate

Într-o metodă LD a fost propusă o metodă a soluției normei minime ponderate (WMN) (sau a regularizării Tikhonov). Soluția a fost regularizată prin impunerea unor informații anatomice și fiziologice asupra funcției de cost globale sub formă de constrângeri. Costurile erorilor pătrate sunt ponderate pe baza proprietăților spațiale și temporale. Informații din

măsurătorile hemodinamice, de exemplu, ale activității creierului din alte modalități imagistice cum ar fi fMRI este sunt folosite ca și constrângeri (sau precedente) împreuna cu funcția cost propusă. În această metodă se presupune că sursele sunt suficient de des distribuite iar sursele sunt orientate ortogonal fața de stratul cortical. Problema localizării sursei EEG instantanee folosind un model linear multivariat și observațiile, **X**, ca potențiale de electrod, este în general formulată pe baza modelului observației din ecuația 2.109.

$$\boldsymbol{X} = \mathfrak{F}(\boldsymbol{r}, \boldsymbol{J}) + \boldsymbol{V} \tag{2.109}$$

X = [$\boldsymbol{x}(1), \boldsymbol{x}(2), \ldots, \boldsymbol{x}(T)$] are dimensiunea $n_e \times T$;

T reprezintă lungimea eșantionului de date iar ne este numărul electrozilor;

$\boldsymbol{r}$ și **J** = [$\boldsymbol{j}_1, \boldsymbol{j}_2, \ldots, \boldsymbol{j}_T$] sunt respectiv locațiile și momentele surselor;

V este matricea zgomotului aditiv;

T este funcția ce leagă sursele de potențialele de electrod.

În calcularea lui T este luat în considerare în mod normal un model potrivit de cap cu trei straturi. O imagine MR structurală a capului poate fi segmentată în trei regiuni izotrope, si anume creierul, craniul, și scalpul, cu aceeași conectivitate și pot fi folosite ca model. Cele mai multe modele consideră capul drept o sferă pentru simplificare. Totuși, în anumite cercetări, sursele EEG sunt modelate printr-o rețea tri-dimensională fixă și uniformă de dipoli curenți împrăștiați în întregul volum al creierului. De asemenea, problema este o problemă lineară nedeterminată ca ecuația 2.110, unde **L** este o matrice a câmpului-cap, care interelaționează dipolii cu potențialele de electrod.

$$\boldsymbol{X} = \boldsymbol{LJ} + \boldsymbol{V} \tag{2.110}$$

Pentru a obține o soluție unică pentru ecuația nedeterminată de mai sus trebuie să fie impuse unele constrângeri. Metoda de regularizare propusă constrânge distribuția surselor reconstruite prin minimizarea împreuna a unui amestec linear al unor norme ponderate $\|\mathbf{H}_j\|_2$ ale surselor curente $\boldsymbol{j}$ și funcția cost principală a soluției inverse. Presupunând că zgomotul este gaussian cu matricea covarianței $\mathbf{C}_v$ atunci este rezultată ecuația 2.111, unde multiplicataroul Lagrange λ trebuie ajustat pentru a realiza un echilibru între principala funcție cost și constrângerea $\|\mathbf{H}\boldsymbol{j}\|_2$.

$$\hat{J} = \arg\min_{j} \left[\left\| \boldsymbol{C_v^{-\frac{1}{2}}} (\boldsymbol{Lj} - \boldsymbol{x}) \right\|_2^2 + \boldsymbol{\lambda^2} \|\boldsymbol{Hj}\|_2^2 \right] \quad \textbf{(2.111)}$$

Matricea covarianței este scalată astfel încât urma *(*$\mathbf{C}_v$*)*=ordinul*(*$\mathbf{C}_v$*)* (va reamintiți că urma unei matrice este suma elementelor sale diagonale iar rangul unei matrice se referă la numărul de coloane independente (rânduri)). Aceasta se poate pune ca o problemă a celor mai mici pătrate supradeterminată. Soluția la minimizarea ecuația 2.112 pentru o $\boldsymbol{\lambda}$ dată este de forma:

$$\hat{j} = \boldsymbol{BX} \quad \textbf{(2.112)}$$

$$\boldsymbol{B} = [\boldsymbol{L^T C_v^{-1} L} + \boldsymbol{\lambda^2}(\boldsymbol{H^T H})]^{-1} \boldsymbol{L^T C_v^{-1}} = [(\boldsymbol{H^T H})]^{-1} \boldsymbol{L^T} [\boldsymbol{L}(\boldsymbol{H^T H})^{-1} \boldsymbol{L^T} + \boldsymbol{\lambda^2 C_v}]^{-1} \quad \textbf{(2.113)}$$

Aceste ecuații descriu soluția normei minim ponderate (WMN) la problema localizării. Totuși, aceasta nu este completă decât dacă este impusă o constrângere spațială sau temporală potrivită. Teoretic, orice număr de constrângeri pot fi adăugate la funcția de cost principală în același fel și hiperparametrii ca multiplicatorii Lagrange, $\boldsymbol{\lambda}$, pot fi calculați prin maximizarea expectației. Totuși, trebuie să fie implicate mai multe ipoteze, cum sunt cele despre covarianța surselor , pentru a găsi efectiv pe **L**, care include informații despre localizări și dipoli. O ipoteză, de forma unei constrângeri, poate fi bazată pe faptul că [diag*(*$\mathbf{L}^T\mathbf{L}$*)*$]^{-1}$, care este proporțional cu componentele covarianței, poate fi normalizată. O altă constrângere este bazată pe informația fMRI spațială care apare ca dependența nivelului de oxigenare a sângelui (BOLD) când sursele sunt active. Răspunsurile eco pot fi de asemenea constrângeri temporale.

2.7.10. Indici de Evaluare

Acuratețea soluției inverse folosind datele EEG simulate a fost evaluată prin trei indici:

(1) distanța erorii (ED), de exemplu distanța dintre locațiile reale și estimate ale surselor;

(2) procentul numărului de surse nedetectate (USP);

(3) procentul numărului de surse fals detectate FSP.

Evident, aceste cuantificări sunt bazate pe modele și date simulate. Pentru date EEG reale este greu de cuantificat și evaluat rezultatele obținute prin diferite metode inverse. ED dintre locațiile estimate ale surselor, $\tilde{s}$, și locațiile reale ale surselor, $\boldsymbol{s}$, este definit conform ecuației 2.114:

$$ED = \frac{1}{N_d}\sum_{i=1}^{N_d} \min_j\left(\left\|\tilde{s}_i - \boldsymbol{s}_j\right\|\right) + \frac{1}{N_{ud}}\sum_{j=1}^{N_{ud}} \min_i\left(\left\|\tilde{s}_i - \boldsymbol{s}_j\right\|_2\right) \quad (2.114)$$

i și j sunt indicii locațiilor surselor estimate și reale;

N_i și N_j sunt numerele totale de surse estimate și nedetectate.

USP și FSP sunt definite respectiv ca USP = $N_{un}/N_{real} \times 100\%$ și FSP = $N_{fals}/N_{estimat} \times 100\%$

N_{un}, N_{real}, N_{fals}, și $N_{estimat}$ sunt numerele surselor reale și estimate, fals detectate și nedetectate.

În practică pot fi folosite trei tipuri de modele de conductori de volum al capului : un model de conductor de volum al capului sferic, o model (BEM) bazat pe metoda elementului de graniță, sau un model (FEM) bazat pe metoda elementului finit. Întrucât FEM este foarte intensiv din punct de vedere computațional, modelul BEM al subiectului-specific, deși este un mod suprasimplificat al capului sferic, este folosit în mod curent. În termenii lui ED, USP, și

FSP, LRT1 (de exemplu, $p = 1$) a fost demonstrat că dă cele mai bune rezultate de localizare. A fost de asemenea încercată și folosirea proprietăților temporale ale semnalelor creierului pentru a îmbunătăți performanța localizării. O constrângere temporală suplimentară poate fi adăugată prin presupunerea că pentru fiecare locație modificarea amplitudinii sursei cu timpul este minimă. Constrângerea ce trebuie adăugată este $min\ ||\boldsymbol{s}(n) - \boldsymbol{s}(n-1)||^2$, unde *n* arată indicele de timp.

2.7.11. Metoda ICA–LORETA unificate

Într-un alt studiu, Infomax BSS bazat pe ICA BSS a fost implementat ca schemă de procesare înainte de aplicarea LORETA pentru a localiza sursele ce stau la baza negativității de nepotrivire (MMN). MMN este un ERP auditiv involuntar, care are vârfuri la 100-200 ms când există o violare a tiparului regulat. ERP pare să corespundă unei inteligențe primitive. Semnalele MMN sunt generate în principal în cortexul supramental. Analiza LORETA a fost realizată cu hărți de scalp asociate cu componente ICA selectate pentru a găsi generatorii acestor hărți. Au fost acceptate ca activări doar valorile mai mari de 2,5 ori decât deviația standard a datelor standardizate (în rezoluția spațială LORETA). A fost de asemenea abordată problema inversă într-un cadru bayesian. În asemenea metode unele informații despre probabilitățile anterioare sunt în mod normal esențiale. Din nou modelul generării EEG poate fi considerat confirm ecuației 2.115.

$$E\boldsymbol{x}(n) = \boldsymbol{H}\boldsymbol{s}(n) + \boldsymbol{v}(n) \tag{2.115}$$

$\boldsymbol{x}(n)$ este un vector $n_e \times 1$ ce conține valorile eșantioanelor EEG la momentul *n*;
H este o matrice *n*e × *m* ce reprezintă modelul mediului capului;
$\boldsymbol{s}(n)$ sunt valorile eșantion ale vectorului $m \times 1$ ale surselor la momentul *n*;
$\boldsymbol{v}(n)$ este vectorul $n_e \times 1$ al eșantioanelor zgomotului la momentul *n*.

Informația *a priori* despre surse impune unele constrângeri asupra locațiilor lor și a proprietăților lor temporale. Estimarea poate fi făcută folosind un criteriu de maximum *a posteriori* (MAP) în care estimatorul încearcă să-ș găsească pe $\boldsymbol{s}(n)$ care maximizează

distribuția probabilității lui ***s***(*n*) date fiind măsurătorile **x**(*n*). Estimatorul este notat ca în ecuația 2.116 și regula lui Bayes ce urmează, probabilitatea posterioară este afișată în ecuația 2.117

$$\hat{s}(n) = \max\left[p\left(\boldsymbol{s}(n)\middle|\boldsymbol{x}(n)\right)\right] \tag{2.116}$$

$$p\left(\boldsymbol{s}(n)\middle|\boldsymbol{x}(n)\right) = p\left(\boldsymbol{x}(n)\middle|\boldsymbol{s}(n)\right)p\left(\boldsymbol{s}(n)\right)/p\left(\boldsymbol{x}(n)\right) \tag{2.117}$$

*p(**x**(n)|**s**(n))* este aproximația;
*p(**x**(n))* este distribuția marginală a măsurătorilor sau martorilor;
*p(**s**(n))* este probabilitatea anterioară.

Posteriorul poate fi scris în termeni de funcții de energie , de exemplu, ecuația 2.118 și $U(\boldsymbol{s}(n)) = (1-\lambda)U_1(\boldsymbol{s}(n)) + \lambda U_2(\boldsymbol{s}(n))$, unde U_1 și U_2 corespund aproximației și respectiv anteriorului , iar $0 \leq \lambda \leq 1$. Anteriorul poate fi separat în două funcții, anterioare spațiale U_s și anterioare temporale U_t.

$$p\left(\boldsymbol{s}(n)\middle|z(n)\right) = \frac{1}{z(n)}\exp\left[-U\left(\boldsymbol{s}(n)\right)\right] \tag{2.118}$$

Funcția anterioară spațială poate lua în considerare netezimea variației spațiale a surselor. O funcție cost care determină netezimea spațială este:

$$\Phi(u) = \frac{u^2}{1+\left(\frac{u}{K}\right)^2} \tag{2.119}$$

Unde *K* este factorul de scalare care determină netezimea cerută. Ca urmare funcția anterioară pentru constrângerile spațiale poate fi scrisă conform ecuației 2.120, unde indicii *x* și *y* corespund gradienților orizontali și respectivi verticali.

$$Us\left(\boldsymbol{s}(n)\right) = \sum_{k=1}^{n_e}\left[\Phi_k^x\left(\nabla_x\boldsymbol{s}(n)|k\right) + \Phi_k^y\left(\nabla_y\boldsymbol{s}(n)\middle|k\right)\right] \tag{2.120}$$

Constrângerile temporale sunt impuse prin presupunerea că proiecția lui $\boldsymbol{s}(n)$ pe perpendiculara spațiului la $\boldsymbol{s}(n-1)$ este mică. Astfel, funcția anterioară temporală, ca o a doua constrângere, poate fi scrisă conform ecuației 2.121:

$$Ut\big(\boldsymbol{s}(n)\big) = \left|\left|\boldsymbol{P}_{n-1}^{\perp}\boldsymbol{s}(n)\right|\right|^2 \tag{2.121}$$

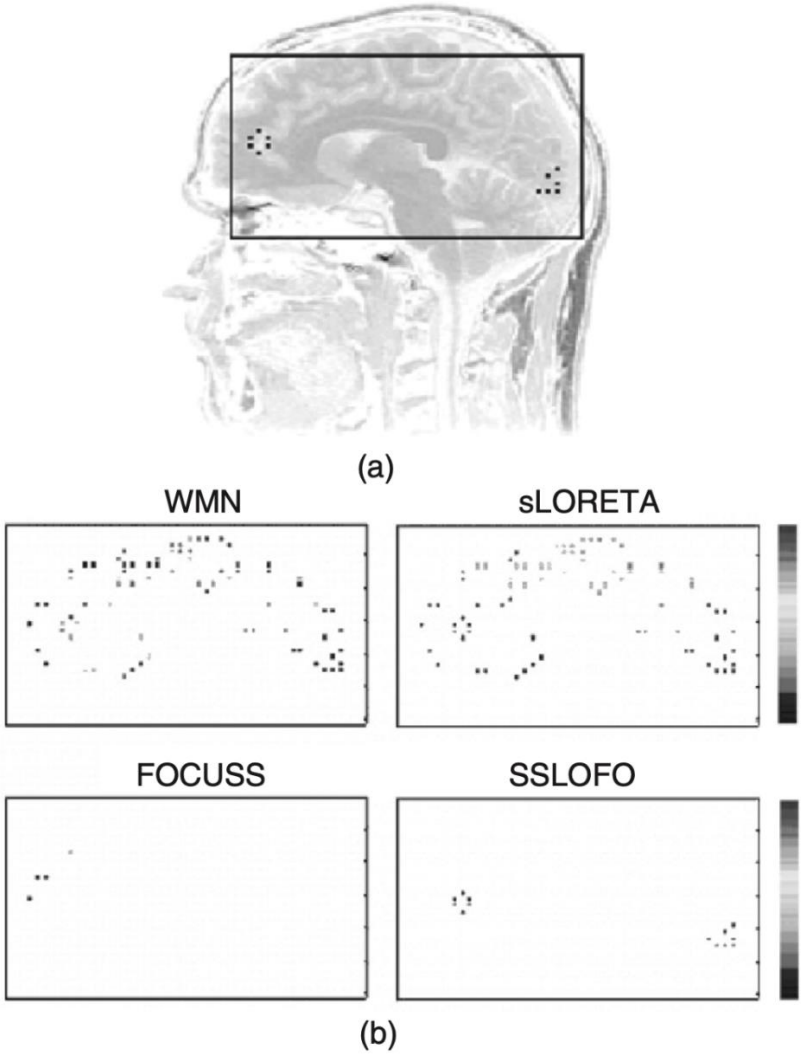


Figura 2.19 Localizarea sursei cerebrale (reconstrucția distribuției sursei modelate în modelul realist al capului) (a) pozițiile surselor simulate, (b) rezultatele folosind cei patru algoritmi inverși WMW, sLORETA, FOCUSS, și SSLOFO [182]

Unde $\boldsymbol{P}_{\boldsymbol{n-1}}^{\perp}$ este proiecția pe perpendicularei spațiului la $\boldsymbol{s}(n-1)$. Ca urmare criteriul de minimizare global pentru estimarea lui $\boldsymbol{s}(n)$ va fi reprezentată în ecuația 2.122, unde α *și* β sunt termenii de penalizare (parametri de regularizare). Conform rezultatelor acestui studiu componentele independente pot fi generate de una sau mai mute surse separate spațial. Aceasta

confirmă faptul că fiecare dipol este cumva asociat cu un dipol generator [190]. În plus, s-a pretins că o structura cerebrală specifică poate participa în componente diferite, lucrând simultan în observații diferite. Combinarea ICA și LORETA exploatează atât dinamica spațio-temporală a creierului cât și localizarea surselor. În alte cercetări științifice au fost comparate patru metode inverse diferite, și anume WMN, sLORETA, FOCUSS, și SSLOFO (pe baza unei presupuneri a capului sferic și în absența zgomotului). Figura 2.19 ilustrează rezultatele acestor simulări.

$$\hat{\boldsymbol{s}}(n) = \arg\min_{s}\left\{\left|\left|\boldsymbol{x}(n) - \boldsymbol{H}\boldsymbol{s}(n)\right|\right|^2 + \alpha\sum_{k=1}^{n_e}\left[\Phi_k^x\left(\nabla_x \boldsymbol{s}(n)|k\right) + \Phi_k^y\left(\nabla_y\, \boldsymbol{s}(n)\middle|k\right)\right] + \beta\left|\left|\boldsymbol{P}_{\boldsymbol{n}-1}^{\perp}\boldsymbol{s}(n)\right|\right|^2\right\} \quad (2.122)$$

2.7.12. Metoda BSS Constrânsă Partial

Recent, locațiile surselor cunoscute, cum ar fi unele ritmuri cerebrale normale, au fost folosite ca informație anterioară pentru a găsi locațiile semnalelor surselor cerebrale anormale sau a altora folosind funcția cost a algoritmului BSS este constrânsă prin această informație iar sursele cunoscute sunt calculate iterativ. Se consideră că $\tilde{A}$ = [$\mathbf{A}_k$ ⋮ $\mathbf{A}_{uk}$] este matricea de amestecare ce include informația geometrică despre sursele cunoscute, $\mathbf{A}_k$, și necunoscute, $\mathbf{A}_{uk}$. $\mathbf{A}_k$ este o matrice $n_e \times k$ *iar* $\mathbf{A}_{uk}$ este o matrice $n_e \times (m - k)$. Dată fiind $\mathbf{A}_k$, $\mathbf{A}_{uk}$ poate fi estimată după cum urmează în ecuația 2.123.

$$\boldsymbol{A}_{ukn+1} = \boldsymbol{A}_{ukn} - \zeta\nabla A_{uk}\left(\boldsymbol{J}_c\right) \quad (2.123)$$

$$\nabla A_{uk}\left(\boldsymbol{J}_c\right) = 2([\boldsymbol{A}_k \vdots \boldsymbol{A}_{ukn}] - \boldsymbol{R}_n + 1\boldsymbol{W}_{n+1}^{-1}) \quad (2.124)$$

$$\boldsymbol{R}_{n+1} = \boldsymbol{R}_n - \gamma\nabla_{\boldsymbol{R}}(\boldsymbol{J}_c) \quad (2.125)$$

$$\boldsymbol{J}c = \left|\left|\tilde{A}_n - \boldsymbol{R}_{n+1}\boldsymbol{W}_{n+1}^{-1}\right|\right|_F^2 \quad (2.126)$$

$$\boldsymbol{J\nabla R(J_c) = 2\left[W_{n+1}^{-1}A_k + R_n W_{n+1}^{-1}\,(W_{n+1}^{-1})^T - W_{n+1}^{-1}A_{uk_n}\right]} \quad (2.127)$$

$$\boldsymbol{W_{n+1} = W_n - \mu\nabla_W J} \quad (2.128)$$

Unde $\mathbf{J}(\mathbf{W}) = \mathbf{J}_m(\mathbf{W}) + \lambda\mathbf{J}_c(\mathbf{W})$ și $\mathbf{J}_m$ este funcția cost BSS principală. Parametrii μ, γ, și ζ sunt fie setați empiric sau modificați iterativ; ei scad când eroarea de convergență scade, și $\mathbf{A}_k$ este cunoscut și rămâne constant.

2.7.13. *Determinarea Numărului de Surse*

Una dintre condițiile majore pentru separarea și localizarea exactă a surselor cerebrale este cunoașterea numărului de surse. Problema detectării numărului de surse independente (sau necorelate) poate fi definită analizând structura matricei de covarianță a matricei de observare. Această matrice poate fi exprimată ca $\mathbf{C} = \mathbf{C}_{semnal} + \mathbf{C}_{zgomot}$, unde $\mathbf{C}_{semnal}$ și $\mathbf{C}_{zgomot}$ sunt covarianța semnalelor surselor și respectiv covarianța zgomotului. PCA și SVD pot performa bine dacă nivelul zgomotului este scăzut. În acest caz numărul valorilor proprii dominante reprezintă numărul surselor. În cazul zgomotului alb, matricea de covarianță $\mathbf{C}_{zgomot}$ poate fi exprimată ca $\mathbf{C}_{zgomot} = \sigma_n^2\,\mathbf{I}$, unde σ_n^2 este varianța zgomotului și $\mathbf{I}$ este matricea de identitate. În cazul zgomotului colorat pot fi implementate metode similare dacă covarianța zgomotului este cunoscută pe lângă σ_n^2. Matricea covarianței zgomotului este o matrice definită pozitiva simetrică $\mathbf{C}_{zgomot} = \sigma_n^2 n\psi$. Atunci, o matrice pătrat nonsigular $\boldsymbol{\psi}(m\times m)$ există astfel încât $\boldsymbol{\psi} = \boldsymbol{\psi\psi}^T$. Atât pentru zgomotul alb cât și pentru cel colorat, cazurile valorilor proprii pot fi calculate din observarea matricelor covarianței, iar apoi valorile proprii pot fi analizate prin criteriul teoretic de informație pentru a estima numărul de surse independente.

Totuși, s-a demonstrat cp această metodă este suboptimală când sursele sunt corelate temporal. Selecția unui model potrivit pentru analiza EEG și localizarea sursei a fost investigată de mulți cercetători, și au fost stabilite câteva criterii pentru a rezolva această problemă. În cele mai multe metode amplitudinile surselor sunt testate pentru a stabili dacă ele sunt semnificativ mai mari decât zero, caz în care sursele sunt incluse în model. Alternativ, locațiile surselor pot fi testate pentru a determina dacă diferă una de alta semnificativ; în acest caz aceste surse ar trebuie să fie si ele incluse în model. PCA și ICA pot separa semnalele în componentele lor

necorelate și respectiv independente. Prin retroproiectarea componentelor individuale la electrozii de scalp pot fi testate ambele criterii de mai sus. Practic, numărul de regiuni active distincte din informația retroproiectată poate denota numărul de surse. Acuratețea estimării crește de asemenea când regiunile sunt clusterizate pe baza conținutului lor de frecvență. totuși, datorită existenței zgomotului cu distribuție necunoscută acuratețea rezultatelor este încă sub semnul întrebării [193]. În alte cercetări științifice au fost discutate metodele bazate pe varianța reziduală (RV), criteriul de informație Akaike (AIC),criteriul de infromație Bayesian (BIC) și testele Wald pe amplitudini (WA) și locații (WL). Aceste metode au fost mai apoi examinate pe date MEG atât pentru cazurile de eroare albă pură cât și pentru cele de eroare colorată [194]. Aceleași metode pot fi implementate și pentru datele EEG. În acest test datele MEG de la m senzori și T eșantioane sunt colectate pentri fiecare incercare independentă $j = 1, \ldots, n_e$ în matricea $m \times T$ $\mathbf{Y}j = (\mathbf{y}_{1j}, \ldots, \mathbf{y}_{Tj})$, cu $y_{ij} = (y_{1ij} \ldots, y_{mij})^T$. Considerând media din încercări ca $\bar{Y} = 1/n \sum^n j = 1\ \mathbf{Y}_j$, modelul pentru datele medii poate fi dat conform ecuației 2.129.

$$\bar{\boldsymbol{Y}} = \boldsymbol{GA} + \boldsymbol{E} \tag{2.129}$$

unde **G** include adaosurile de senzor ale surselor de amplitudini unitare. Matricea **G** depinde de parametrii de locație și orientare ai surselor dipolare. Pe baza acestui model testele pentru selectarea modelului sunt după cum urmează. Testul RV este definit ecuației 2.130, compară rezidualele pătrate cu datele pătrate ale tuturor senzorilor și eșantioanelor simultan.

$$RV = 100\ \frac{tr[(\bar{Y} - GA)(\bar{Y} - GA)^T]}{tr[\bar{Y}\bar{Y}]} \tag{2.130}$$

RV scade ca funcția de numărul de parametru, și de aceea se supra-potrivește cu ușurință. Se spune că modelul se potrivește dacă RV este sun un anumit prag. Metoda AIC penalizează funcția de log-aproximație pentru parametrii adiționali necesari pentru a descrie datele. Acești parametri pot fi descrie cumva sursele. Numărul surselor a fost păstrat limitat pentru acest test întrucât la un anumit punct orice sursă adițională scade puternic funcția log-aproximație, dar crește penalizarea. AIC este definită conform ecuației 2.131. În această ecuație s^2 este media elementelor diagonale ale matricei covarianței spațiale.

$$AIC = nmT \ln\left(\frac{\pi s^2}{n}\right) + \frac{1}{ns^2}\, tr\,[(\bar{Y} - \boldsymbol{GA})(\bar{Y} - \boldsymbol{GA})`] + 2p \quad (2.131)$$

Testul BIC seamănă cu metoda AIC dar cu mai mult accent pe parametrii adiționali, de aceea este așteptată o supra-potrivire mai mică în utilizarea BIC.

$$IC = n_e m^T \ln\left(\frac{\pi s^2}{n_e}\right) + \frac{1}{n_e s^2}\, tr\,[(\bar{Y} - \boldsymbol{GA})(\bar{Y} - \boldsymbol{GA})^T] + p \ln(mT) \quad (2.132)$$

În mod similar, este selectat modelul cu minimum CIC. Testul Wald este un alt criteriu important, care dă oportunitatea de a testa o ipoteză pe un anumit subset specific de parametri [196]. Atât amplitudinile cât și locațiile surselor pot fi testate folosind acest criteriu. Dacă $\boldsymbol{r}$ este o funcție vectorială q a parametrilor sursei (i.e. amplitudinea și locația), $\boldsymbol{r}_h$ vectorul q a valorii fixe ipotetice a lui $\boldsymbol{r}$, $\mathbf{R}$ matricea Jacobiană $q \times k$ a lui $\boldsymbol{r}$ cu privire la parametrii k, și $\mathbf{C}$ matricea covarianței $k \times k$ a surselor parametrilor, atunci testul Wald este definit conform ecuației 2.133:

$$\boldsymbol{W} = \frac{1}{q}\,(r - \boldsymbol{r}_h)^T(\boldsymbol{RC}^{-1}\boldsymbol{R}`)^{-1}(r - r_h) \quad (2.133)$$

Un avantaj al folosirii tehnicii WA în analiza spațio-temporală este posibilitatea de a verifica nivelele de semnificație univariată pentru a determina la care eșantioane sursele sunt active. Testele realizate pentru două surse sintetice sunt diferite componente ale zgomotului au arătat că testul WL are o performanță globală superioară, iar AIC și WA performează bine când sursele sunt apropiate la un loc. Aceste teste au fost bazate pe stimulările surselor si zgomot. De asemenea s-a presupus că localizările și orientările dipolilor sursei sunt ficși și doar amplitudinile se schimbă. Pentru datele EEG (sau MEG) reale , totuși, asemenea informații pot face subiectul schimbării și sunt în general cunoscute. De aceea, până acum nu a fost stabilit niciun criteriu de estimare a numărului de surse ale semnalelor creierului.

2.7.14. Sumar și concluzii

Localizarea sursei, doar din semnalele EEG, este o problemă de optimizare prost formulată. Aceasta se întâmplă în principal din cauza faptului că numărul surselor este necunoscut. Acest număr se poate schimba din timp în timp, în special când obiectivul este

investigarea EP sau sursele legate de mișcare. Cei mai mulți algoritmi propuși se subscriu uneia dintre cele două metode ale dipolului curent echivalent și a abordărilor distribuite linear. Unele dintre metodele de mai sus cum ar fi sLORETA au fost comercializate și descrise ca având un rezultat rezonabil pentru multe aplicații. Un sistem hibrid de metode diferite pare să dea rezultate mai bune. Localizarea poate fi de asemenea mai acurată dacă funcțiile cost propuse pot fi constrânse prin unele informații suplimentare ce rezultă din constatările clinice sau din anumite limitări geometrice. Neomogenitatea mediului capului este o altă problemă majoră; studii medicale și fizice comprehensive au fost realizate pentru a găsi un model acurat al capului. Fuziunea altor modalități cum sunt MEG sau fMRI va accentua într-adevăr acuratețea rezultatelor localizării. Există multe aplicații potențiale ale creierului pentru localizarea sursei creierului cum ar fi localizarea semnalelor ERP, interfața creier-computer, și localizarea sursei crizei.

3. Concluzii

Raportul 4 al tezei de doctorat *„Contribuții privind sistemele de evaluare automată a comportamentului uman pentru personalul din infrastructuri critice”* s-a concentrat pe aprofundarea tehnicilor avansate de procesare și analiză a semnalelor EEG, esențiale pentru evaluarea comportamentului uman în medii critice. Au fost prezentate și discutate mai multe metode inovative, cum ar fi transformata wavelet (discretă și continuă), analiza în domeniul timp-frecvență (inclusiv distribuția Wigner-Ville și funcția ambiguității), care permit o înțelegere mai detaliată a dinamicii semnalelor EEG pe multiple scale de frecvență și timp. Aceste tehnici sunt fundamentale pentru detectarea schimbărilor subtile în activitatea cerebrală, ce pot indica stări emoționale și comportamente critice. De asemenea, raportul a abordat soluțiile pentru ameliorarea problemelor legate de zgomot și artefacte, prin utilizarea unor metode avansate de filtrare și tehnici hibride, inclusiv algoritmi de învățare automată. Aceste soluții au demonstrat cum se poate îmbunătăți calitatea datelor EEG, ceea ce este crucial pentru evaluarea precisă a comportamentului uman în medii de risc înalt. În ansamblu, **raportul 4** a contribuit la dezvoltarea unui cadru teoretic și practic robust pentru aplicarea semnalelor EEG în analiza comportamentului uman, în special în contextul infrastructurilor critice. Metodele prezentate au rolul de a sprijini dezvoltarea unor sisteme automate de monitorizare a stărilor cognitive și emoționale ale personalului, în vederea unei reacții rapide și eficiente în situații de urgență sau risc.

Raportul 5 va continua aprofundarea cercetărilor din domeniul evaluării comportamentului uman, cu un focus special pe algoritmii de clasificare, esențiali pentru interpretarea datelor EEG într-un cadru automatizat. În cadrul acestui raport, vor fi detaliate mai multe tehnici de clasificare, inclusiv *Mașinile cu Vector de Suport (SVM), Algoritmul Mediei k și Procedeul de Potrivire*, fiecare având aplicații specifice în analiza semnalelor EEG și în corelarea acestora cu comportamentele umane. Aceste metode vor fi descrise și comparate în detaliu, evidențiind avantajele și limitările lor în contextul infrastructurilor critice. De asemenea, raportul 5 va aborda corelația dintre trăsăturile de personalitate, gradul de emotivitate și undele EEG, în special undele alfa. Această secțiune va explora cum diferitele tipuri de unde EEG, în special undele alfa, sunt asociate cu dimensiunile personalității și cu nivelurile de stres și anxietate ale individului, punând în lumină relevanța acestora pentru

monitorizarea comportamentului personalului în medii critice. **Raportul 5** va analiza metodelor de clasificare și va examina corelațiile dintre trăsăturile psihologice și semnalele EEG, contribuind astfel la îmbunătățirea sistemelor de evaluare automată a comportamentului uman în infrastructuri critice. Aceste cercetări vor sprijini dezvoltarea unor tehnologii mai avansate și mai eficiente pentru monitorizarea stărilor emoționale și comportamentale ale personalului, esențiale pentru gestionarea riscurilor în mediile de lucru cu pericole majore.

4. Bibliografie

[1] L. Milić, *Multirate filtering for digital signal processing: MATLAB applications*. 2009. doi: 10.4018/978-1-60566-178-0.

[2] S. C. Kim and S. S. Bhattacharyya, "Implementation of a Multirate Resampler for Multi-carrier Systems on GPUs," *J Signal Process Syst*, 2017, doi: 10.1007/s11265-017-1239-5.

[3] P. J. Franaszczuk, G. K. Bergey, P. J. Durka, and H. M. Eisenberg, "Time-frequency analysis using the matching pursuit algorithm applied to seizures originating from the mesial temporal lobe," *Electroencephalogr Clin Neurophysiol*, 1998, doi: 10.1016/S0013-4694(98)00024-8.

[4] "Multirate digital signal processing: multirate systems, filter banks, wavelets," *Choice Reviews Online*, 1995, doi: 10.5860/choice.32-4545.

[5] P. P. Vaidyanathan, "Multirate Digital Filters, Filter Banks, Polyphase Networks, and Applications: A Tutorial," *Proceedings of the IEEE*, 1990, doi: 10.1109/5.52200.

[6] M. Holschneider, R. Kronland-Martinet, J. Morlet, and Ph. Tchamitchian, "A Real-Time Algorithm for Signal Analysis with the Help of the Wavelet Transform," 1989. doi: 10.1007/978-3-642-97177-8_28.

[7] A. Graps, "An Introduction to Wavelets," *IEEE Computational Science and Engineering*, 1995, doi: 10.1109/99.388960.

[8] E. M. Stein, "On the Functions of Littlewood-Paley, Lusin, and Marcinkiewicz," *Trans Am Math Soc*, 1958, doi: 10.2307/1993226.

[9] M. Vetterli and J. Kovačević, "Wavelets and Subband Coding," *Book*, 1995.

[10] E. L. Glassman, "A wavelet-like filter based on neuron action potentials for analysis of human scalp electroencephalographs," *IEEE Trans Biomed Eng*, 2005, doi: 10.1109/TBME.2005.856277.

[11] C. Gerloff, J. Richard, J. Hadley, A. E. Schulman, M. Honda, and M. Hallett, “Functional coupling and regional activation of human cortical motor areas during simple, internally paced and externally paced finger movements,” *Brain*, 1998, doi: 10.1093/brain/121.8.1513.

[12] A. Sharott, P. J. Magill, J. P. Bolam, and P. Brown, “Directional analysis of coherent oscillatory field potentials in the cerebral cortex and basal ganglia of the rat,” *Journal of Physiology*, 2005, doi: 10.1113/jphysiol.2004.073189.

[13] C. W. J. Granger, “Investigating Causal Relations by Econometric Models and Cross-spectral Methods,” *Econometrica*, 1969, doi: 10.2307/1912791.

[14] C. Bernasconi and P. König, “On the directionality of cortical interactions studied by structural analysis of electrophysiological recordings,” *Biol Cybern*, 1999, doi: 10.1007/s004220050556.

[15] M. J. Kaminski and K. J. Blinowska, “A new method of the description of the information flow in the brain structures,” *Biol Cybern*, 1991, doi: 10.1007/BF00198091.

[16] H. Jing and M. Takigawa, “Observation of EEG coherence after repetitive transcranial magnetic stimulation,” *Clinical Neurophysiology*, 2000, doi: 10.1016/S1388-2457(00)00357-6.

[17] R. Kuś, M. Kamiński, and K. J. Blinowska, “Determination of EEG activity propagation: Pair-wise versus multichannel estimate,” *IEEE Trans Biomed Eng*, 2004, doi: 10.1109/TBME.2004.827929.

[18] J. Ginter, K. J. Blinowska, M. Kamiński, and P. J. Durka, “Phase and amplitude analysis in time-frequency space - Application to voluntary finger movement,” *J Neurosci Methods*, 2001, doi: 10.1016/S0165-0270(01)00424-1.

[19] M. Kamiński, M. Ding, W. A. Truccolo, and S. L. Bressler, “Evaluating causal relations in neural systems: Granger causality, directed transfer function and statistical assessment of significance,” *Biol Cybern*, 2001, doi: 10.1007/s004220000235.

[20] P. K. Johal and N. Jain, “Artifact removal from EEG: A comparison of techniques,” 2016. doi: 10.1109/ICEEOT.2016.7755056.

[21] H. Jebelli, S. Hwang, and S. H. Lee, “EEG-based workers’ stress recognition at construction sites,” *Autom Constr*, 2018, doi: 10.1016/j.autcon.2018.05.027.

[22] J. A. Urigüen and B. Garcia-Zapirain, “EEG artifact removal - State-of-the-art and guidelines,” *J Neural Eng*, vol. 12, no. 3, 2015, doi: 10.1088/1741-2560/12/3/031001.

[23] T. J. Huppert, S. G. Diamond, M. A. Franceschini, and D. A. Boas, “HomER: A review of time-series analysis methods for near-infrared spectroscopy of the brain,” *Appl Opt*, 2009, doi: 10.1364/AO.48.00D280.

[24] M. K. Islam, A. Rastegarnia, and Z. Yang, “Methods for artifact detection and removal from scalp EEG: A review,” *Neurophysiologie Clinique/Clinical Neurophysiology*, 2016, doi: 10.1016/j.neucli.2016.07.002.

[25] G. L. Wallstrom, R. E. Kass, A. Miller, J. F. Cohn, and N. A. Fox, “Automatic correction of ocular artifacts in the EEG: A comparison of regression-based and component-based methods,” *International Journal of Psychophysiology*, 2004, doi: 10.1016/j.ijpsycho.2004.03.007.

[26] A. Schlögl, C. Keinrath, D. Zimmermann, R. Scherer, R. Leeb, and G. Pfurtscheller, “A fully automated correction method of EOG artifacts in EEG recordings,” *Clinical Neurophysiology*, 2007, doi: 10.1016/j.clinph.2006.09.003.

[27] A. Q. Hamal and A. W. B. A. Rehman, “Artifact processing of epileptic EEG signals: An overview of different types of artifacts,” 2013. doi: 10.1109/ACSAT.2013.77.

[28] I. I. Goncharova, D. J. McFarland, T. M. Vaughan, and J. R. Wolpaw, “EMG contamination of EEG: Spectral and topographical characteristics,” *Clinical Neurophysiology*, 2003, doi: 10.1016/S1388-2457(03)00093-2.

[29] B. W. McMenamin, A. J. Shackman, L. L. Greischar, and R. J. Davidson, “Electromyogenic artifacts and electroencephalographic inferences revisited,” *NeuroImage*. 2011. doi: 10.1016/j.neuroimage.2010.07.057.

[30] S. Devuyst, T. Dutoit, P. Stenuit, M. Kerkhofs, and E. Stanus, “Removal of ECG artifacts from EEG using a modified independent component analysis approach,” 2008. doi: 10.1109/iembs.2008.4650387.

[31] K. J. Lee, C. Park, and B. Lee, “Elimination of ECG Artifacts from a Single-Channel EEG Using Sparse Derivative Method,” 2016. doi: 10.1109/SMC.2015.417.

[32] K. T. Sweeney, T. E. Ward, and S. F. McLoone, “Artifact removal in physiological signals-practices and possibilities,” *IEEE Transactions on Information Technology in Biomedicine*, 2012, doi: 10.1109/TITB.2012.2188536.

[33] G. Nolte, O. Bai, L. Wheaton, Z. Mari, S. Vorbach, and M. Hallett, “Identifying true brain interaction from EEG data using the imaginary part of coherency,” *Clinical Neurophysiology*, 2004, doi: 10.1016/j.clinph.2004.04.029.

[34] Y. Qin, P. Xu, and D. Yao, “A comparative study of different references for EEG default mode network: The use of the infinity reference,” *Clinical Neurophysiology*, 2010, doi: 10.1016/j.clinph.2010.03.056.

[35] M. A. Klados, C. Papadelis, C. Braun, and P. D. Bamidis, “REG-ICA: A hybrid methodology combining Blind Source Separation and regression techniques for the rejection of ocular artifacts,” 2011. doi: 10.1016/j.bspc.2011.02.001.

[36] S. A. Hillyard and R. Galambos, “Eye movement artifact in the CNV,” *Electroencephalogr Clin Neurophysiol*, 1970, doi: 10.1016/0013-4694(70)90185-9.

[37] J. L. Whitton, F. Lue, and H. Moldofsky, “A spectral method for removing eye movement artifacts from the EEG,” *Electroencephalogr Clin Neurophysiol*, 1978, doi: 10.1016/0013-4694(78)90208-0.

[38] G. L. Wallstrom, R. E. Kass, A. Miller, J. F. Cohn, and N. A. Fox, “Correction of Ocular Artifacts in the EEG Using Bayesian Adaptive Regression Splines,” 2002. doi: 10.1007/978-1-4612-2078-7_19.

[39] G. Di Flumeri, P. Arico, G. Borghini, A. Colosimo, and F. Babiloni, “A new regression-based method for the eye blinks artifacts correction in the EEG signal, without using any EOG channel,” 2016. doi: 10.1109/EMBC.2016.7591406.

[40] P. S. Kumar, R. Arumuganathan, K. Sivakumar, and C. Vimal, “Removal of ocular artifacts in the EEG through wavelet transform without using an EOG reference channel.,” *International Journal of Open Problems in Computer Science and Mathematics. IJOPCM*, vol. 1, no. 3, pp. 189–200, 2008.

[41] D. Safieddine *et al.*, “Removal of muscle artifact from EEG data: Comparison between stochastic (ICA and CCA) and deterministic (EMD and wavelet-based) approaches,” *EURASIP J Adv Signal Process*, 2012, doi: 10.1186/1687-6180-2012-127.

[42] K. G. A. Lakshmi, S. N. N. Surling, and O. Sheeba, “A novel approach for the removal of artifacts in EEG signals,” 2018. doi: 10.1109/WiSPNET.2017.8300232.

[43] P. Berg and M. Scherg, “Dipole modelling of eye activity and its application to the removal of eye artefacts from the eeg and meg,” *Clinical Physics and Physiological Measurement*, 1991, doi: 10.1088/0143-0815/12/A/010.

[44] S. Casarotto, A. M. Bianchi, S. Cerutti, and G. A. Chiarenza, “Principal component analysis for reduction of ocular artefacts in event-related potentials of normal and dyslexic children,” *Clinical Neurophysiology*, 2004, doi: 10.1016/j.clinph.2003.10.018.

[45] B. Somers and A. Bertrand, “Removal of eye blink artifacts in wireless EEG sensor networks using reduced-bandwidth canonical correlation analysis,” *J Neural Eng*, 2016, doi: 10.1088/1741-2560/13/6/066008.

[46] T.-P. Jung, S. Makeig, A. J. Bell, and T. J. Sejnowski, “Independent Component Analysis of Electroencephalographic and Event-Related Potential Data,” in *Central Auditory Processing and Neural Modeling*, 1998. doi: 10.1007/978-1-4615-5351-9_17.

[47] E. B. Assi, S. Rihana, and M. Sawan, “33% Classification Accuracy Improvement in a Motor Imagery Brain Computer Interface,” *J Biomed Sci Eng*, 2017, doi: 10.4236/jbise.2017.106025.

[48] R. Vigário, J. Särelä, V. Jousmäki, M. Hämäläinen, and E. Oja, “Independent component approach to the analysis of EEG and MEG recordings,” *IEEE Transactions on Biomedical Engineering*. 2000. doi: 10.1109/10.841330.

[49] T. P. Jung, S. Makeig, M. Westerfield, J. Townsend, E. Courchesne, and T. J. Sejnowski, “Removal of eye activity artifacts from visual event-related potentials in normal and clinical subjects,” *Clinical Neurophysiology*, 2000, doi: 10.1016/S1388-2457(00)00386-2.

[50] S. Romero, M. A. Mañanas, S. Clos, S. Gimenez, and M. J. Barbanoj, “Reduction of EEG Artifacts by ICA in Different Sleep Stages,” 2003. doi: 10.1109/iembs.2003.1280467.

[51] A. Delorme, S. Makeig, and T. Sejnowski, “Automatic artifact rejection for EEG data using high-order statistics and independent component analysis,” *International workshop on ICA (* ..., 2001.

[52] C. A. Joyce, I. F. Gorodnitsky, and M. Kutas, “Automatic removal of eye movement and blink artifacts from EEG data using blind component separation,” *Psychophysiology*, 2004, doi: 10.1111/j.1469-8986.2003.00141.x.

[53] N. Y. Bian, B. Wang, Y. Cao, and L. Zhang, “Automatic removal of artifacts from EEG data using ICA and exponential analysis,” 2006. doi: 10.1007/11760023_106.

[54] Y. Li, Z. Ma, W. Lu, and Y. Li, “Automatic removal of the eye blink artifact from EEG using an ICA-based template matching approach,” *Physiol Meas*, 2006, doi: 10.1088/0967-3334/27/4/008.

[55] A. Flexer, H. Bauer, J. Pripfl, and G. Dorffner, “Using ICA for removal of ocular artifacts in EEG recorded from blind subjects,” *Neural Networks*, 2005, doi: 10.1016/j.neunet.2005.03.012.

[56] K. H. Ting, P. C. W. Fung, C. Q. Chang, and F. H. Y. Chan, “Automatic correction of artifact from single-trial event-related potentials by blind source separation using second order statistics only,” *Med Eng Phys*, 2006, doi: 10.1016/j.medengphy.2005.11.006.

[57] W. Zhou and J. Gotman, “Automatic removal of eye movement artifacts from the EEG using ICA and the dipole model,” *Progress in Natural Science*, 2009, doi: 10.1016/j.pnsc.2008.11.013.

[58] M. Borga and O. Friman, “A canonical correlation approach to exploratory data analysis in fMRI,” *Proceedings of the …*, 2002.

[59] L. Dong *et al.*, “Characterizing nonlinear relationships in functional imaging data using eigenspace maximal information canonical correlation analysis (emiCCA),” *Neuroimage*, 2015, doi: 10.1016/j.neuroimage.2015.01.006.

[60] W. De Clercq, A. Vergult, B. Vanrumste, W. Van Paesschen, and S. Van Huffel, “Canonical correlation analysis applied to remove muscle artifacts from the electroencephalogram,” *IEEE Trans Biomed Eng*, 2006, doi: 10.1109/TBME.2006.879459.

[61] C. Vaya, J. J. Rieta, C. Sanchez, and D. Moratal, “Convolutive blind source separation algorithms applied to the electrocardiogram of atrial fibrillation: Study of performance,” *IEEE Trans Biomed Eng*, 2007, doi: 10.1109/TBME.2006.889778.

[62] K. Kaiboriboon, H. O. Lüders, M. Hamaneh, J. Turnbull, and S. D. Lhatoo, “EEG source imaging in epilepsyĝ€"practicalities and pitfalls,” *Nature Reviews Neurology*. 2012. doi: 10.1038/nrneurol.2012.150.

[63] I. F. Gorodnitsky, J. S. George, and B. D. Rao, “Neuromagnetic source imaging with FOCUSS: a recursive weighted minimum norm algorithm,” *Electroencephalogr Clin Neurophysiol*, 1995, doi: 10.1016/0013-4694(95)00107-A.

[64] T. Liu and D. Yao, “Removal of the ocular artifacts from EEG data using a cascaded spatio-temporal processing,” *Comput Methods Programs Biomed*, 2006, doi: 10.1016/j.cmpb.2006.03.009.

[65] D. Yao, “A method to standardize a reference of scalp EEG recordings to a point at infinity,” *Physiol Meas*, 2001, doi: 10.1088/0967-3334/22/4/305.

[66] N. E. Huang *et al.*, “The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis,” *Proceedings of the Royal Society A*, 1996.

[67] M. K. I. Molla, M. Rabiul Islam, T. Tanaka, and T. M. Rutkowski, “Artifact suppression from EEG signals using data adaptive time domain filtering,” *Neurocomputing*, 2012, doi: 10.1016/j.neucom.2012.05.009.

[68] M. Chavez, F. Grosselin, A. Bussalb, F. De Vico Fallani, and X. Navarro-Sune, “Surrogate-based artifact removal from single-channel EEG,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 2018, doi: 10.1109/TNSRE.2018.2794184.

[69] B. Yang, T. Zhang, Y. Zhang, W. Liu, J. Wang, and K. Duan, “Removal of Electrooculogram Artifacts from Electroencephalogram Using Canonical Correlation Analysis with Ensemble Empirical Mode Decomposition,” *Cognit Comput*, 2017, doi: 10.1007/s12559-017-9478-0.

[70] Y. Zhang *et al.*, “Noise-assisted multivariate empirical mode decomposition for multichannel EMG signals,” *Biomed Eng Online*, 2017, doi: 10.1186/s12938-017-0397-9.

[71] X. Xu, X. Chen, and Z. Yu, “Removal of muscle artefacts from few-channel EEG recordings based on multivariate empirical mode decomposition and independent vector analysis,” *Electron Lett*, 2018, doi: 10.1049/el.2018.0191.

[72] B. Mijović, M. De Vos, I. Gligorijević, J. Taelman, and S. Van Huffel, “Source separation from single-channel recordings by combining empirical-mode decomposition and independent component analysis,” *IEEE Trans Biomed Eng*, 2010, doi: 10.1109/TBME.2010.2051440.

[73] P. He, M. Kahle, G. Wilson, and C. Russell, “Removal of ocular artifacts from EEG: A comparison of adaptive filtering method and regression method using simulated data,” 2005. doi: 10.1109/iembs.2005.1616614.

[74] C. Marque, C. Bisch, R. Dantas, S. Elayoubi, V. Brosse, and C. Pérot, “Adaptive filtering for ECG rejection from surface EMG recordings,” *Journal of Electromyography and Kinesiology*, 2005, doi: 10.1016/j.jelekin.2004.10.001.

[75] P. He, G. Wilson, and C. Russell, “Removal of ocular artifacts from electro-encephalogram by adaptive filtering,” *Med Biol Eng Comput*, 2004, doi: 10.1007/BF02344717.

[76] R. Kher and R. Gandhi, “Adaptive filtering based artifact removal from electroencephalogram (EEG) signals,” 2016. doi: 10.1109/ICCSP.2016.7754202.

[77] B. Somers, T. Francart, and A. Bertrand, “A generic EEG artifact removal algorithm based on the multi-channel Wiener filter,” *J Neural Eng*, 2018, doi: 10.1088/1741-2552/aaac92.

[78] M. Izzetoglu, A. Devaraj, S. Bunce, and B. Onaral, “Motion artifact cancellation in NIR spectroscopy using Wiener filtering,” *IEEE Trans Biomed Eng*, 2005, doi: 10.1109/TBME.2005.845243.

[79] D. L. Donoho, “Sparse components of images and optimal atomic decompositions,” *Constr Approx*, 2001, doi: 10.1007/s003650010032.

[80] A. R. F. Da Silva, “Atomic decomposition with evolutionary pursuit,” *Digital Signal Processing: A Review Journal*, 2003, doi: 10.1016/S1051-2004(02)00028-3.

[81] S. G. Mallat and Z. Zhang, “Matching Pursuits With Time-Frequency Dictionaries,” *IEEE Transactions on Signal Processing*, 1993, doi: 10.1109/78.258082.

[82] P. Xu and D. Yao, “Two dictionaries matching pursuit for sparse decomposition of signals,” *Signal Processing*, 2006, doi: 10.1016/j.sigpro.2006.05.006.

[83] P. Li, P. Xu, R. Zhang, L. Guo, and D. Yao, “L1 Norm based common spatial patterns decomposition for scalp EEG BCI,” *Biomed Eng Online*, 2013, doi: 10.1186/1475-925X-12-77.

[84] P. Li *et al.*, “Autoregressive model in the Lp norm space for EEG analysis,” *J Neurosci Methods*, 2015, doi: 10.1016/j.jneumeth.2014.11.007.

[85] X. Chen, Z. J. Wang, and M. McKeown, “Joint Blind Source Separation for Neurophysiological Data Analysis: Multiset and multimodal methods,” *IEEE Signal Process Mag*, 2016, doi: 10.1109/MSP.2016.2521870.

[86] X. Chen, Q. Chen, Y. Zhang, and Z. J. Wang, “A Novel EEMD-CCA Approach to Removing Muscle Artifacts for Pervasive EEG,” *IEEE Sens J*, 2019, doi: 10.1109/JSEN.2018.2872623.

[87] X. Chen, C. He, and H. Peng, “Removal of muscle artifacts from single-channel EEG based on ensemble empirical mode decomposition and multiset canonical correlation analysis,” *J Appl Math*, 2014, doi: 10.1155/2014/261347.

[88] K. T. Sweeney, S. F. McLoone, and T. E. Ward, “The use of ensemble empirical mode decomposition with canonical correlation analysis as a novel artifact removal technique,” *IEEE Trans Biomed Eng*, 2013, doi: 10.1109/TBME.2012.2225427.

[89] G. Wang, C. Teng, K. Li, Z. Zhang, and X. Yan, “The Removal of EOG Artifacts from EEG Signals Using Independent Component Analysis and Multivariate Empirical Mode Decomposition,” *IEEE J Biomed Health Inform*, 2016, doi: 10.1109/JBHI.2015.2450196.

[90] M. H. Soomro, N. Badruddin, M. Z. Yusoff, and M. A. Jatoi, “Automatic eye-blink artifact removal method based on EMD-CCA,” 2013. doi: 10.1109/ICCME.2013.6548236.

[91] X. Chen, X. Xu, A. Liu, M. J. McKeown, and Z. J. Wang, “The Use of Multivariate EMD and CCA for Denoising Muscle Artifacts from Few-Channel EEG Recordings,” *IEEE Trans Instrum Meas*, 2018, doi: 10.1109/TIM.2017.2759398.