Raport 5

Titlu teză: “Recunoaşterea comportamentului disimulat bazată pe tehnici de inteligență artificială: contribuții metodologice şi validare empirică”

Student: Nicolescu Șerban-Teodor

Capitolul 4. Procesarea bazelor de date open-source (validare computațională)

Deception_data

Deception_data este o bază de date care a fost colectată în anul 2020 și include semnale EEG, date fiziologice și comportamentale. Participanții (44 de adulți sănătoși, cu vârste cuprinse între 21 și 40 de ani) au fost înregistrați atât în stare de repaus cu ochii închiși, cât și în timpul unor sarcini experimentale. Sarcinile administrate subiecților includ o sarcină de decepție spontană (Gambling Game; GG) și o sarcină de control cognitiv (CC). Participanților li s-a comunicat că scopul GG este investigarea comportamentului în cadrul unui joc de noroc. La începutul sesiunii, fiecare a primit o sumă inițială de 50 SGD. Ulterior, au parcurs 144 de runde în care au făcut o predicție privind rezultatul unei aruncări de zar și au plasat un pariu pentru fiecare predicție (între 0,10 și 0,80 SGD); câștigau pariul dacă predicția era corectă și îl pierdeau dacă era falsă. Un element esențial al paradigmei a fost faptul că doar participantul cunoștea rezultatul aruncării; acesta trebuia să raporteze sistemului dacă predicția fusese sau nu corectă [1].

Participanții au efectuat 60 de încercări ale unei sarcini simple de viteză de procesare, 80 de încercări ale unei sarcini simple de selecție a răspunsului, 160 de încercări ale unei sarcini de inhibare a răspunsului și 160 de încercări ale unei sarcini de rezolvare a conflictelor. Semnalele EEG au fost înregistrate cu sistemul **TruScan 128 Research EEG** și software-ul **TruScan Acquisition**. Electrozii au fost poziționați conform *standardului 10–5*, iar impedanța a fost menținută sub 20 kΩ pentru fiecare participant. Electrodul de masă a fost plasat pe osul zigomatic, iar doi electrozi au fost fixați pe mastoizi pentru a fi utilizați ca referințe. Rata de eșantionare în timpul înregistrării a fost de **3000 Hz**. De menționat este faptul că canalele 124 și 125 au fost amplasate deasupra și, respectiv, sub ochi, pentru captarea EOG vertical (artefacte de clipit și mișcare oculară). Pe lângă EEG, au fost înregistrate și **semnale fiziologice la o frecvență de 4000 Hz**: ECG, respirație, EDA și EMG. Achiziția s-a realizat cu sistemul **BIOPAC MP160** și software-ul **AcqKnowledge 5.0**. ECG a fost colectat cu trei electrozi într-o configurație Lead II modificată. Respirația a fost măsurată cu o centură poziționată pe abdomenul superior, EDA a fost înregistrată cu electrozi montați pe degetul mijlociu și arătător al mâinii nedominante, iar EMG a fost obținut prin măsurarea activității electrice a mușchilor corugatori [1].

Deception_data este o bază de date valoroasă ca resursă multimodală și ca demonstrație de fezabilitate pentru *paradigme de tip „gambling”*. Totuși, pentru obiectivul tezei – recunoașterea comportamentului disimulat – setul nu oferă un **ground-truth** suficient de puternic. Etichetele („probable lie/probable truth”) reprezintă **deducții** din date comportamentale și rapoarte ulterioare, **nu** un **ground-truth** verificat independent. Etichetele minciună/adevăr au o validitate de construct redusă; modelul poate învăța predominant semnături ale incertitudinii și ale așteptării recompensei, în locul celor specifice disimulării. De asemenea, din punct de vedere tehnic, setul prezintă (pentru unii subiecți) lipsă/inconsecvență a fișierelor comportamentale, variații de nomenclatură și de structură a evenimentelor și posibile **neconcordanțe de sincronizare** între evenimente și semnalul EEG. Aceste limitări ne obligă la decizii ad-hoc (reguli de etichetare, excluderi selective de subiecți/probe), ceea ce diminuează reproductibilitatea. Totodată, dezechilibrul de clasă — număr redus de probe de tip **„minciună”** la unii subiecți — afectează stabilitatea evaluării în validare încrucișată independentă de subiect (LOSO). În plus, paradigma de tip *gambling* introduce factori cognitivi de confuzie — decizie sub risc, anticiparea recompensei și feedback de rezultat — care nu sunt congruenți cu protocolul controlat propus pentru inducerea și validarea disimulării.

În concluzie, datorită limitărilor identificate — absența unui ground-truth valid pentru disimulare, adnotări comportamentale incomplete sau inconsecvente, posibile desincronizări între evenimente și datele EEG achiziționate, dezechilibru de clasă și nealinierea cu arhitectura vizată și cu paradigma propusă — Deception_data nu va fi utilizată ca punct de plecare în validarea computațională.

LieWaves

LieWaves este o bază de date EEG concepută special pentru detecția minciunii, utilă atât cercetării metodologice, cât și evaluării unor algoritmi practici. Semnalele au fost înregistrate cu dispozitivul purtabil **Emotiv Insight** (cască EEG cu cinci canale) de la 27 de subiecți, cu o frecvență de eșantionare de 128 Hz. Fiecare participant a parcurs **două experimente**, asumând pe rând rolurile de persoană mincinoasă și sinceră, ceea ce permite o separare clară a condițiilor și o analiză echilibrată a celor două stări comportamentale. Structura experimentală și formatele fișierelor (.csv) facilitează o procesare transparentă și reproductibilă [2]. *Paradigma de stimulare* a fost standardizată și repetitivă, pentru a obține repere temporale solide. În fiecare experiment,

subiecții primeau o cutie cu cinci mărgele și trebuiau să aleagă două pe care să le păstreze. Pe durata sesiunii, participanții urmăreau un videoclip compus din cicluri de 3 secunde de ecran negru, urmate de secvențe repetate de 2 secunde de imagini cu mărgele și 1 secundă de ecran negru. În rolul de persoană mincionoasă, dacă pe ecran apărea imaginea uneia dintre mărgelele alese, subiectul apăsa „no" (mâna stângă), iar dacă nu apărea, apăsa „yes" (mâna dreaptă), mințind astfel la toate imaginile; pentru rolul de persoană sinceră, acțiunile erau inversate, astfel încât să spună adevărul în toate cazurile. După înregistrări, au rezultat aproximativ 75 de secunde utile de semnale EEG per sesiune [2].

Procesare date EEG – LieWaves

Baza de date **LieWaves** a fost aleasă ca punct de plecare în teză deoarece corespunde direct obiectivului de a discrimina stările de adevăr și minciună pe baza semnalelor EEG, având etichete bine definite și o paradigmă temporală clară. **Utilizarea unei căști EEG purtabile cu doar cinci canale** aduce problema mai aproape de scenariile reale, în care densitatea redusă a senzorilor, costul scăzut și ușurința în utilizare sunt critice. **Alternanța** bine definită dintre intervalele „interval cu stimul" (2 s) și „ interval de referință" (fără stimul) (1 s) oferă repere temporale clare pentru o segmentare strictă și reproductibilă.

Primul pas din cadrul procesării semnalelor EEG corespunzătoare setului de date **LieWaves** a fos aplicarea unui **filtru notch la 50 Hz** (pentru zgomotul de la rețea) pe toate cele cinci canale (AF3, T7, Pz, T8, AF4), urmat de un **filtru trece-bandă la 1–45 Hz**. Alegerea **filtrului trece-bandă 1–45 Hz** a fost dictată de constrângerile metodologice și hardware ale studiului (căști EEG purtabile cu **5 canale**, $\mathbf{f_s \approx 128\ Hz}$, ferestre de **2 s** cu pas de **1 s**) și de obiectivul de a maximiza **raportul semnal–zgomot** pentru trăsăturile spectrale și temporale utilizate în clasificare. Capătul inferior la **1 Hz** funcționează ca un **filtru trece-sus** care atenuează componenta continuă (offset) și fluctuațiile foarte lente ale linii de bază (legate de contactul electrozilor, transpirație, micro-mișcări), efecte deosebit de pronunțate în sistemele purtabile cu densitate redusă a senzorilor și care pot distorsiona estimările pe ferestre scurte. Capătul superior la **45 Hz** acționează ca un **filtru trece-jos** care atenuează artefactele musculare și interferența de rețea, menținând totodată **unda gamma scăzută (30–45 Hz)** și lăsând o „zonă tampon" față de **50 Hz** ce reduce scurgerea spectrală în jurul **filtrului notch**. Prin această fereastră, se păstrează integral benzile EEG relevante pentru sarcina analizată—**delta (≥ 1 Hz), theta, alfa, beta** și **gamma**

scăzută—asigurând trăsături mai stabile și **reproductibilitate** mai bună în validarea *inter-subiect*, în timp ce componentele cel mai frecvent contaminate (< 1 Hz și > 45 Hz) sunt suprimate.

După preprocesare, am standardizat structurala experimentală prin marcarea alternanței „interval cu stimul” (2 s) și „interval de referință” (fără stimul) (1 s), conform paradigmei **LieWaves**. În Figura 1 se observă clar această alternanță, redată prin zone transparente suprapuse peste traseele celor 5 canale. Canalele frontale (AF3, AF4) prezintă amplitudini mai mari și deflexiuni punctuale, compatibile cu artefacte oculare și/sau musculare, chiar și după filtrarea de bază — un rezultat așteptat la sisteme purtabile cu densitate mică de senzori. Această inspecție vizuală confirmă că preprocesarea a păstrat dinamica de interes, dar indică și prezența unor episoade tranzitorii de amplitudine ridicată care trebuie avute în vedere în analizele spectrale ulterioare.

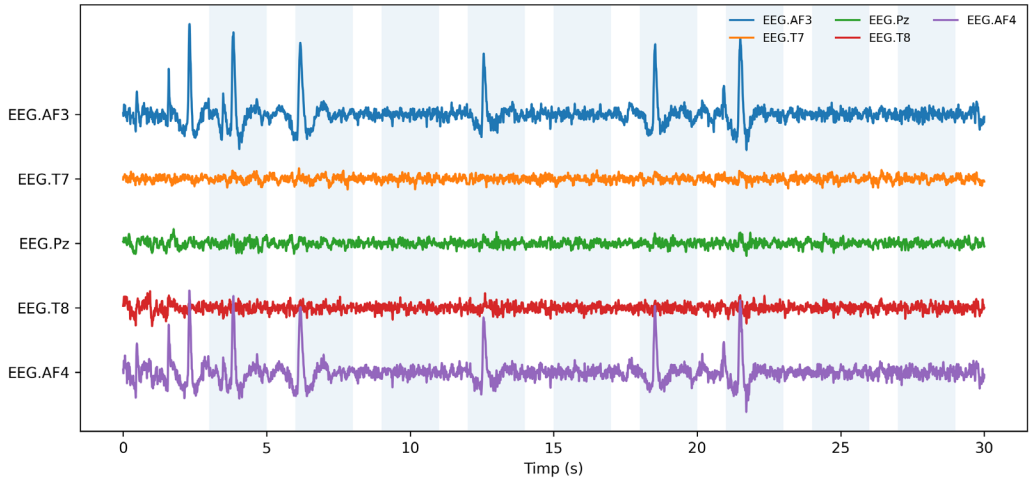


Figura 1. Semnalul EEG preprocesat pe canalele AF3, T7, Pz, T8, AF4 pentru subiectul 1, sesiunea 1

Pentru analiză în frecvență, am estimat **densitatea spectrală de putere (PSD)** prin **metoda Welch**. Conform Figurii 2, curbele celor cinci canale urmează profilul tipic **1/f**; se vede o **depresiune la 50 Hz** (efectul filtrului notch) și o **cădere abruptă după 45 Hz** datorată filtrului trece-bandă. Densitatea puterii este mai ridicată **sub 10 Hz** pe canalele frontale (AF3/AF4), în timp ce **Pz** și **T7/T8** au evoluții mai uniforme. Aceste elemente confirmă alegerea ferestrei **1–45 Hz** pentru datele analizate.

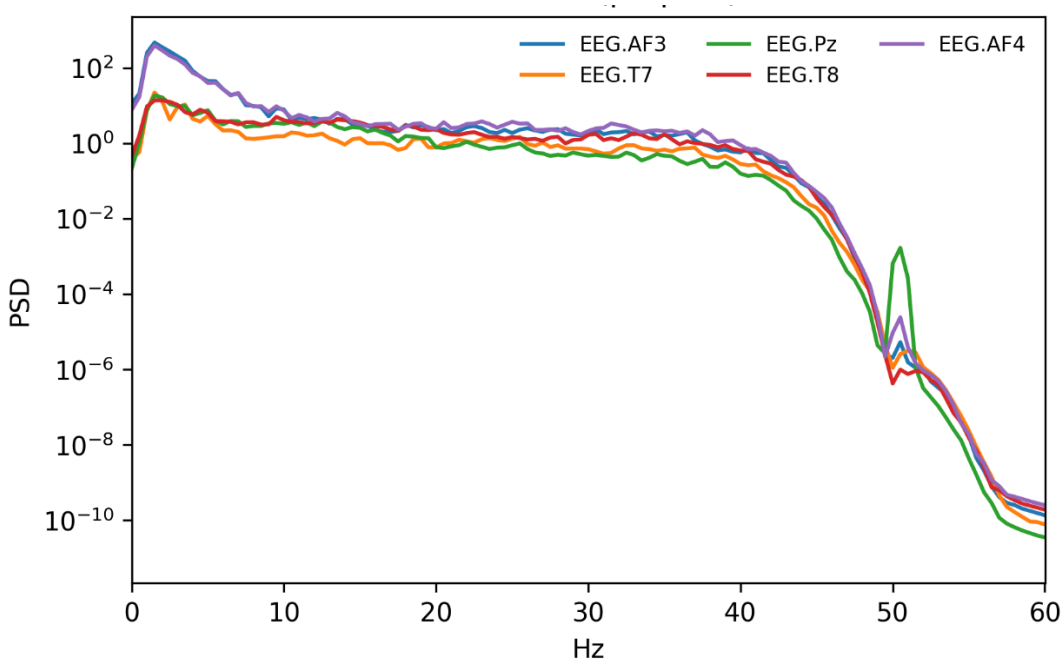


Figura 2. Densitatea spectrală de putere pe canalele AF3, T7, Pz, T8, AF4 pentru subiectul 1, sesiunea 1

La nivel agregat, am evaluat **puterea pe benzile** (δ, θ, α, β, γ scăzută), calculată pe ferestre și **mediată pe canale**. **Figura 3** ilustrează distribuțiile cu **cozi lungi** și **asimetrie accentuată**, în special în **delta** și **theta**, precum și o **suprapunere consistentă** a intervalelor intercuartile între cele două clase. Medianele sunt apropiate, ceea ce indică o **separare univariată modestă**. În consecință, un criteriu bazat doar pe media puterii pe bandă nu este suficient în regim de **inter-subiecți**; este necesară combinarea mai multor trăsături pe benzi/canale și **agregarea la nivel de sesiune**, cu **validare încrucișată între subiecți (GroupKFold)** pentru o estimare robustă a performanței.

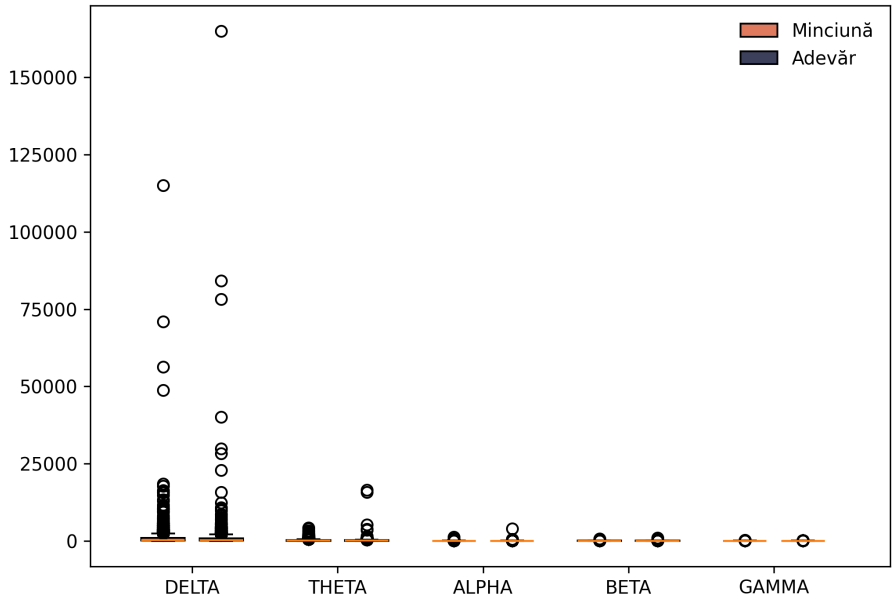


Figura 3. Densitatea spectrală pe benzile de frecvență (δ, θ, α, β, γ scăzută) pentru cele două clase

Tabel 1. Cuartilele Q1 și Q3 și intervalul IQR pentru puterea spectrală asociată fiecărei unde și clase

Bandă	$Q1_{*a}$	$Q1_{*m}$	M_{*a}	M_{*m}	$Q3_{*a}$	$Q3_{*m}$	IQR_{*a}	IQR_{*m}	ΔM_{*a-*m}
alfa	17.679	19.453	27.473	30.704	48.440	51.594	30.761	32.140	-3.231
beta	28.649	27.363	42.351	38.539	62.631	64.630	33.983	37.267	+3.811
delta	72.241	97.633	281.562	305.294	894.176	1,007.889	821.935	910.257	-23.733
gamma	10.691	10.902	17.573	15.840	31.272	28.100	20.581	17.198	+1.733
theta	24.882	31.199	60.025	78.128	197.725	224.502	172.843	193.303	-18.103

Notă: *a – Adevăr; *m – Minciună; M - Mediană

Tabel 2. Mărimea efectului Cliff pe toate benzile de frecvență

Bandă	ΔCliff*a - *m
alfa	-0.064
beta	+0.034
delta	-0.066
gamma	+0.038
theta	-0.088

Tabelul 1 prezintă faptul că distribuțiile **puterii pe fiecare bandă** sunt puternic răspândite, mai ales în undele **delta** și **theta**, unde intervalele intercuartile ating valori foarte mari (≈822–910 în δ și ≈173–193 în θ). În acest context de variabilitate ridicată, **diferențele de mediană** dintre clase sunt modeste: în **beta** și **gamma**, medianele sunt ușor mai mari pentru *Adevăr* (ΔMediană ≈ +3.81, respectiv +1.73), iar în **delta**, **theta** și **alpha** sunt puțin mai mari pentru *Minciună* (de exemplu ΔMediană δ ≈ −23.73; θ ≈ −18.10), însă toate aceste diferențe reprezintă doar o mică fracțiune din IQR. Aceeași concluzie reiese și din Δ**Cliff's**, care este aproape de zero pe toate benzile ($|\Delta| \leq 0.088$), ceea ce indică o **suprapunere substanțială** între distribuțiile celor două clase și o **separare univariată slabă**. Consecința pentru modelare este că **puterea pe bandă, luată singular**, nu discriminează suficient între *Minciună* și *Adevăr* în regim de **inter-subiecți**; este necesară combinarea mai multor trăsături (benzi și canale, rapoarte între benzi, parametrii Hjorth etc.) și **agregarea pe sesiune** a probabilităților obținute pe ferestre, așa cum s-a procedat în pipeline.

Pentru a surprinde **variabilitatea între subiecți**, am comparat condițiile **Minciună** și **Adevăr** pe benzi de frecvență (Figurile 4 - 8) la nivelul fiecărui participant, folosind **puterea medie pe bandă** (mediată pe cele cinci canale). În ansamblu, se conturează un tipar relativ stabil: **benzile lente (δ/θ)** tind să fie **mai mari în Minciună**, dar amplitudinea diferenței variază considerabil între persoane; în schimb, în **benzi rapide (β/γ scăzută)** diferențele sunt mici sau chiar ușor în favoarea condiției de **Adevăr** la unii subiecți. Heterogenitatea aceasta confirmă că o evaluare fiabilă necesită **trăsături combinate** din mai multe benzi/canale și **agregare la nivel de sesiune**, nu doar indicatori univariabili.

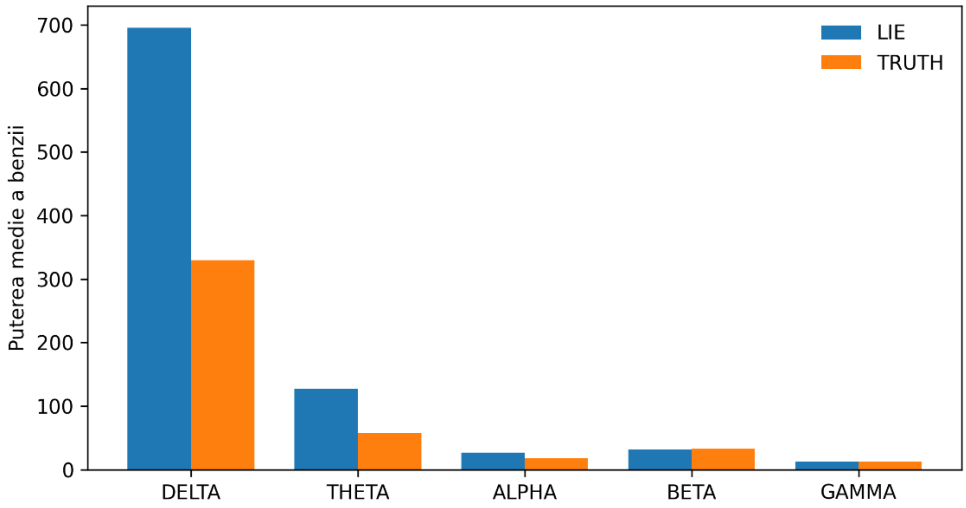


Figura 4. Puterea medie pe benzi pentru subiectul 1

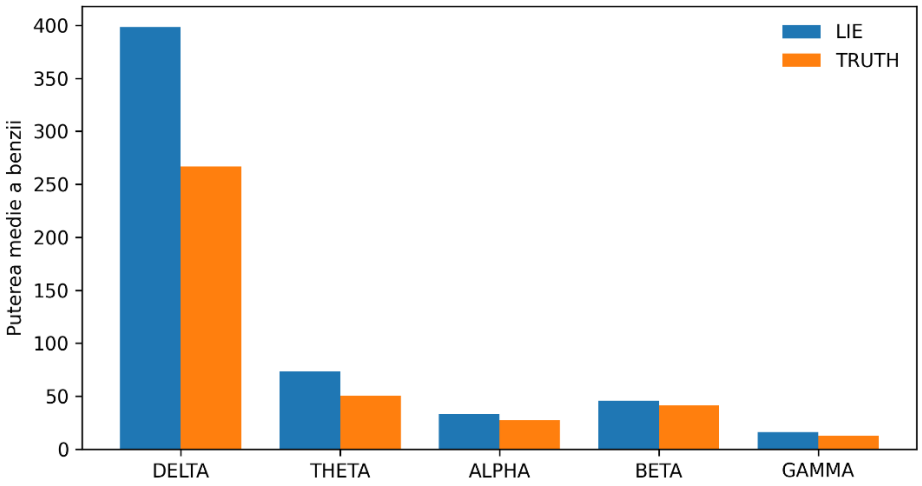


Figura 5. Puterea medie pe benzi pentru subiectul 2

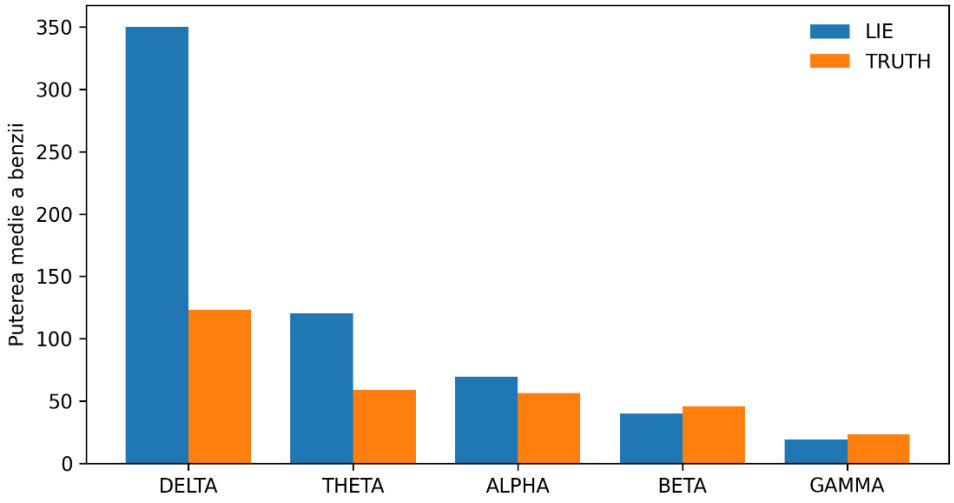


Figura 6. Puterea medie pe benzi pentru subiectul 7

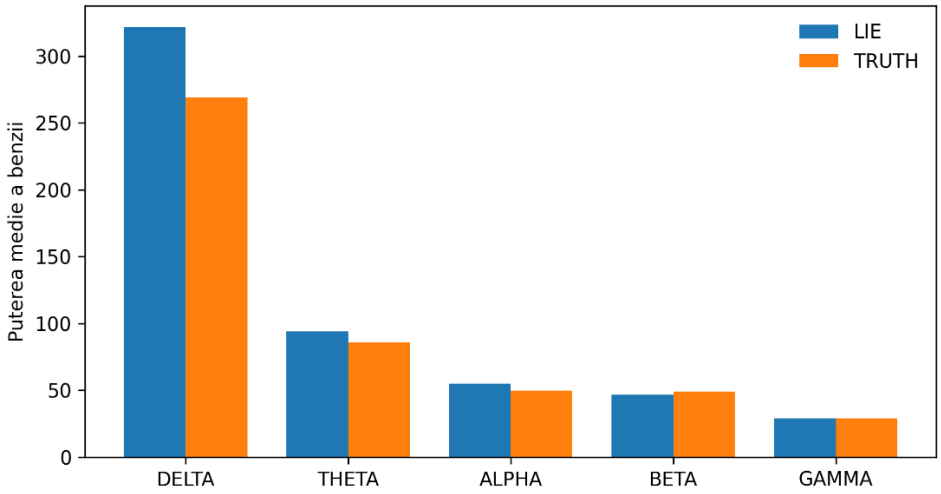


Figura 7. Puterea medie pe benzi pentru subiectul 15

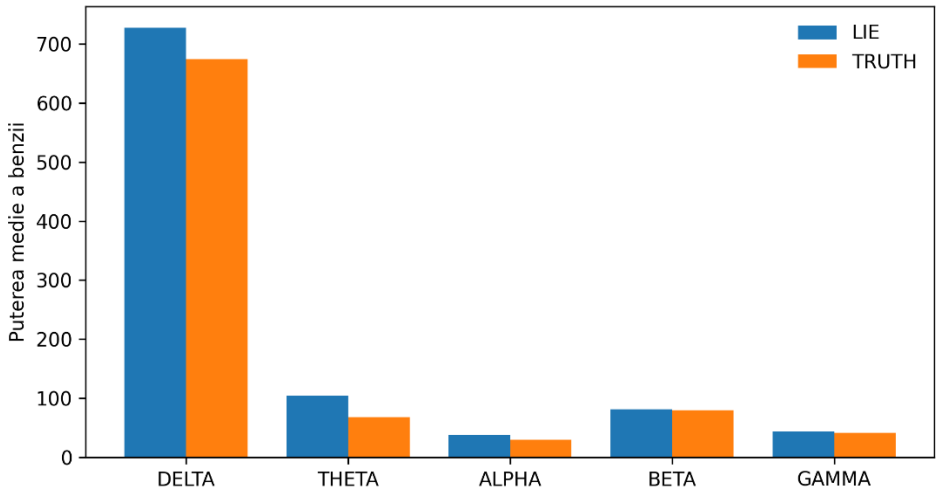


Figura 8. Puterea medie pe benzi pentru subiectul 26

Pentru a surprinde **variabilitatea între subiecți**, am comparat **PSD** dintre condițiile **Minciună** și **Adevăr** (Figurile 9 - 13) după **medierea pe cele cinci canale**. Curbele sunt, în general, **aproape suprapuse în intervalul 1–45 Hz**, diferențele apărând mai ales în **zona 2–8 Hz** și, ocazional, în **alfa**. La analiza **pe canal**, mici decalaje pe condițiile minciună/adevăr sunt mai vizibile pe **zonele frontale (AF3/AF4)**, în timp ce **Pz** rămâne de regulă stabil (Figurile 14 - 18). Acest tablou confirmă că efectul condiției este **fin, dependent de participant și de canal**, ceea ce justifică atât focalizarea pe intervalele *stimulus-on*, cât și utilizarea unor **trăsături suplimentare** (raporturi între benzi, parametrii Hjorth, conectivitate, măsuri riemanniene, indicatori non-liniari), împreună cu **agregare la nivel de sesiune**.

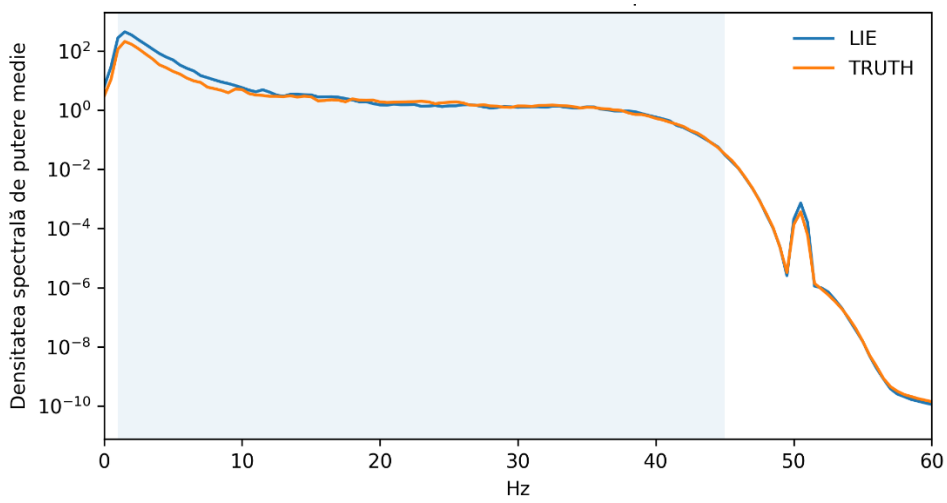


Figura 9. Densitatea spectrală de putere pentru subiectul 1

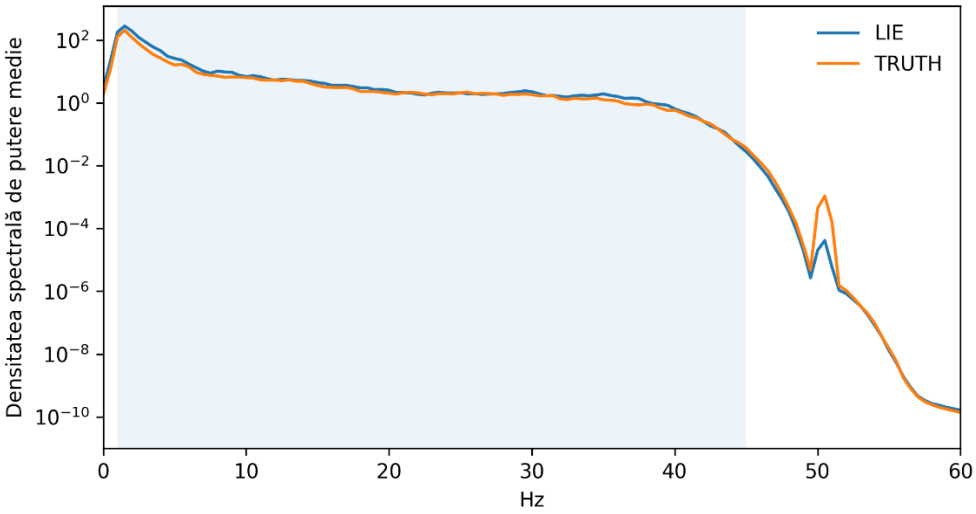


Figura 10. Densitatea spectrală de putere pentru subiectul 2

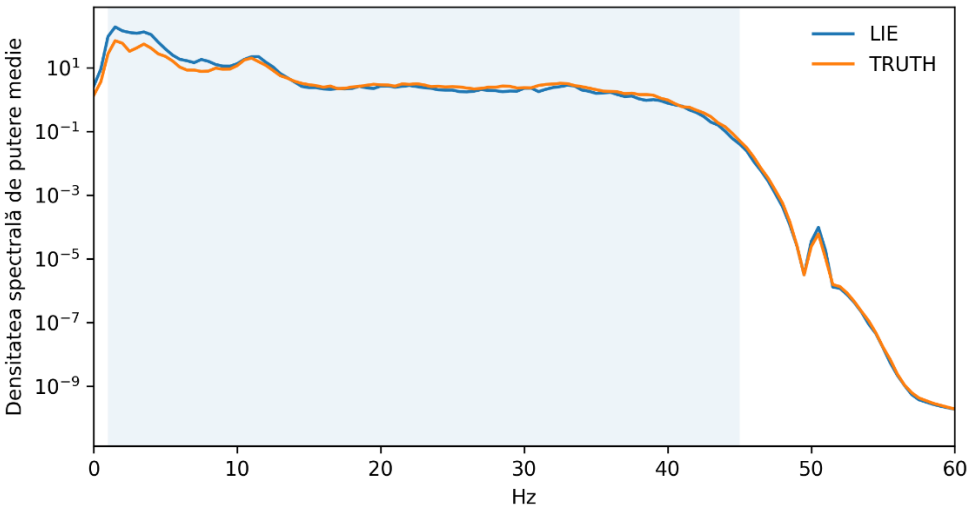


Figura 11. Densitatea spectrală de putere pentru subiectul 7

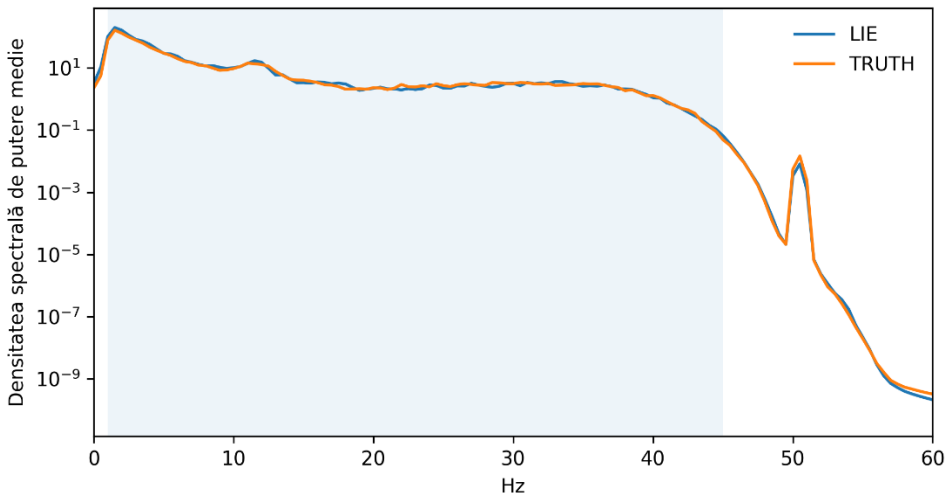


Figura 12. Densitatea spectrală de putere pentru subiectul 15

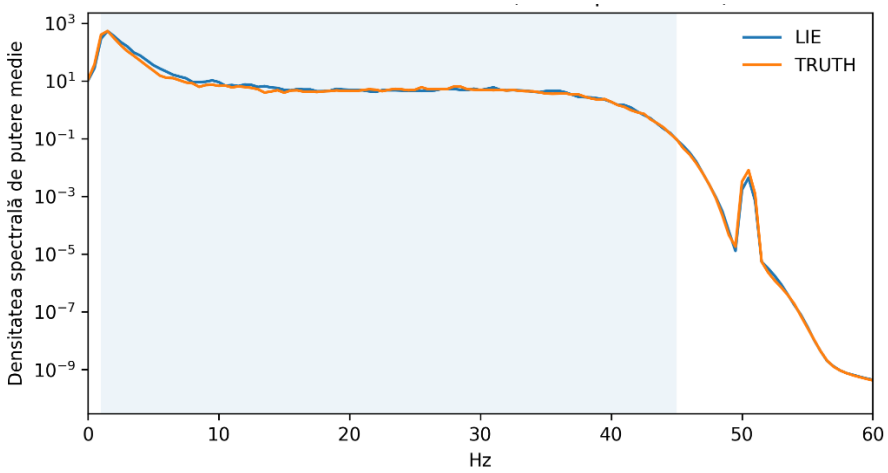


Figura 13. Densitatea spectrală de putere pentru subiectul 26

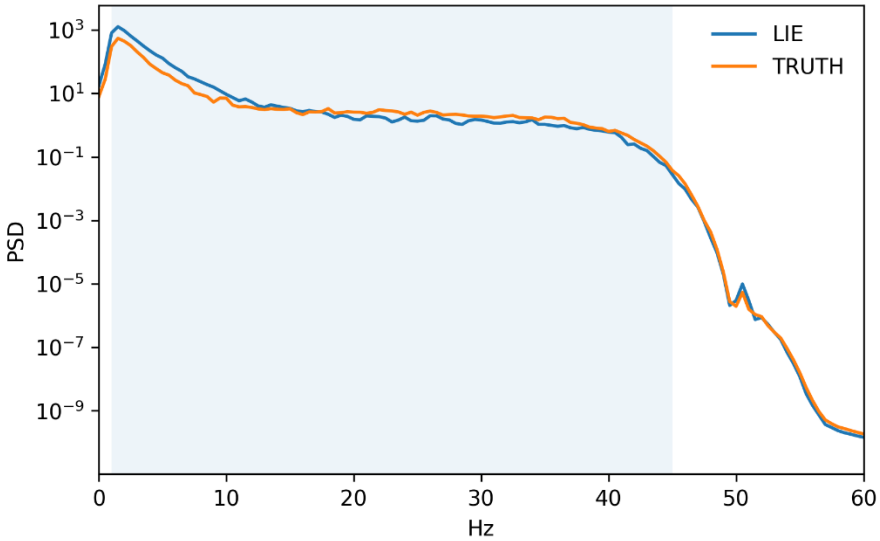


Figura 14. Densitatea spectrală de putere pentru subiectul 1 (electrodul AF3)

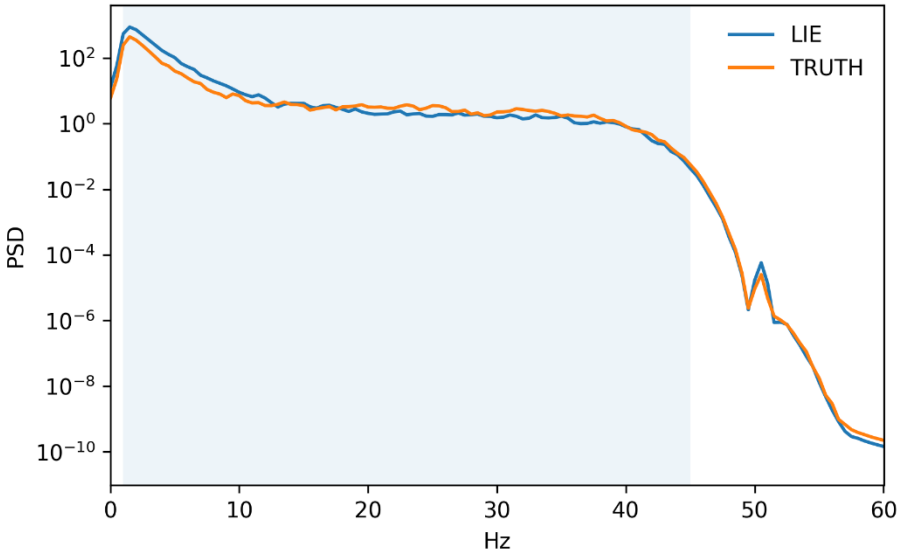


Figura 15. Densitatea spectrală de putere pentru subiectul 1 (electrodul AF4)

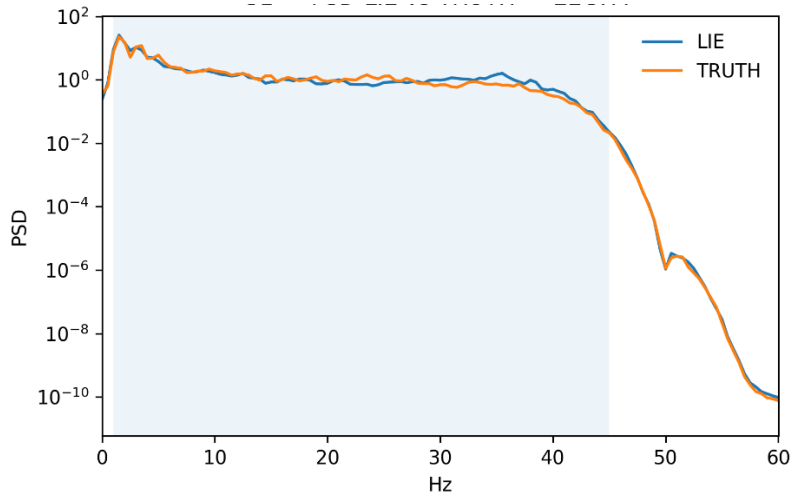


Figura 16. Densitatea spectrală de putere pentru subiectul 1 (electrodul T7)

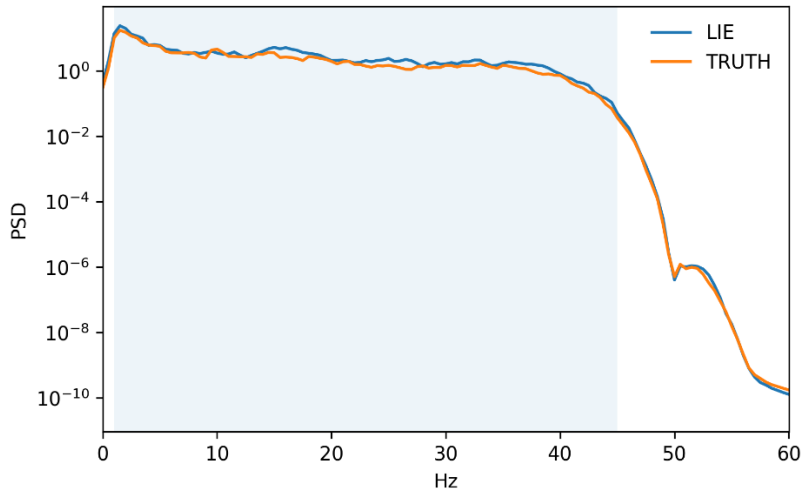


Figura 17. Densitatea spectrală de putere pentru subiectul 1 (electrodul T8)

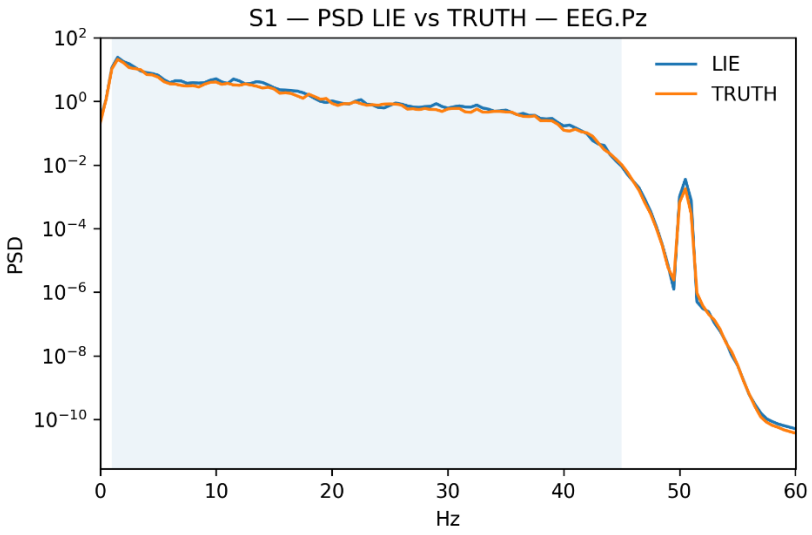


Figura 18. Densitatea spectrală de putere pentru subiectul 1 (electrodul Pz)

Ultima etapă a analizei bazei de date LieWaves a constat în compararea modelelor de clasificare (Figura 19; Tabel 3), cu evaluare strict între subiecți (GroupKFold per subiect) și agregarea probabilităților per sesiune din ferestrele de 2 s. Am raportat indicatori la nivel de fereastră (Win_Acc, Win_F1, Win_AUC) și la nivel de sesiune (Ses_Acc, Ses_F1, Ses_AUC). Rezultatele sunt sintetizate în Figura 19, care indică performanțe moderate, dar consecvente. Aceste rezultate sunt aliniate cu analizele în frecvență (PSD) și cu distribuțiile de putere pe benzi: diferențele minciună/adevăr sunt subtile și dependente de subiect/canal, iar agregarea pe sesiune stabilizează decizia.

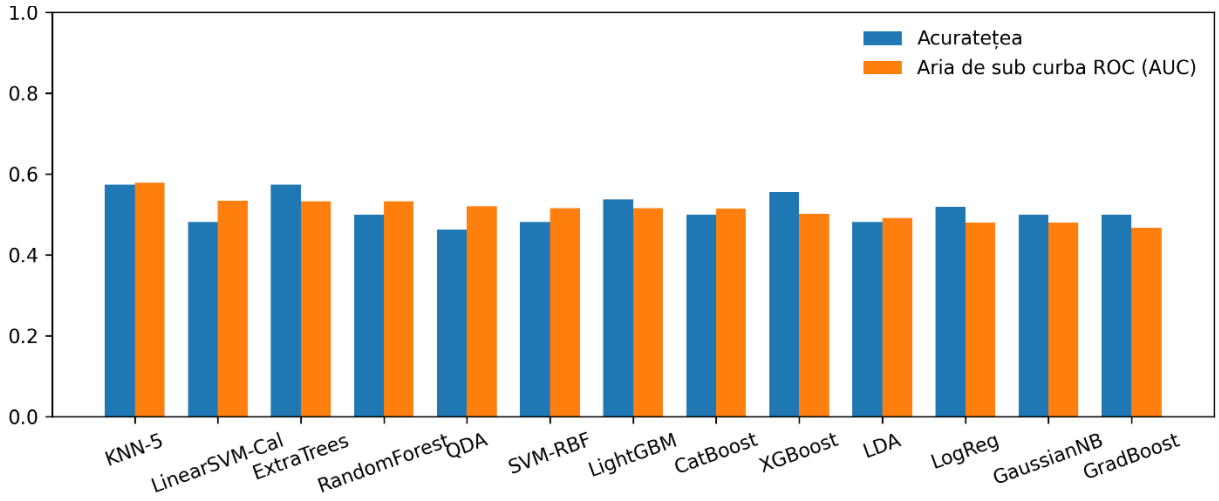


Figura 19. Comparație între modelele ML propuse

Graficul arată că performanțele sunt moderate și relativ apropiate între modele. KNN-5 și ExtraTrees sunt, per total, cele mai stabile: ating Ses_Acc ≈ 0.57 și Ses_AUC până la ≈ 0.58, depășind modelele liniare (LogReg, SVM liniar calibrat, LDA). XGBoost se plasează imediat în după modelele KNN-5 și ExtraTrees (Ses_Acc ≈ 0.56). Modelele generative (QDA, GaussianNB) au F1 ridicat per sesiune, dar AUC mai mic — semn că separarea globală este slabă și scorurile nu sunt bine calibrate, deși, pentru clasa pozitivă, raportul precizie –sensibilitate poate fi avantajos.

Tabel 3. Comparație între modelele ML propuse

Model	Win_Acc	Win_F1	Win_AUC	Ses_Acc	Ses_F1	Ses_AUC
KNN-5	0.520	0.504	0.523	0.574	0.549	0.578
LinearSVM-Cal	0.503	0.309	0.513	0.481	0.222	0.534
ExtraTrees	0.519	0.516	0.525	0.574	0.549	0.532
RandomForest	0.524	0.513	0.525	0.500	0.491	0.532
QDA	0.493	0.613	0.505	0.463	0.623	0.520
SVM-RBF	0.494	0.472	0.502	0.481	0.440	0.516
LightGBM	0.518	0.518	0.511	0.537	0.545	0.516
CatBoost	0.508	0.508	0.509	0.500	0.491	0.514
XGBoost	0.513	0.509	0.509	0.556	0.538	0.502
LDA	0.500	0.483	0.498	0.481	0.440	0.491
LogReg	0.499	0.481	0.500	0.519	0.435	0.480
GaussianNB	0.488	0.636	0.484	0.500	0.658	0.480
GradBoost	0.489	0.477	0.481	0.500	0.509	0.468

În concluzie, rezultatele confirmă că **LieWaves** este un punct de plecare potrivit pentru o investigație riguroasă a detecției minciunii pe semnale EEG în condiții realiste. Etichetarea clară (minciună/adevăr), alternanța temporală standardizată a stimulilor și forma portabilă a echipamentului susțin un lanț de procesare reproductibil: filtrare notch (50 Hz) și trece-bandă (1–45 Hz), segmentare în ferestre de 2 s cu pas de 1 s, extragere de trăsături în benzi și validare strict inter-subiect cu agregare la nivel de sesiune. Analizele exploratorii (PSD, puterea pe benzi) indică diferențe subtile între condiții, iar comparația modelelor de clasificare arată performanțe moderate dar consistente între algoritmi, cu KNN-5 și ExtraTrees ca repere robuste în regim inter-subiect. Această convergență între analiză descriptivă și evaluare ML sugerează că pipeline-ul este corect

calibrat la specificul datelor și poate servi drept bază solidă pentru extinderi. Setul de date are, însă, limitări intrinseci. Numărul redus de canale restrânge rezoluția spațială, iar paradigma cu mărgele reprezintă o formă particulară de minciună, ceea ce ridică semne de întrebare privind generalizarea către contexte mai complexe. Dimensiunea eșantionului (27 de participanți) și durata relativ scurtă a sesiunilor cresc riscul de supraînvățare, motiv pentru care validarea pe grupuri și raportarea metricei la nivel de sesiune sunt esențiale. De asemenea, pot persista artefacte oculare și muscucale asociate cu prezentarea vizuală și apăsarea butoanelor.

Bibliografie

[1] D. Makowski, T. Pham, and Z. J. Lau, “Deception_data.” Openneuro, 2023. doi: 10.18112/OPENNEURO.DS004511.V1.0.0.

[2] M. Aslan, M. Baykara, and T. B. Alakus, “LieWaves: dataset for lie detection based on EEG signals and wavelets,” *Med. Biol. Eng. Comput.*, vol. 62, no. 5, pp. 1571–1588, May 2024, doi: 10.1007/s11517-024-03021-2.